大数据系统与大规模数据分析

大数据运算系统（2）

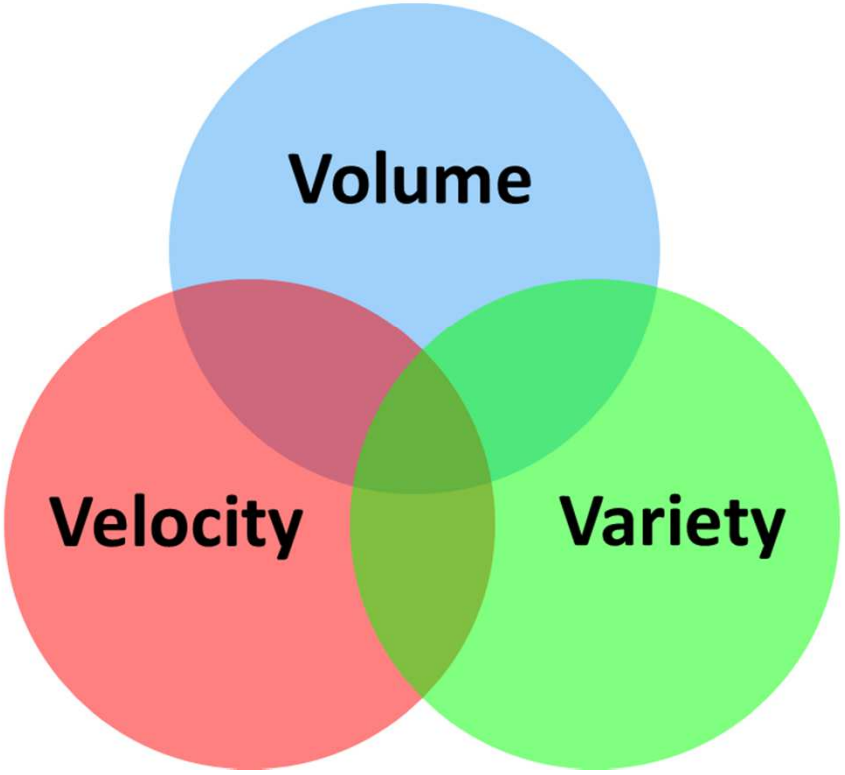

陈世敏

中科院计算所
计算机体系结构
国家重点实验室

作业时间安排

周次	内容	作业
第4周，3/11	大数据存储系统1：基础，文件系统，HDFS	作业1布置
第5周，3/18	大数据存储系统2：键值系统	
第6周，3/25	大数据存储系统3：图存储，document store	
第7周，4/1	大数据运算系统1：MapReduce, 图计算系统	作业1提交 作业2布置
第8周，4/8	大数据运算系统2：图计算系统，MR+SQL	
第9周，4/15	大数据运算系统3：内存计算系统	大作业布置
第10周，4/22	最邻近搜索和位置敏感（LHS）哈希算法	作业2提交
第11周，4/29	数据空间的维度约化	
第12周，5/6	推荐系统	作业3
第13周，5/13	流数据采样与估计、流数据过滤与分析	
第14周，5/20	教育大数据的建模与分析	
第15周，5/27	期末考试	
第16周，6/3	大作业验收报告	大作业验收

Outline

- 图计算系统
  - GraphLab
  - PowerGraph
- 数据流系统Storm
- MapReduce + SQL系统
- 内存计算
  - 内存数据库
  - 内存键值系统

Outline

- 图计算系统
  - GraphLab
  - PowerGraph
- 数据流系统Storm
- MapReduce + SQL系统
- 内存计算
  - 内存数据库
  - 内存键值系统

GraphLab

- "***GraphLab: A New Framework For Parallel Machine Learning***". Yucheng Low, Joseph Gonzalez, Aapo Kyrola, Danny Bickson, Carlos Guestrin, Joseph M. Hellerstein. **UAI 2010**.
- "*Distributed GraphLab: A Framework for Machine Learning and Data Mining in the Cloud*." Yucheng Low, Joseph Gonzalez, Aapo Kyrola, Danny Bickson, Carlos Guestrin and Joseph M. Hellerstein. **PVLDB 2012**.

GraphLab

- 单机系统
- 共享内存
  - 多个线程都可以访问图数据
  - 线程之间不用发送和接收消息
- 异步计算
  - 不分超步，允许不同顶点有不同的更新速度
  - 适合支持机器学习算法，在不同部分收敛速度不同
    - 注意：许多机器学习算法没有“精确”的结果
    - 异步计算收敛的结果和同步计算收敛的结果可能是不一样的

数据模型

- Data graph G=(V, E)
  - 每个顶点可以有数据D_v
  - 每条边可以有数据$D_{u->v}$
- 全局数据表(SDT, shared data table)
  - SDT[key] ➔ value
  - 可以定义全局可见的数据

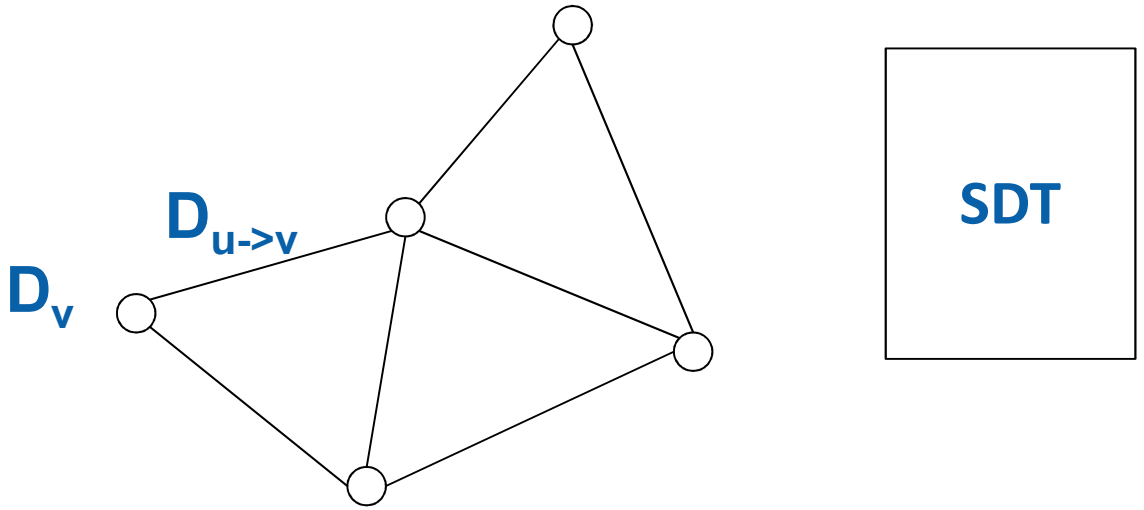

顶点计算

- $D_{Scope_v} = update(D_{Scope_v}; SDT)$
  - update类似Pregel compute，是应用程序
  - $Scope_v$是顶点运算涉及的范围
    - 包括顶点v，v的相邻边，和v的相邻顶点
  - 运算是**直接访问内存**进行的
  - update直接修改顶点和边上的数据，**修改立即可见**，而不是下个超步才可见

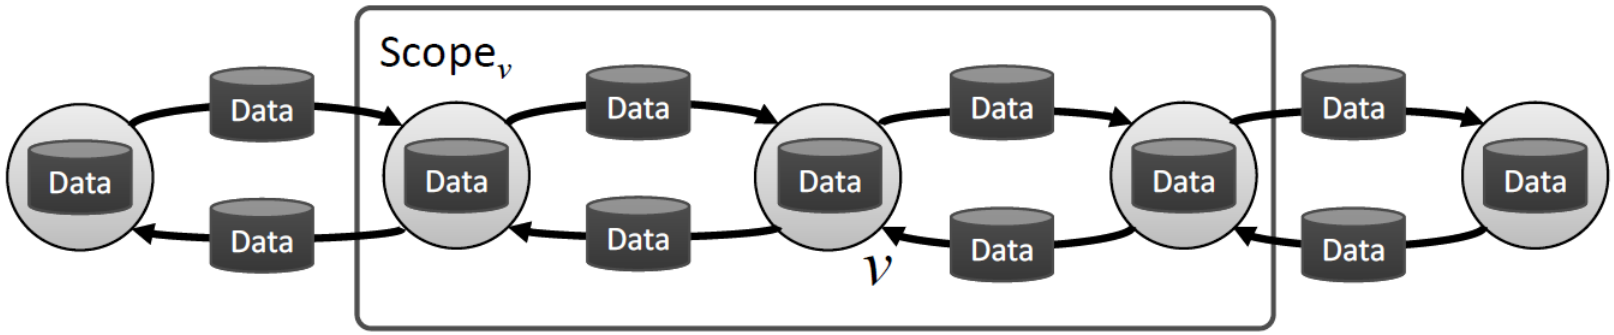

共享内存有什么问题？

- 数据竞争（Data Race）
- 避免数据竞争
  - 提出三种一致性模型
  - 要求应用程序选择其中一种
  - 系统根据一致性模型，避免数据竞争，并发执行

三种一致性模型

- Full consistency
  - 应用程序update需要访问整个$Scope_v$
  - 系统保证在update执行过程中，没有任何其它函数会访问$Scope_v$
    - 对并行执行的限制最大

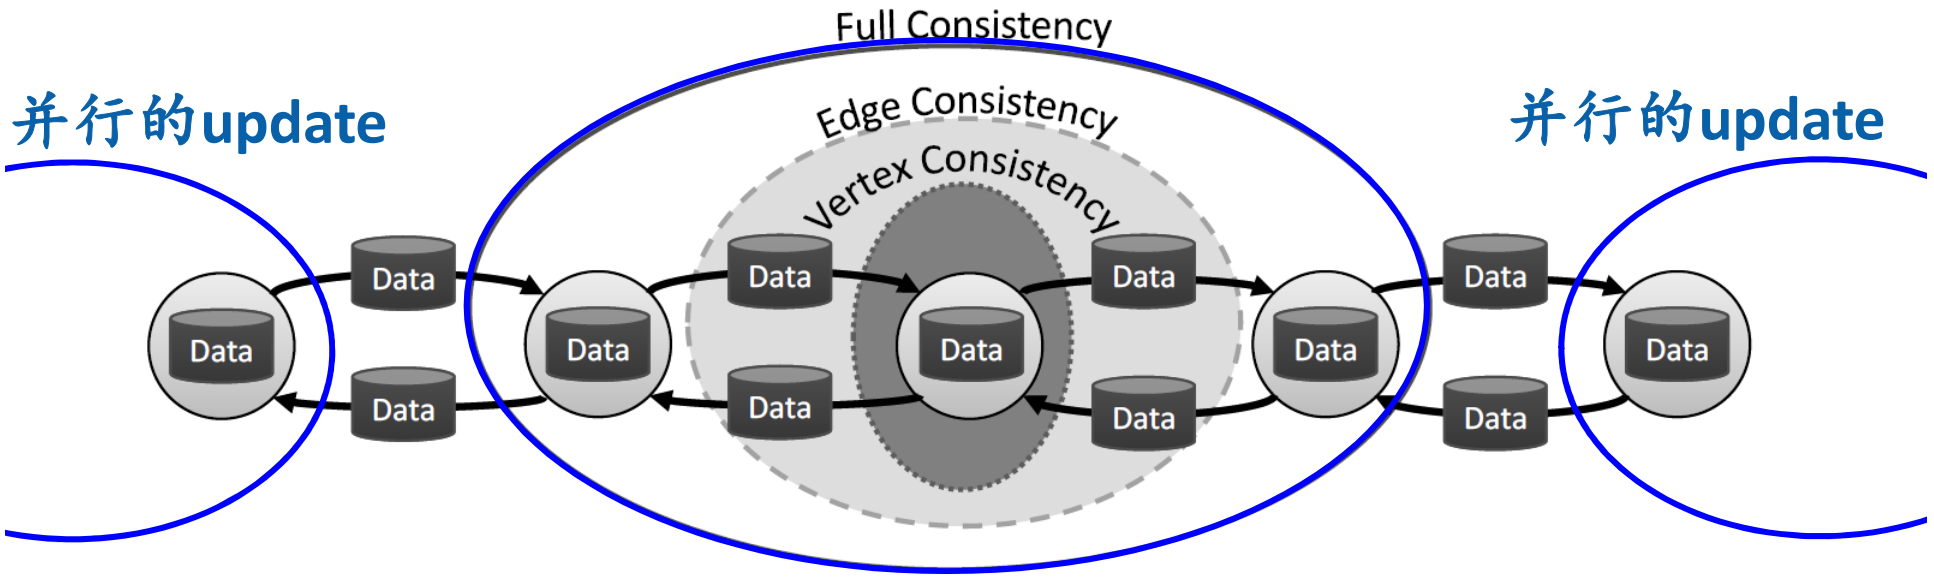

三种一致性模型

- Edge consistency:
  - 应用程序update不写邻居顶点的数据，但可能读邻居顶点的数据
    - 可以写v, v的邻边
    - 可以读整个$Scope_v$
  - 系统保证在update执行过程中，没有任何其它函数会访问v及其邻边

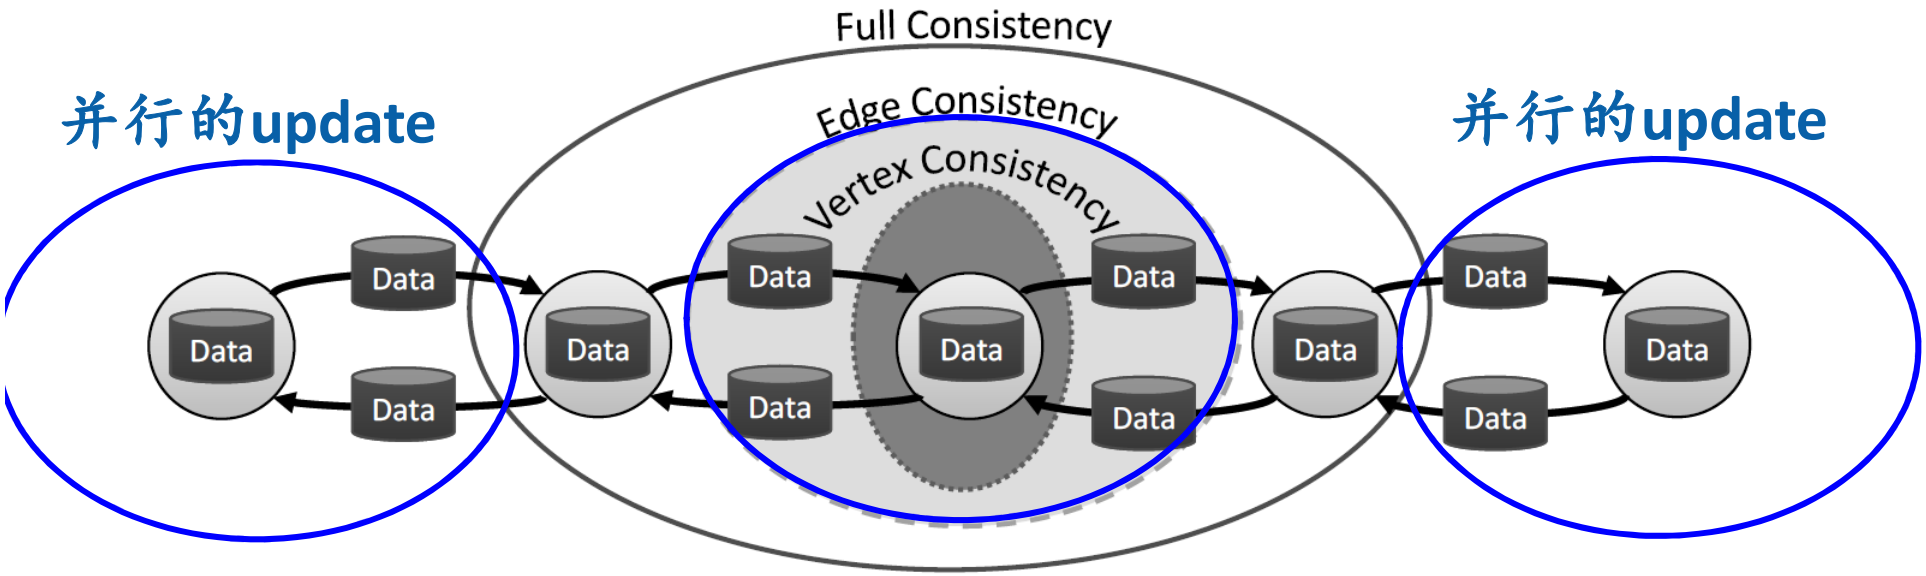

三种一致性模型

- Vertex consistency
  - 应用程序update只读写本顶点的数据，和读v邻边的数据
  - 系统保证在update执行过程中，没有任何其它函数会访问v本身

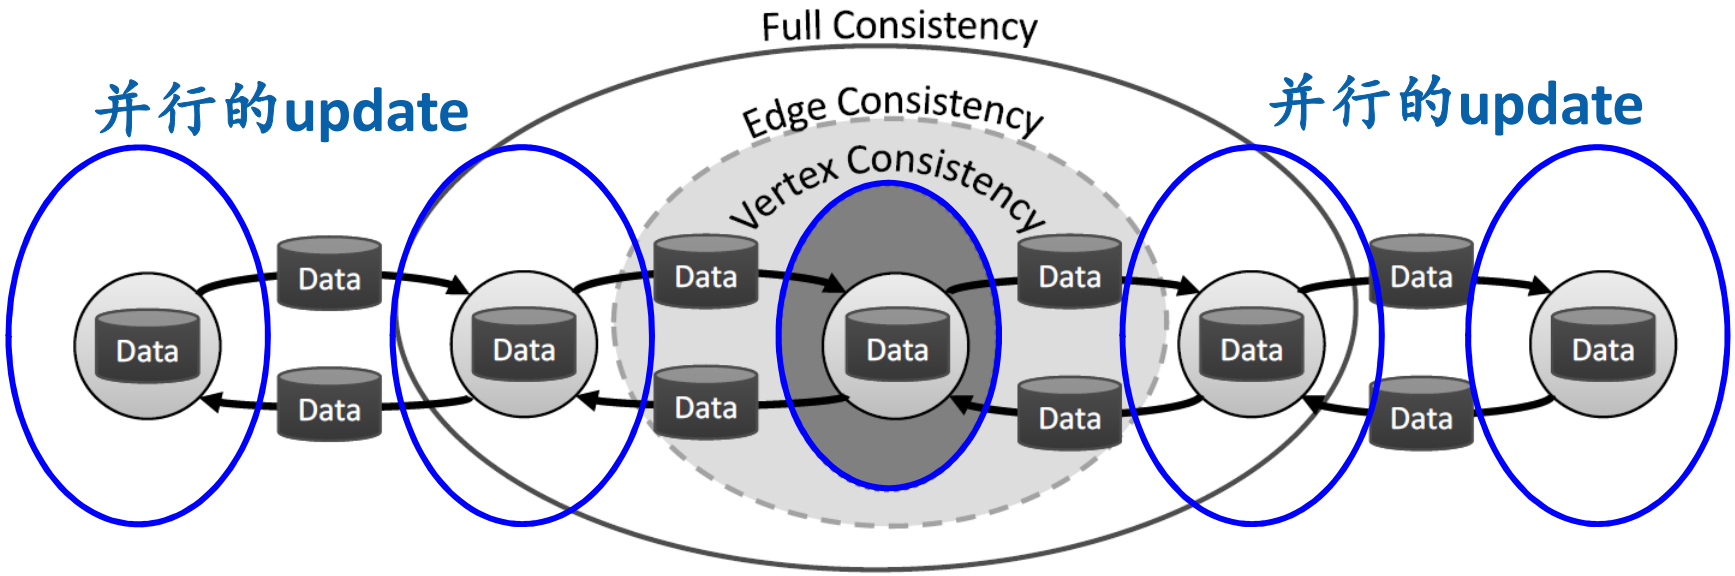

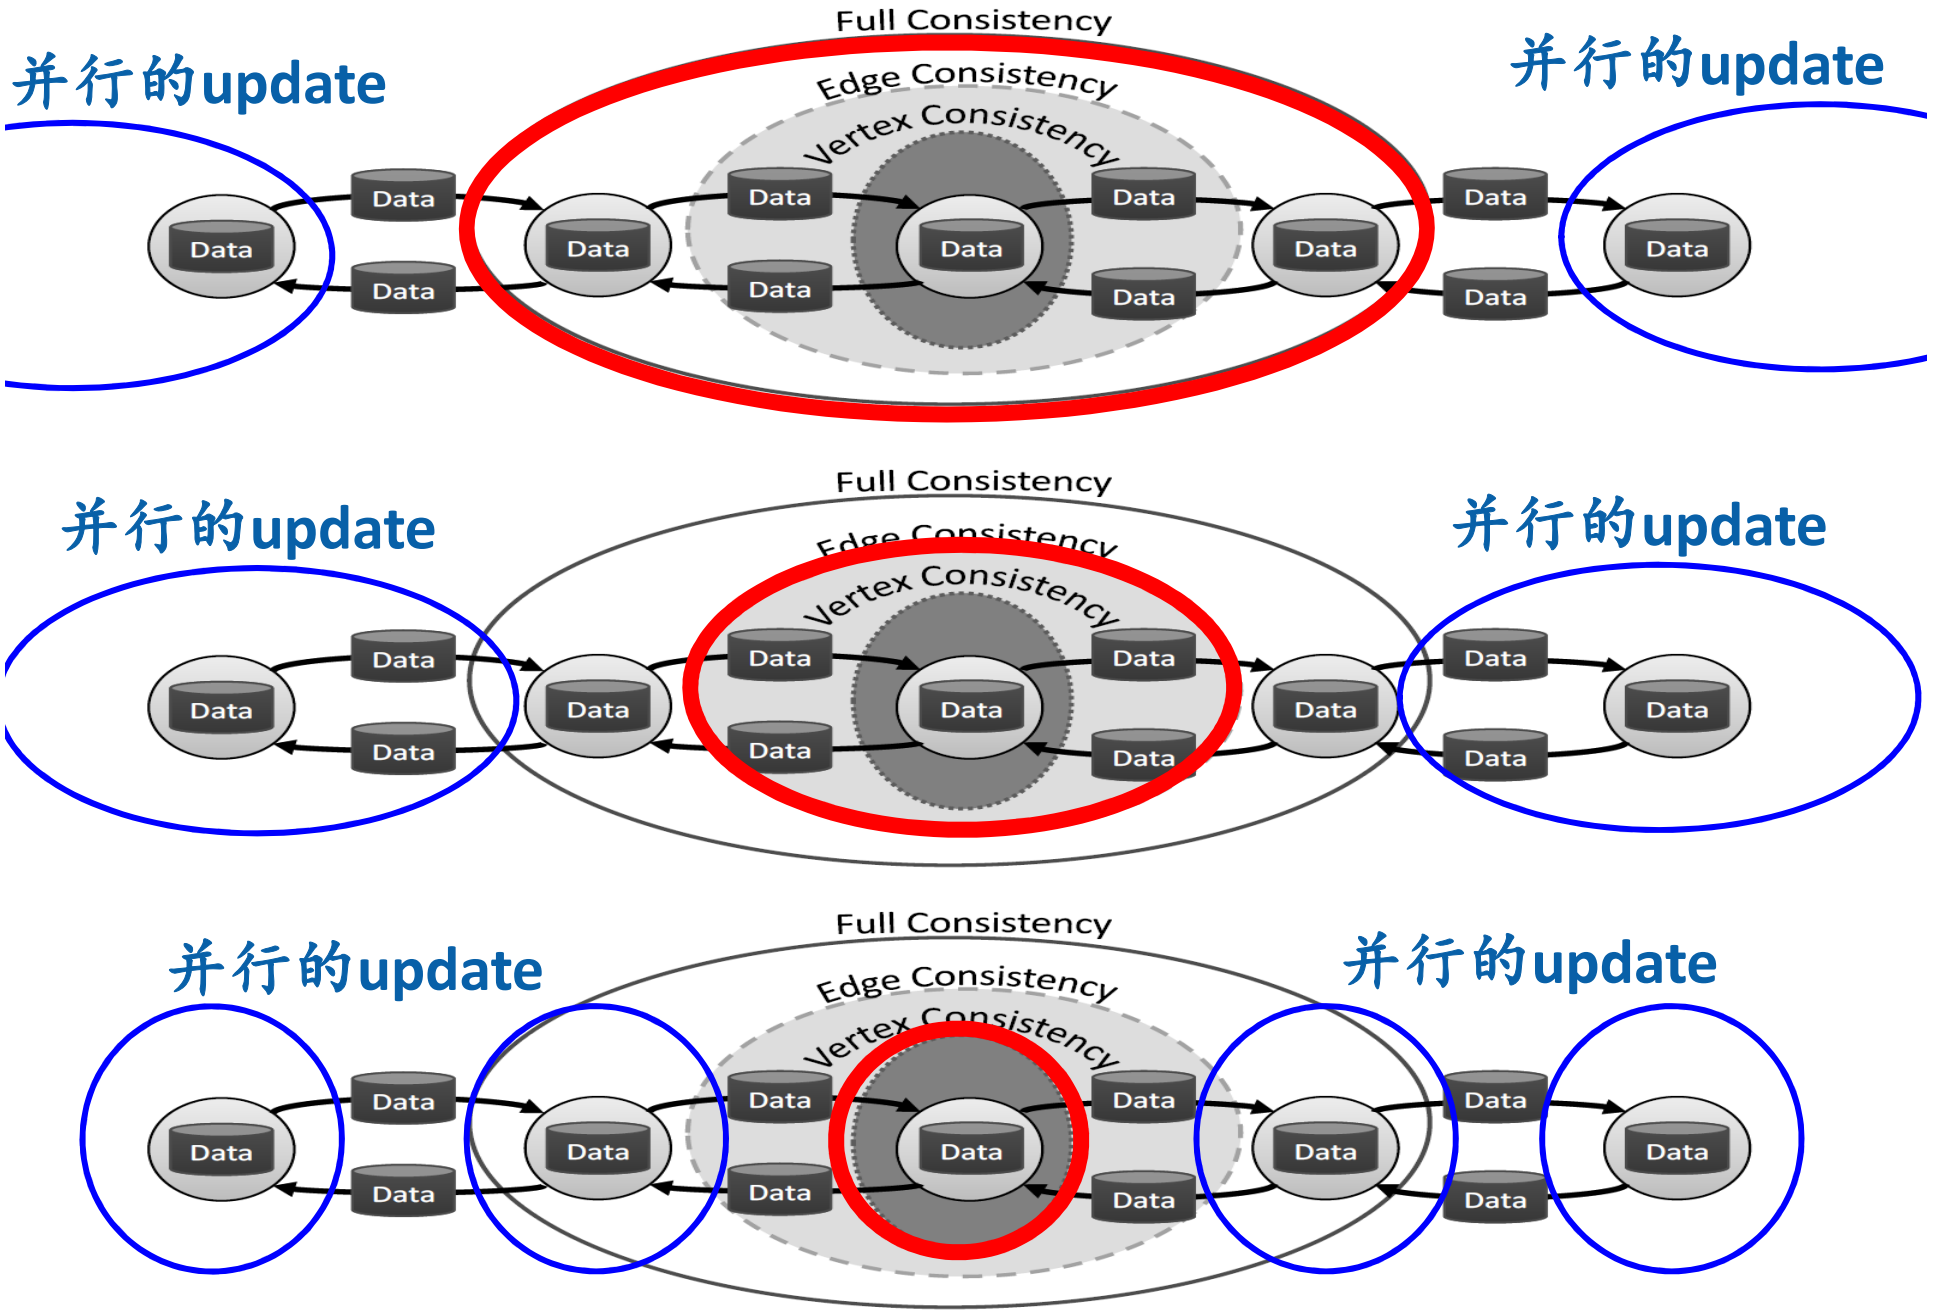
并行的update
Full Consistency
Edge Consistency
Vertex Consistency
并行的update
Data
并行的update
Full Consistency
Edge Consistency
Vertex Consistency
并行的update
Data
并行的update
Full Consistency
Edge Consistency
Vertex Consistency
并行的update
Data

Scheduling

- 系统按照什么顶点顺序调用update程序?
- 支持多种选择
  - Synchronous scheduler: 类似同步图运算
  - Round-robin scheduler: 顺序计算每个顶点，下一个顶点可以看到前面的计算结果
  - FIFO scheduler: update中调用AddTask创建新的Task，Task对应顶点的update，创建的Task按照先进先出顺序执行
  - Prioritized scheduler: 创建Task并指定优先顺序

Sync计算

- 除了update计算，GraphLab还定义了一种全局的计算sync
- Sync类似在所有的顶点上计算一个aggregate
  - 程序员提供fold和apply函数，给定一个初始值initial_value和一个key
  - 系统执行下面的操作：

```
t = initial_value;
foreach v ∈ V {
    t = fold(v, t);
}
SDT[key] = apply(t);
```

- 例如：可以计算update运算是否已经收敛

GraphLab

- 以顶点为中心的计算
- 异步计算
  - 可以定义不同的scheduling策略
- 可以立即看到完成的计算结果
  - 共享内存方式编程，而不是消息传递方式
  - 需要一致性模型
    - Full, edge, vertex consistency模型
- 采用一种全局的aggregate机制帮助判断是否收敛

Outline

- 图计算系统
  - GraphLab
  - PowerGraph
- 数据流系统Storm
- MapReduce + SQL系统
- 内存计算
  - 内存数据库
  - 内存键值系统

PowerGraph

- “PowerGraph: Distributed Graph-Parallel Computation on Natural Graphs.” Joseph E. Gonzalez, Yucheng Low, Haijie Gu, Danny Bickson, and Carlos Guestrin. **OSDI 2012**.

- 下面的slides基于OSDI’12

大量自然图符合Power-Law

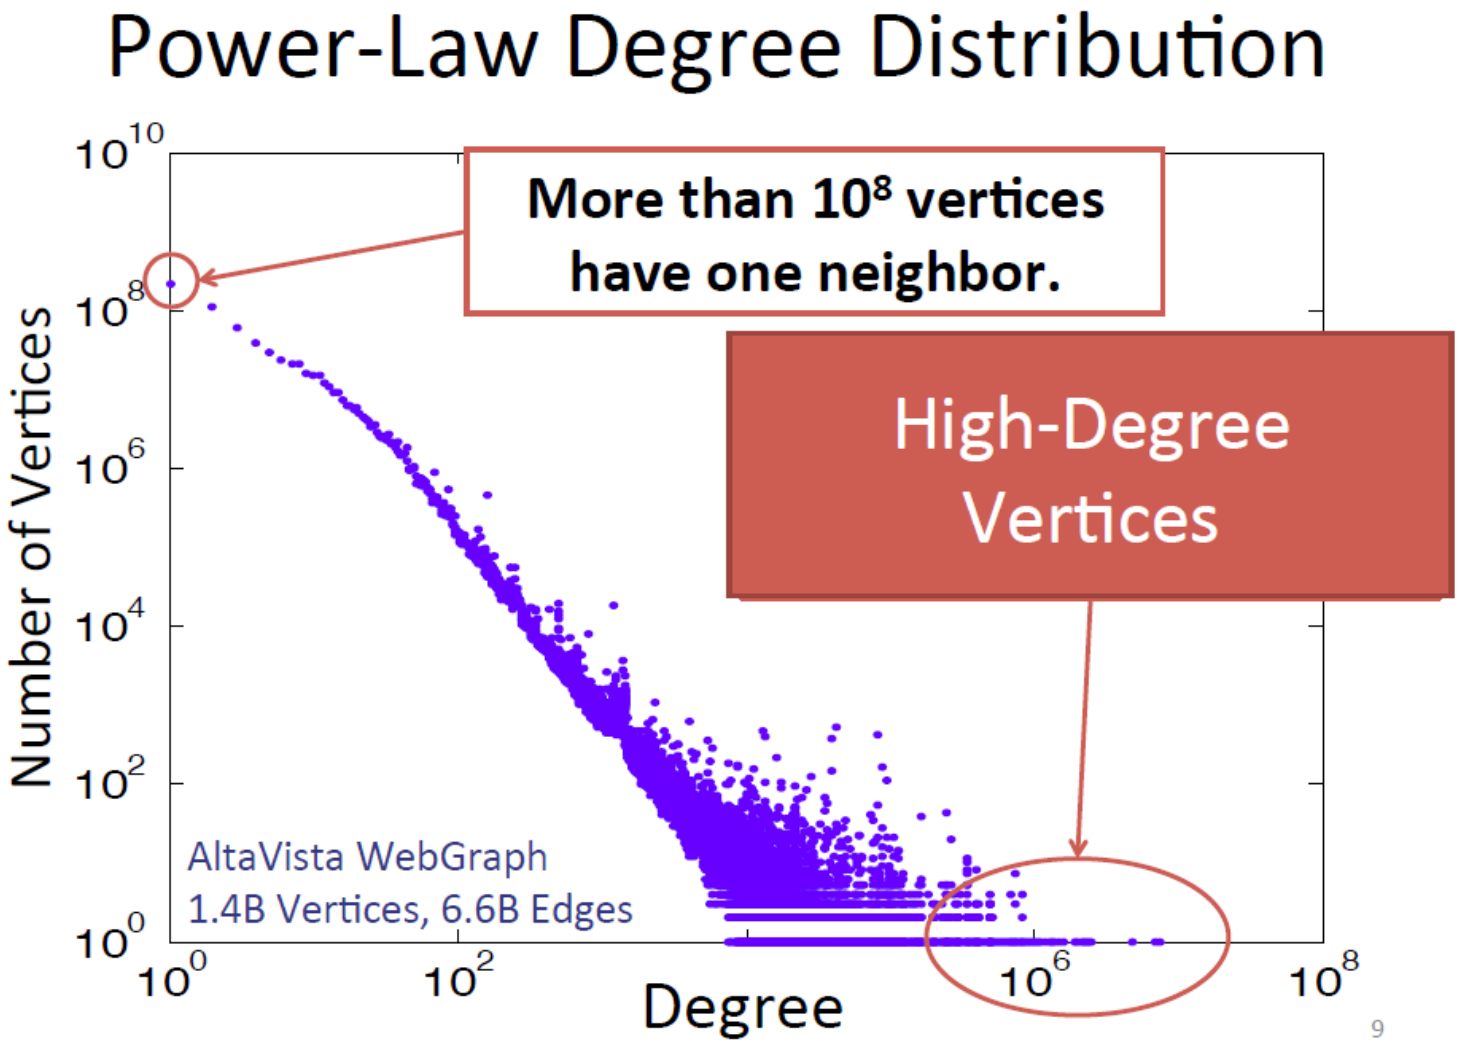

Power-Law引起的问题

- 图划分之间有大量的跨边
- Pregel
  - 需要传输大量的消息
- 如何优化？

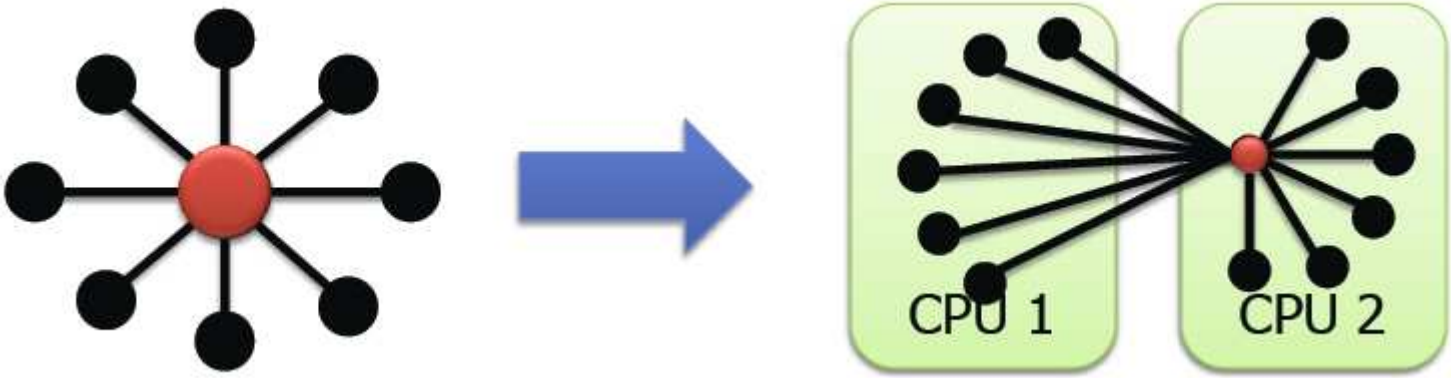

PowerGraph

- 把单一的Compute()分成三个用户函数GAS来实现
  - Gather
  - Apply
  - Scatter
- 利用了一大类图计算算法的特点
- 实际的效果
  好像把大度顶点
  分裂成为了多个

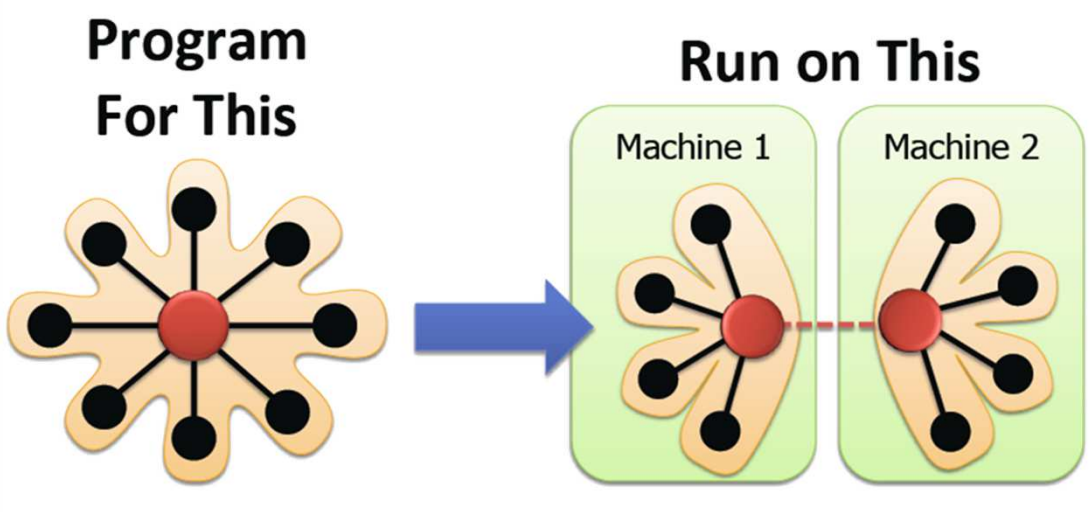

图算法举例：PageRank

- $R_u = 0.15 + 0.85 \sum_{v \in B(u)} \frac{R_v}{L_v}$
  - R_v: 顶点v的PageRank*N
  - L_v: 顶点v的出度（出边的条数）
  - $B(u)$: 顶点u的入邻居集合
  - damping factor为0.85
  - N: 总顶点个数

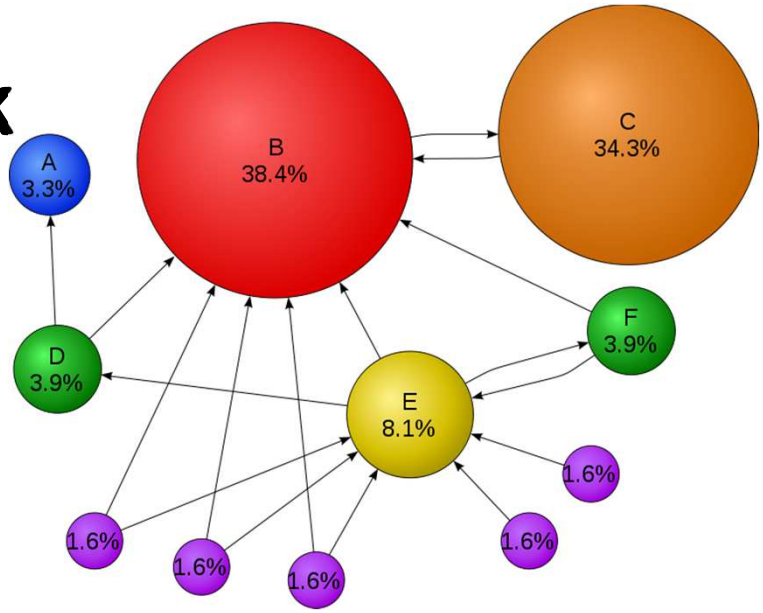

图来源：Wikipedia

- 计算方法
  - 初始化：所有的顶点的PageRank为1
  - 迭代：用上述公式迭代直至收敛

GraphLite的实现

```
double sum= 0.0;
for (; !msgs->done(); msgs->next()) {
    sum += msgs->getValue();
}
```

接收消息

```
val = 0.15 + 0.85 * sum;
*mutableValue() = val;
```

更新状态

```
int64_t n = getOutEdgeIterator().size();
sendMessageToAllNeighbors(val / n);
```

发送消息

GAS抽象

```
double sum= 0.0;
for (; !msgs->done(); msgs->next()) {
    sum += msgs->getValue();
}
```

改为 Gather

```
val = 0.15 + 0.85 * sum;
*mutableValue() = val;
```

改为 Apply

```
int64_t n = getOutEdgeIterator().size();
sendMessageToAllNeighbors(val / n);
```

改为 Scatter

GAS Decomposition

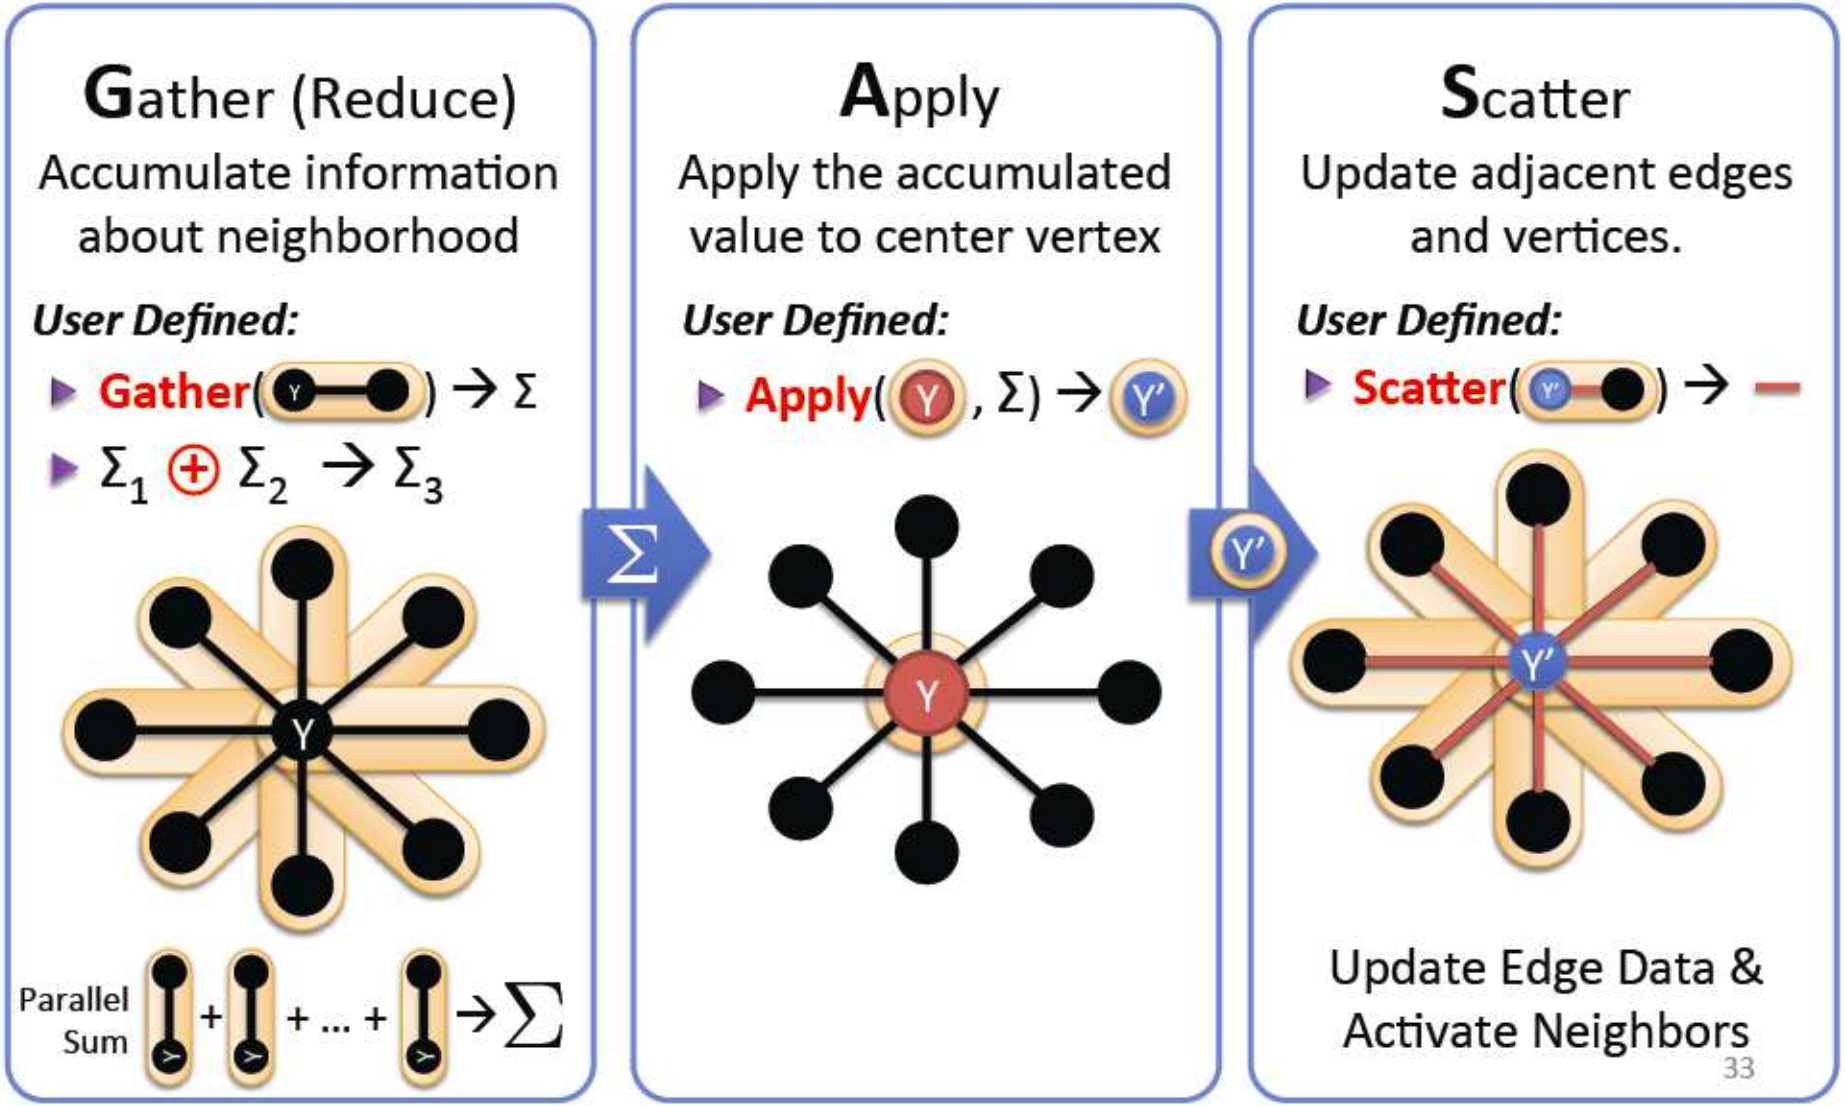

具体实现：通常的划分

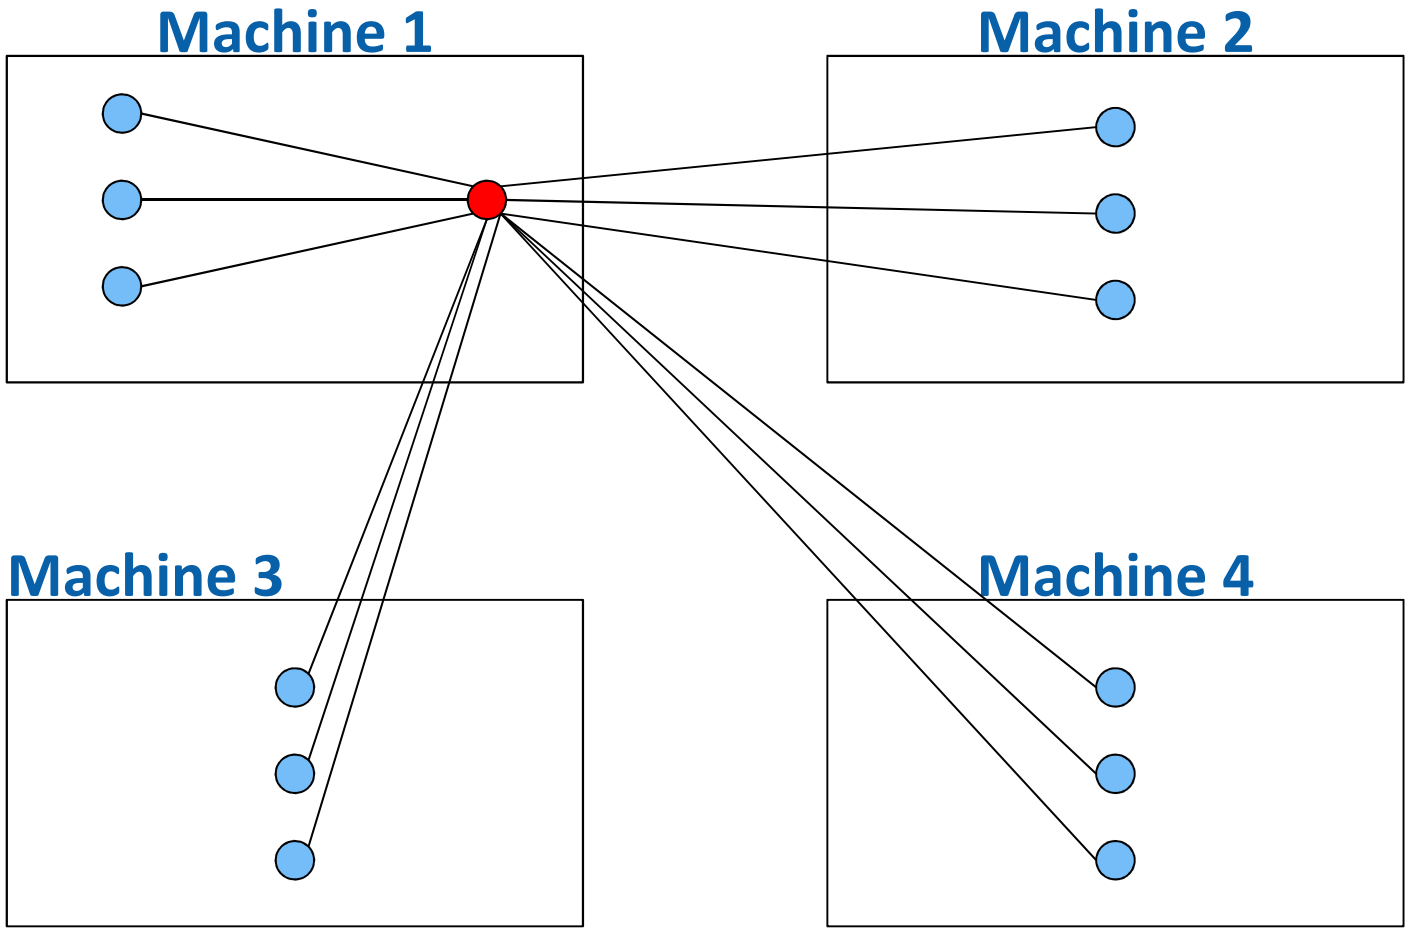

具体实现：PowerGraph

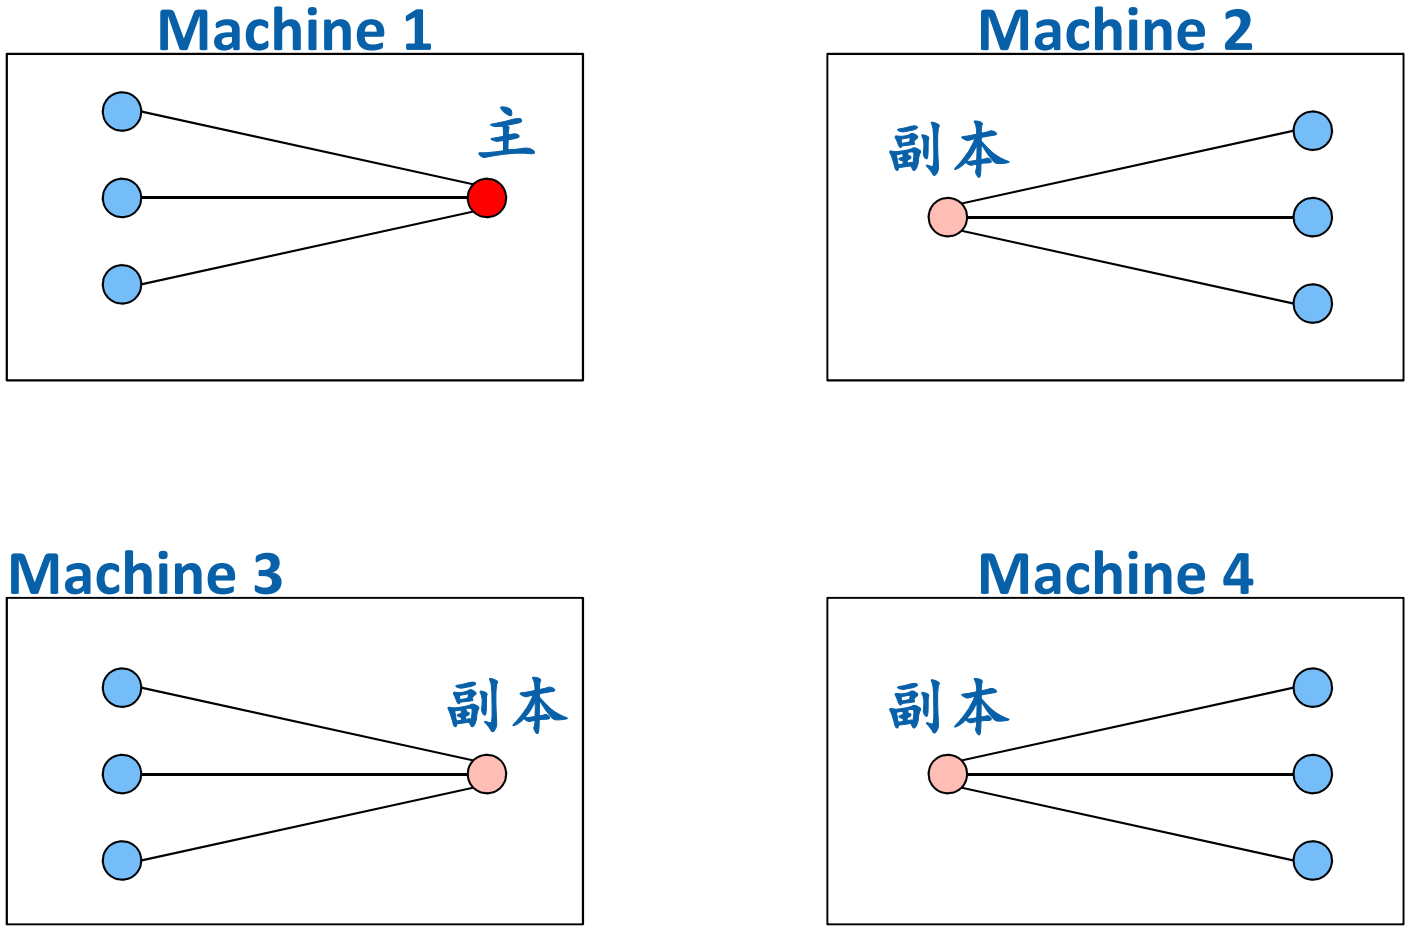

GAS Decomposition

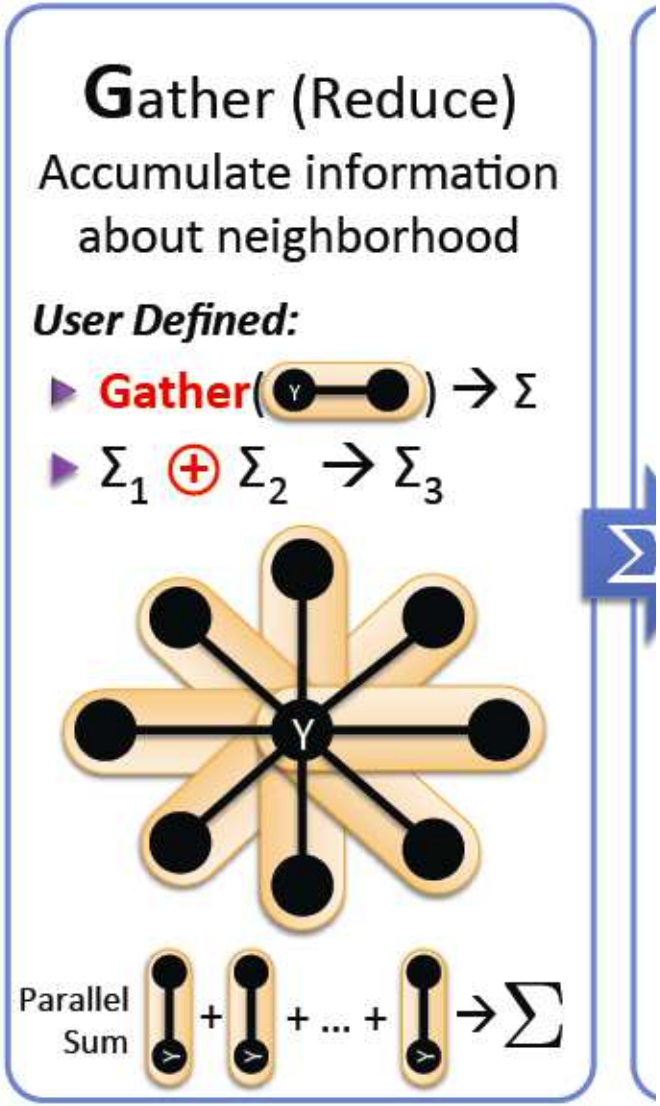

具体实现：Gather，收消息求局部和

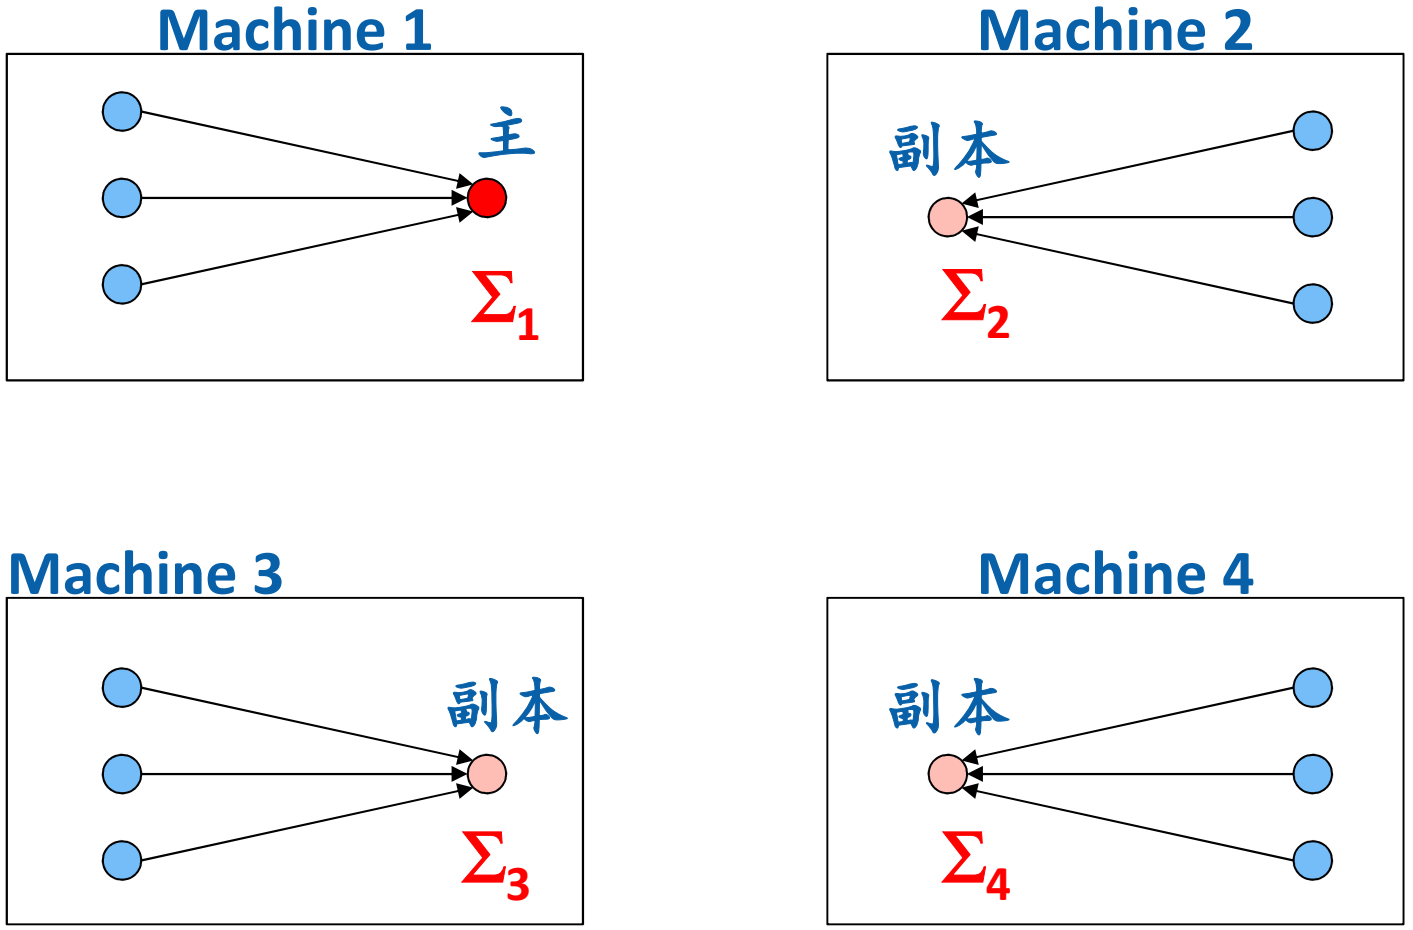

- Gather( ) → Σ
- $\Sigma_1 \oplus \Sigma_2 \rightarrow \Sigma_3$

具体实现：Gather，局部和➔全局和

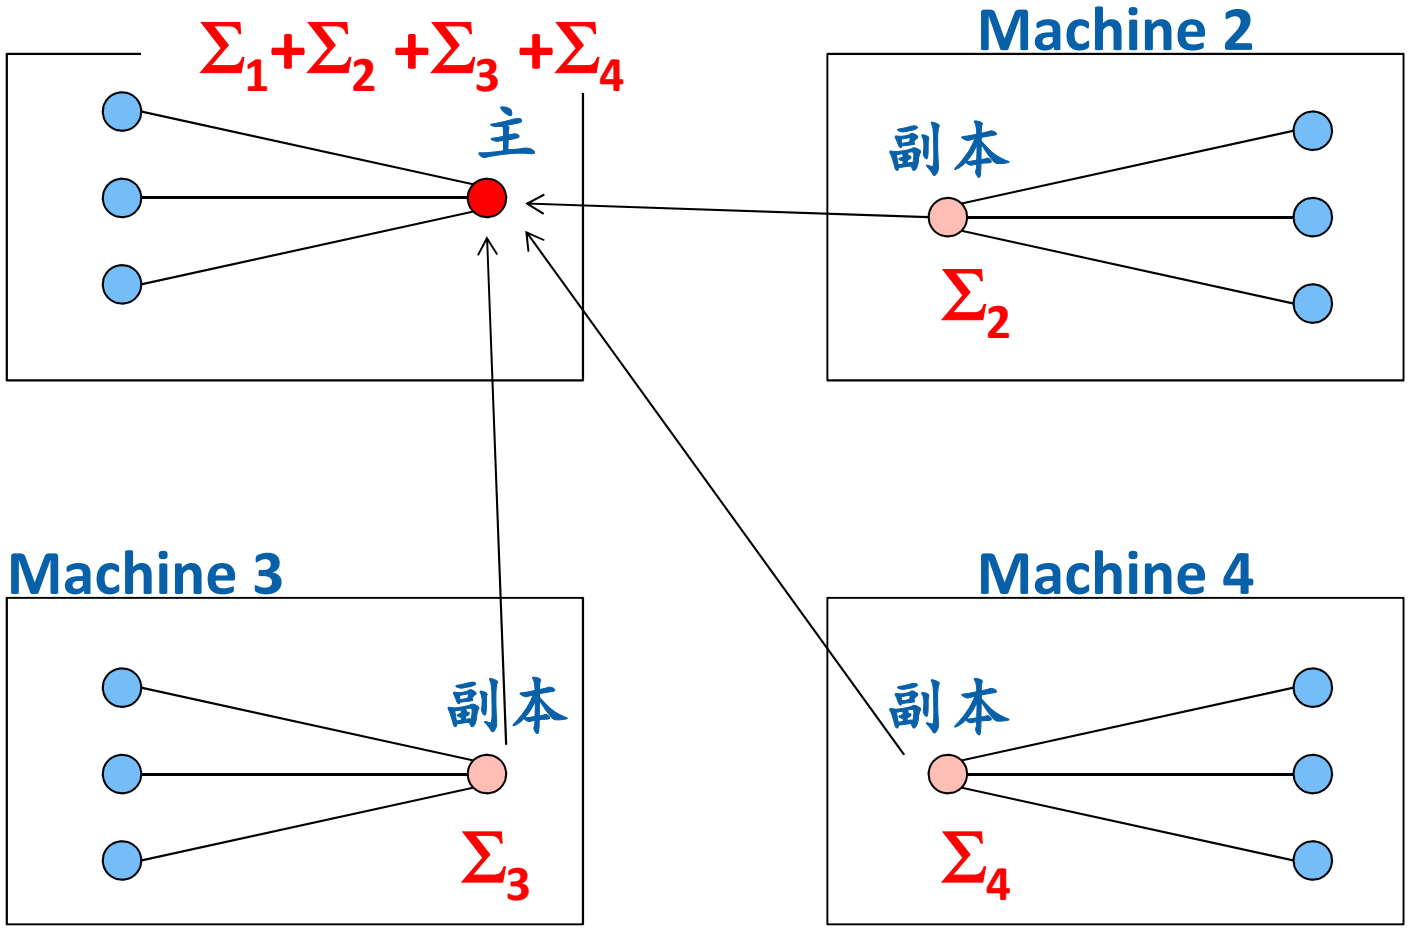

- Gather( ) → Σ
- $\Sigma_1 \oplus \Sigma_2 \rightarrow \Sigma_3$

GAS Decomposition

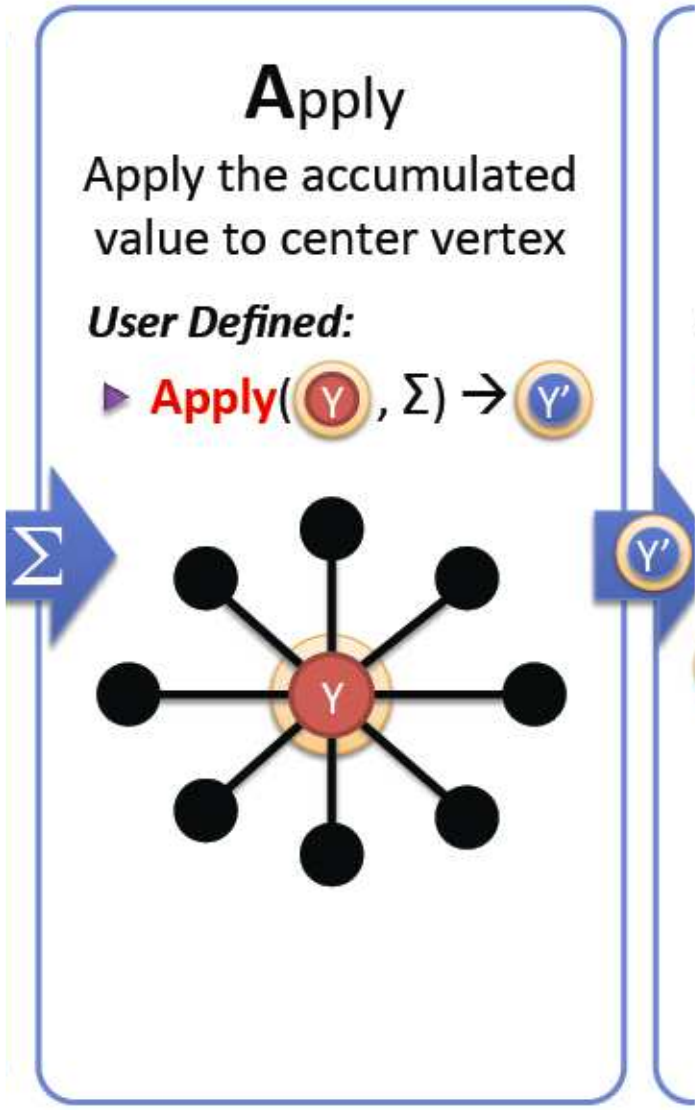

具体实现：Apply，在主顶点更新PageRank

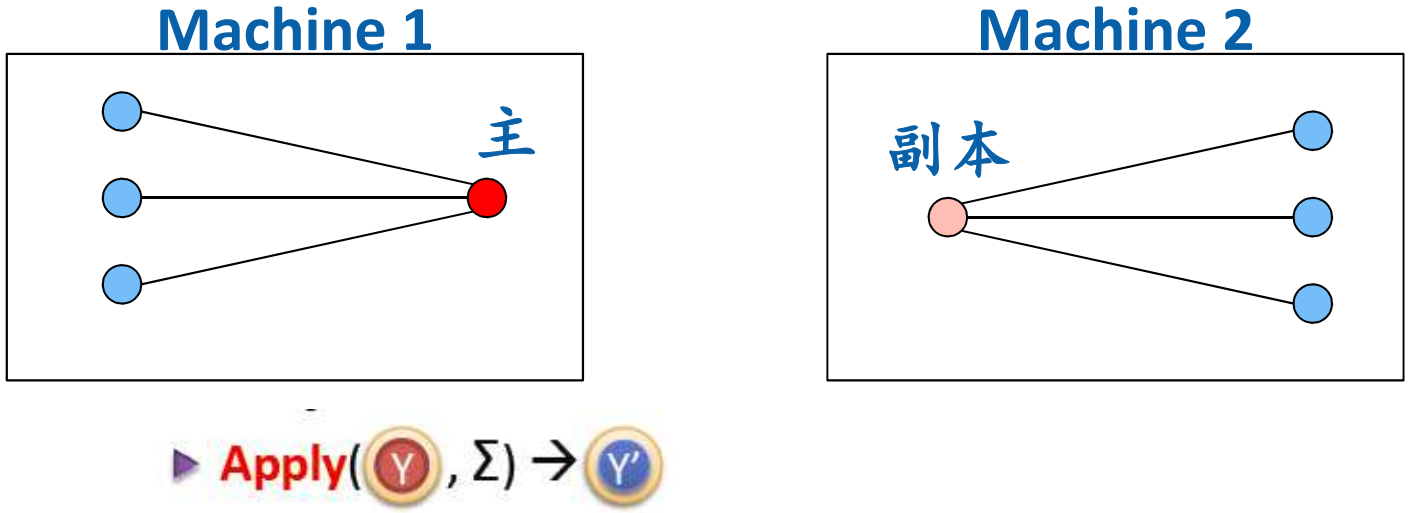

GAS Decomposition

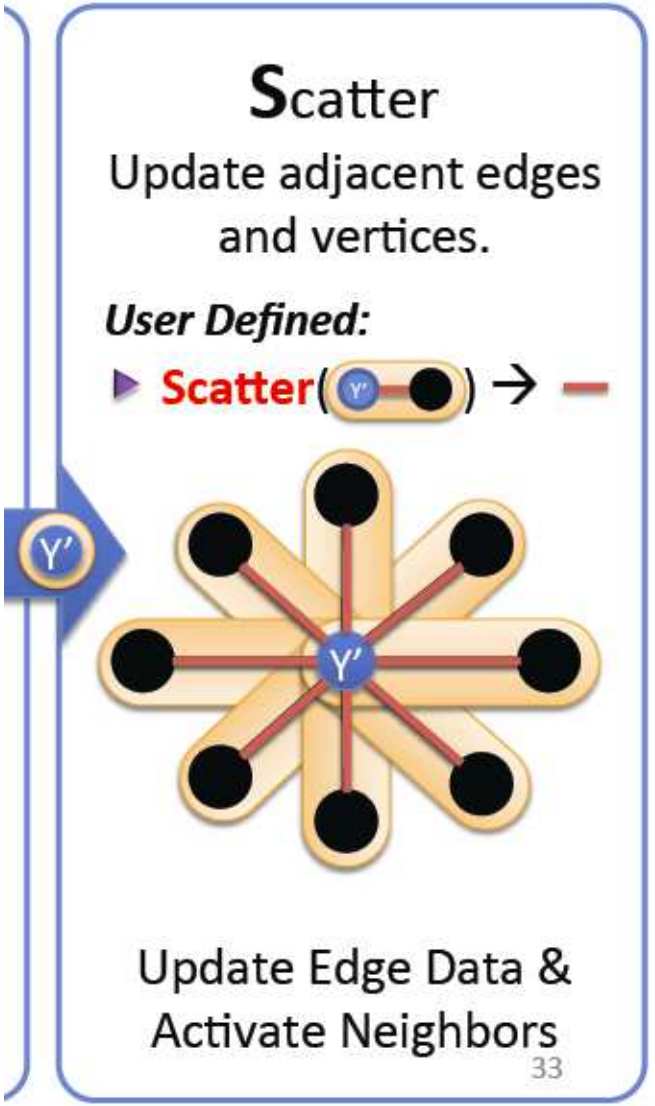

具体实现：Scatter，发送消息

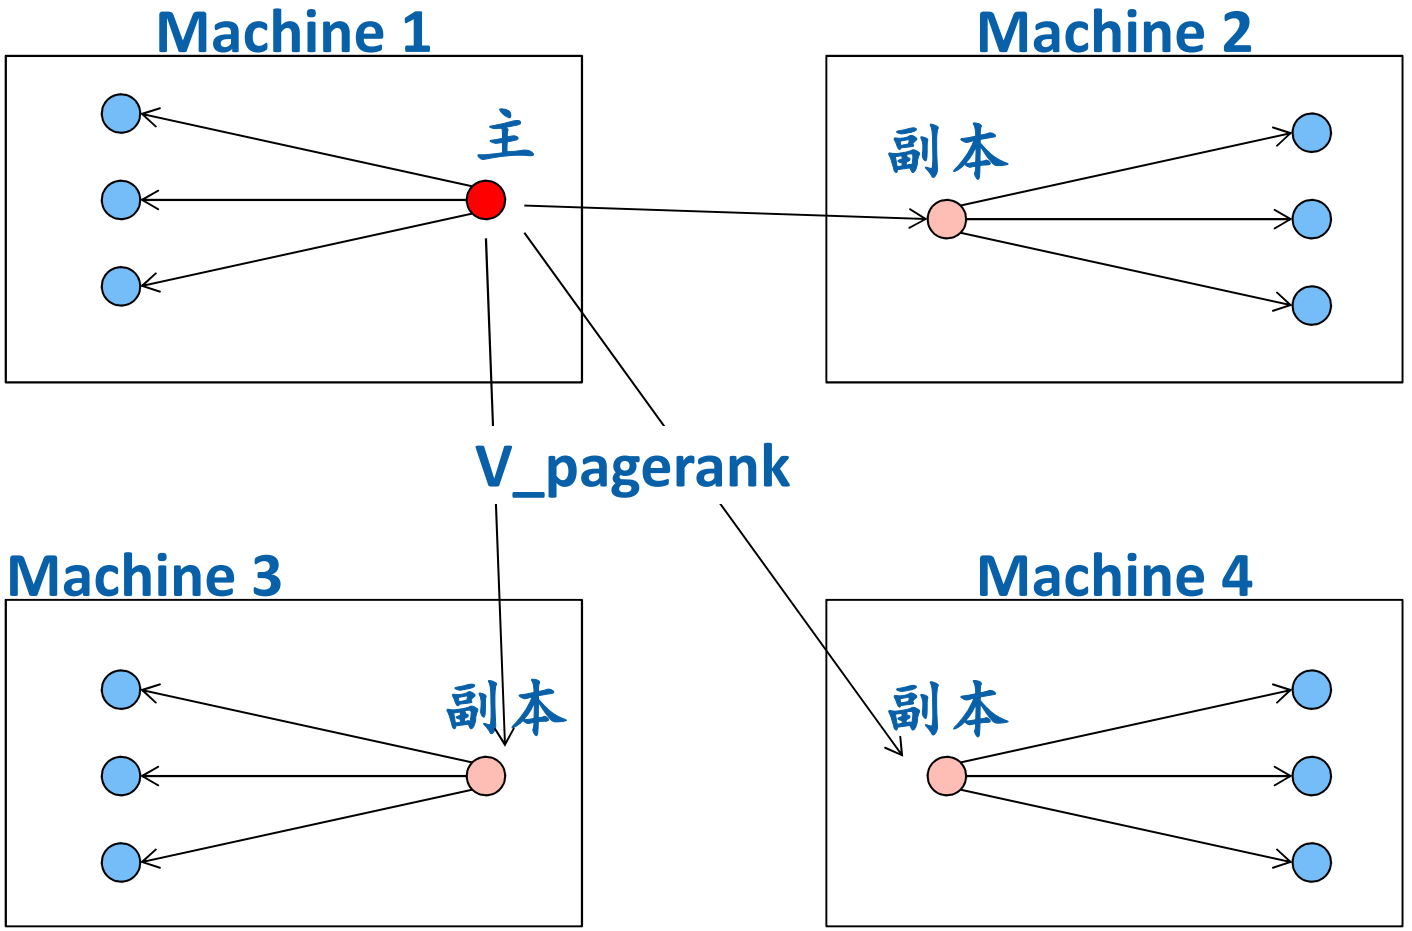

▶ Scatter( ) →

PowerGraph

- 分布式图计算
- 针对Power-law图
- 提出GAS模型

Outline

- 图计算系统
  - GraphLab
  - PowerGraph
- 数据流系统Storm
- MapReduce + SQL系统
- 内存计算
  - 内存数据库
  - 内存键值系统

数据流

- 概念
  - 数据流过系统
  - 在流动的数据上完成处理

Apache Storm

- Twitter于2011年9月发布
  - 目前是Apache的开源项目
- 数据流处理
- 内部实现：Java 与 Clojure混合实现
  - 大部分功能代码是Clojure写的
    - Clojure一种Lisp
    - 编译成为JVM bytecode
  - 提供的编程接口主要为Java
    - 函数说明等基本是Java
    - 通过thrift支持多种语言

Storm 系统结构

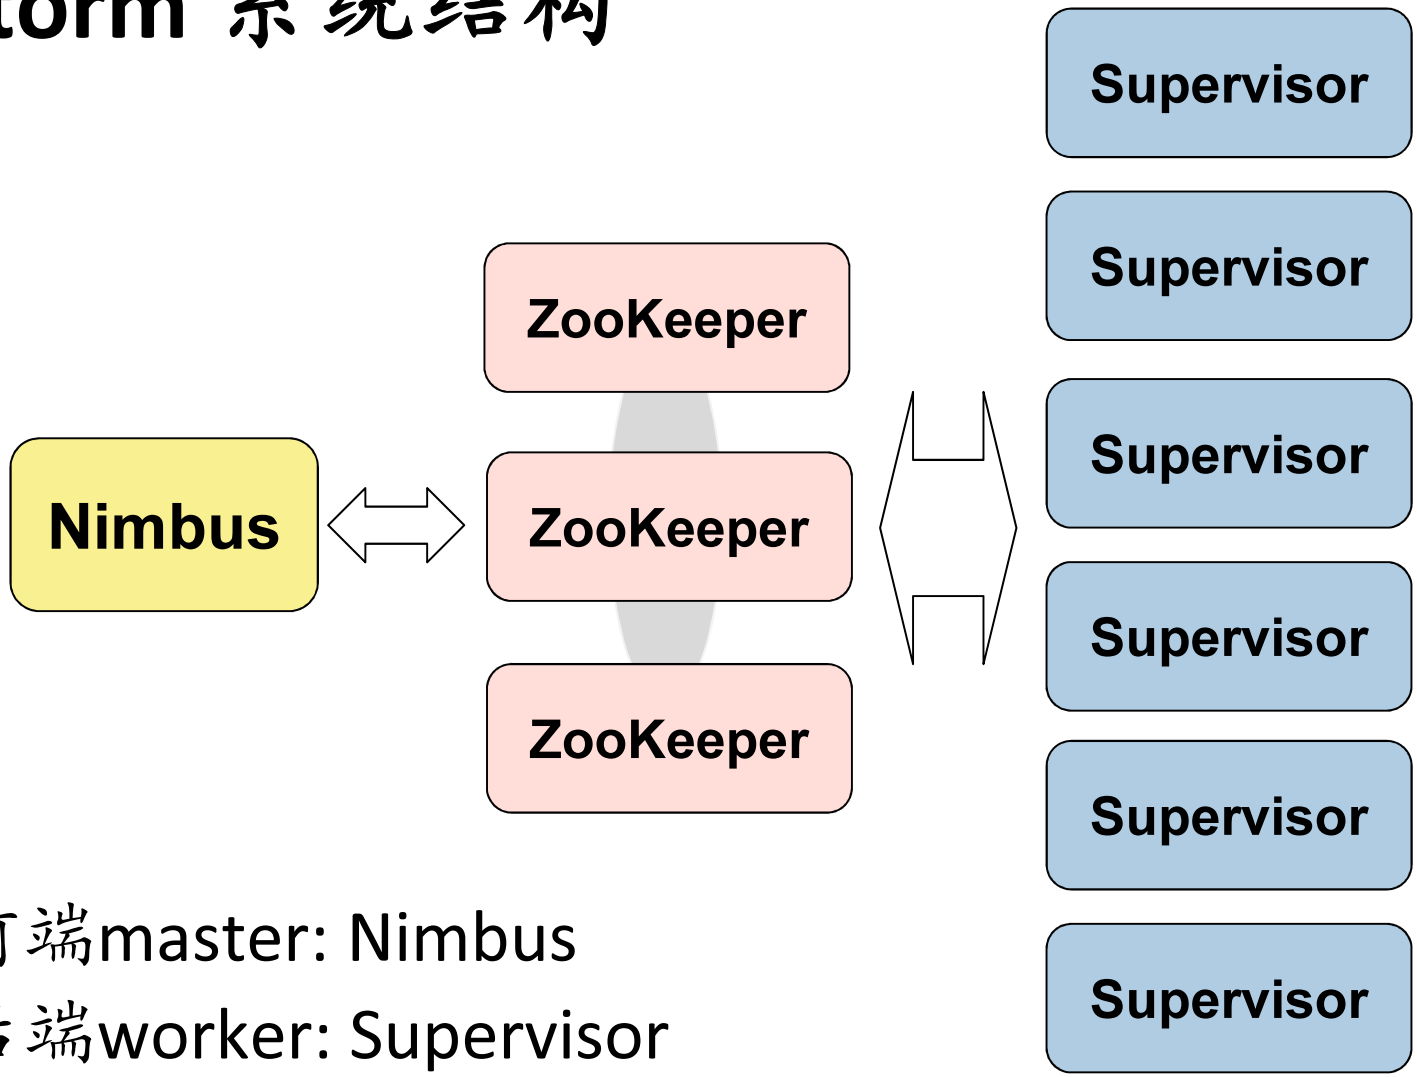

- 前端master: Nimbus
- 后端worker: Supervisor
- 通过ZooKeeper通信

Storm程序概念

- 计算形成一个有向无环图DAG
  - DAG用一个Topolopy数据结构表示
  - 每个job有一个Topology
  - 对应于数据流处理运算关系的一张图
- Topology中的每个顶点代表一个运算
  - Spout：产生数据流
    - 没有输入，有输出
  - Bolt：对数据流进行某种运算
    - 有输入，有输出
- Topology中两个顶点之间的边代表数据流动的关系

Topology

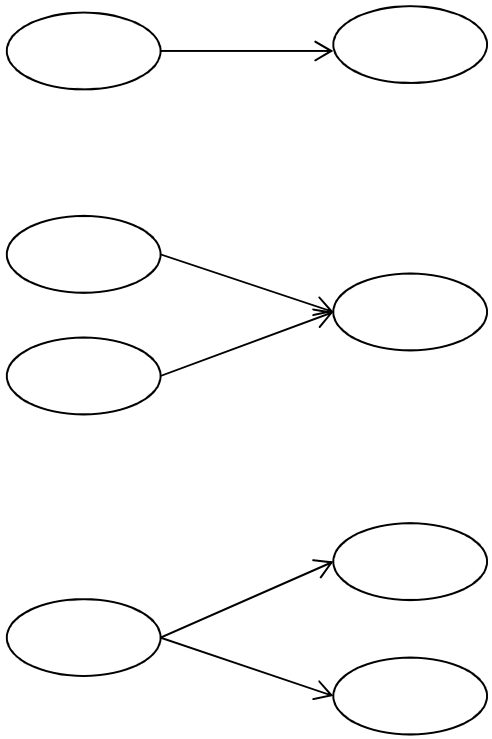

- 可以有很多不同结构

举例:一个简单的Topology和程序

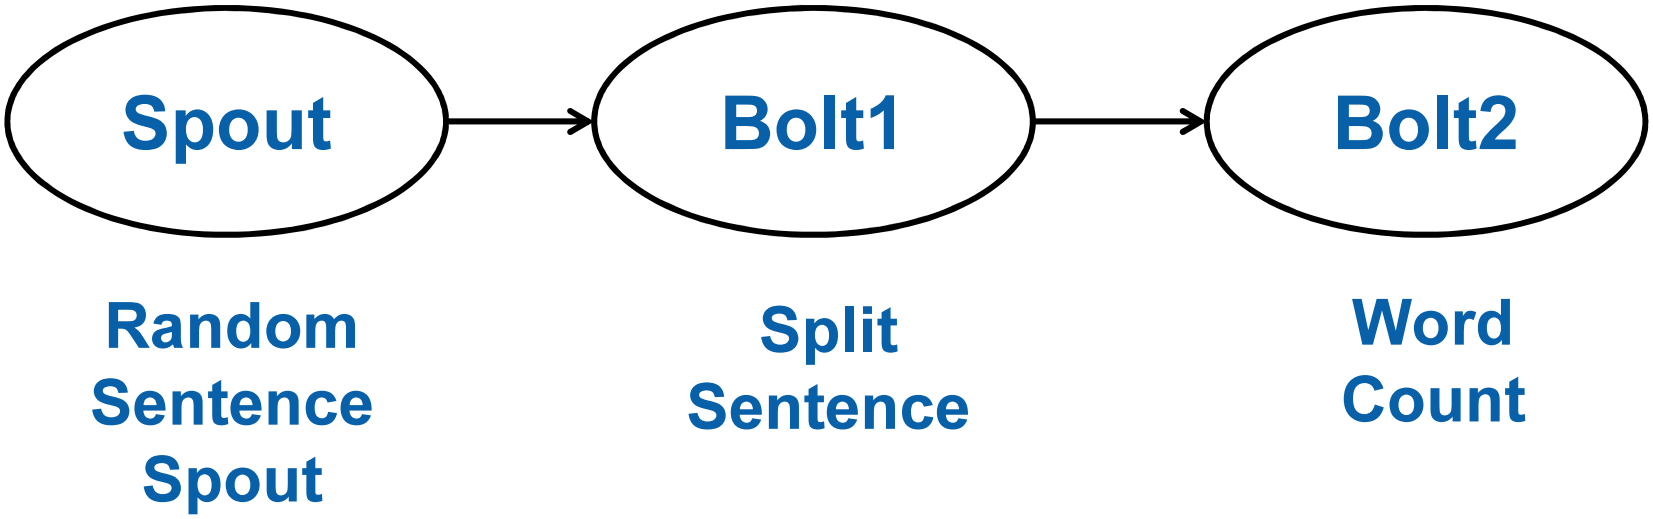

- Topology表示数据流上定义的一组运算

举例:一个简单的Topology和程序

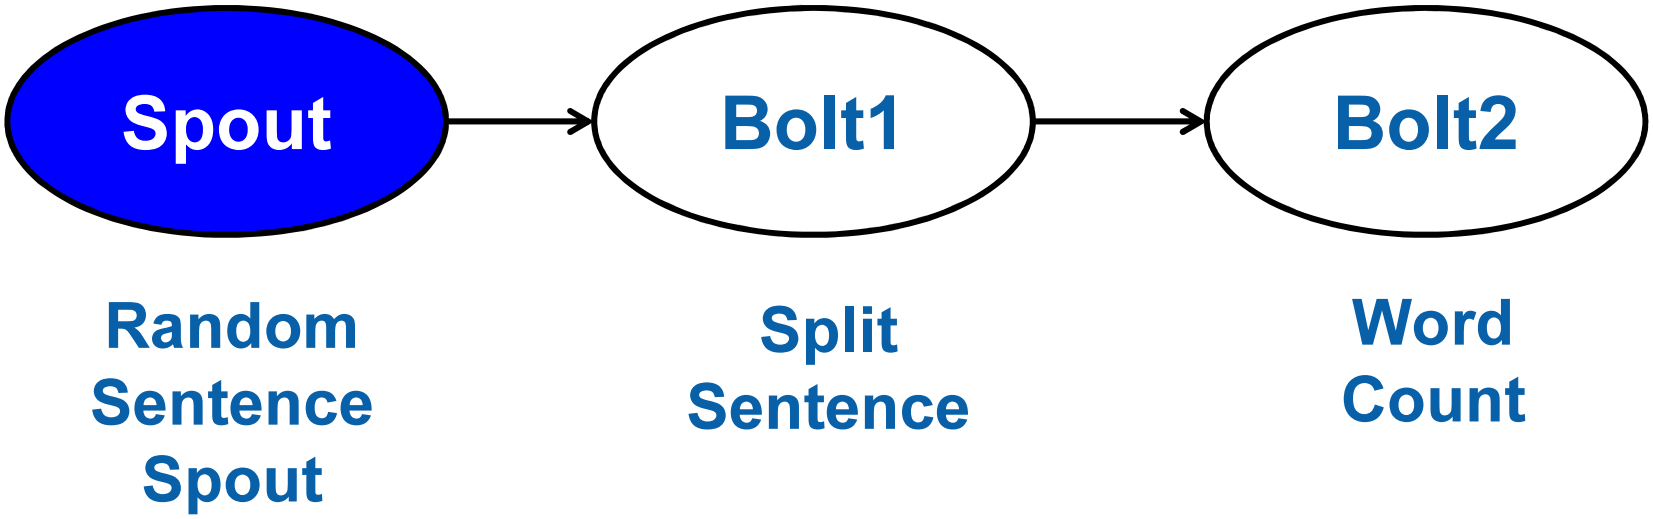

- Random Sentence Spout:
  每调用一次返回一个随机的句子

举例： RandomSentenceSpout

```
public class RandomSentenceSpout extends BaseRichSpout {
  SpoutOutputCollector _collector;
  Random _rand;

  @Override
  public void open(Map conf, TopologyContext context,
                   SpoutOutputCollector collector) {
    _collector = collector;
    _rand = new Random();
  }
  @Override
  public void nextTuple() {
    Utils.sleep(100);
    String[] sentences = new String[]{ "the cow jumped over the moon",
        "four score and seven years ago", "snow white and the seven dwarfs"};
    String sentence = sentences[_rand.nextInt(sentences.length)];
    _collector.emit(new Values(sentence));
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word"));
  }
}
```

实现一个
BaseRichSpout的子类

例子来源： Storm Example Code

举例： RandomSentenceSpout

```
public class RandomSentenceSpout extends BaseRichSpout {
  SpoutOutputCollector _collector;
  Random _rand;

  @Override
  public void open(Map conf, TopologyContext context,
                   SpoutOutputCollector collector) {
    _collector = collector;
    _rand = new Random();
  }
  @Override
  public void nextTuple() {
    Utils.sleep(100);
    String[] sentences = new String[]{ "the cow jumped over the moon",
        "four score and seven years ago", "snow white and the seven dwarfs"};
    String sentence = sentences[_rand.nextInt(sentences.length)];
    _collector.emit(new Values(sentence));
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word"));
  }
}
```

Open时初始化

举例： RandomSentenceSpout

```
public class RandomSentenceSpout extends BaseRichSpout {
  SpoutOutputCollector _collector;
  Random _rand;

  @Override
  public void open(Map conf, TopologyContext context,
                   SpoutOutputCollector collector) {
    _collector = collector;
    _rand = new Random();
  }
  @Override
  public void nextTuple() {
    Utils.sleep(100);
    String[] sentences = new String[]{ "the cow jumped over the moon",
        "four score and seven years ago", "snow white and the seven dwarfs"};
    String sentence = sentences[_rand.nextInt(sentences.length)];
    _collector.emit(new Values(sentence));
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word"));
  }
}
```

主要是实现nextTuple函数

举例：RandomSentenceSpout

```
public class RandomSentenceSpout extends BaseRichSpout {
  SpoutOutputCollector _collector;
  Random _rand;

  @Override
  public void open(Map conf, TopologyContext context,
                   SpoutOutputCollector collector) {
    _collector = collector;
    _rand = new Random();
  }
  @Override
  public void nextTuple() {
    Utils.sleep(100);
    String[] sentences = new String[]{ "the cow jumped over the moon",
        "four score and seven years ago", "snow white and the seven dwarfs"};
    String sentence = sentences[_rand.nextInt(sentences.length)];
    _collector.emit(new Values(sentence));
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word"));
  }
}
```

使用emit向Storm发出一个数据tuple

举例： RandomSentenceSpout

```
public class RandomSentenceSpout extends BaseRichSpout {
  SpoutOutputCollector _collector;
  Random _rand;

  @Override
  public void open(Map conf, TopologyContext context,
                   SpoutOutputCollector collector) {
    _collector = collector;
    _rand = new Random();
  }
  @Override
  public void nextTuple() {
    Utils.sleep(100);
    String[] sentences = new String[]{ "the cow jumped over the moon",
        "four score and seven years ago", "snow white and the seven dwarfs"};
    String sentence = sentences[_rand.nextInt(sentences.length)];
    _collector.emit(new Values(sentence));
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word"));
  }
}
```

定义输出tuple各属性的名字

举例:一个简单的Topology

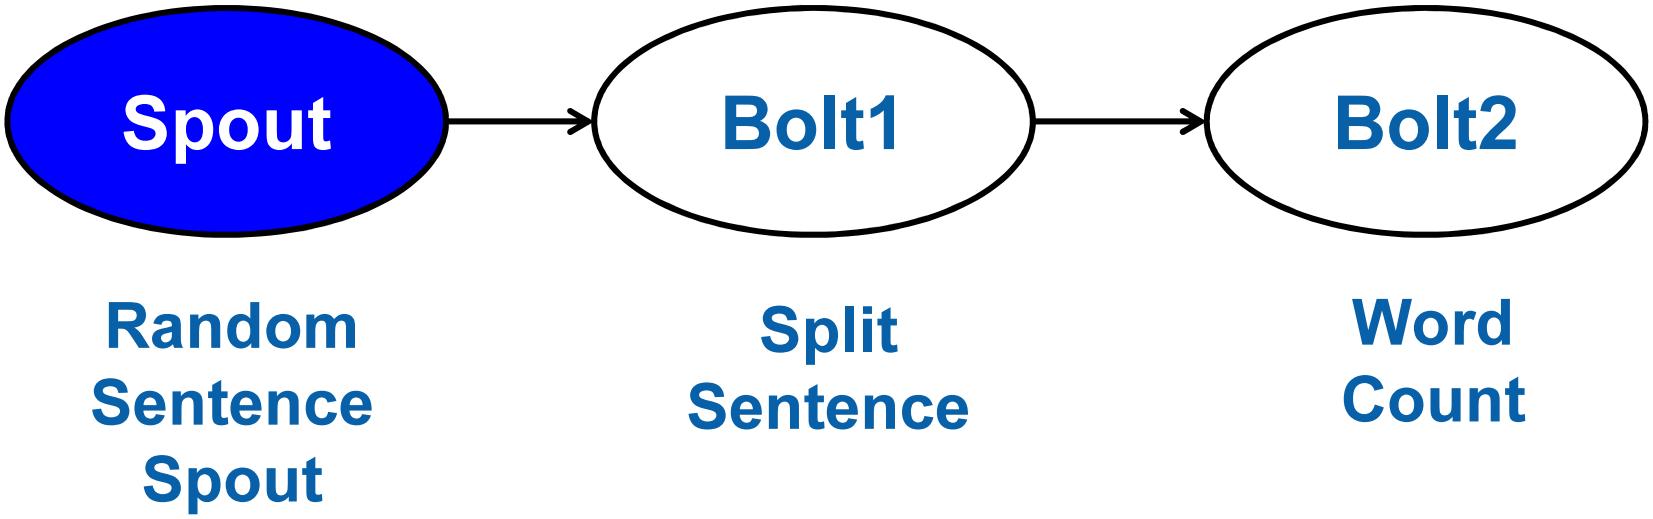

- Random Sentence Spout:
  每调用一次返回一个随机的句子
- 实际使用时，Spout通常是获得外部数据，emit
  - 例如：微博的推送

举例:一个简单的Topology

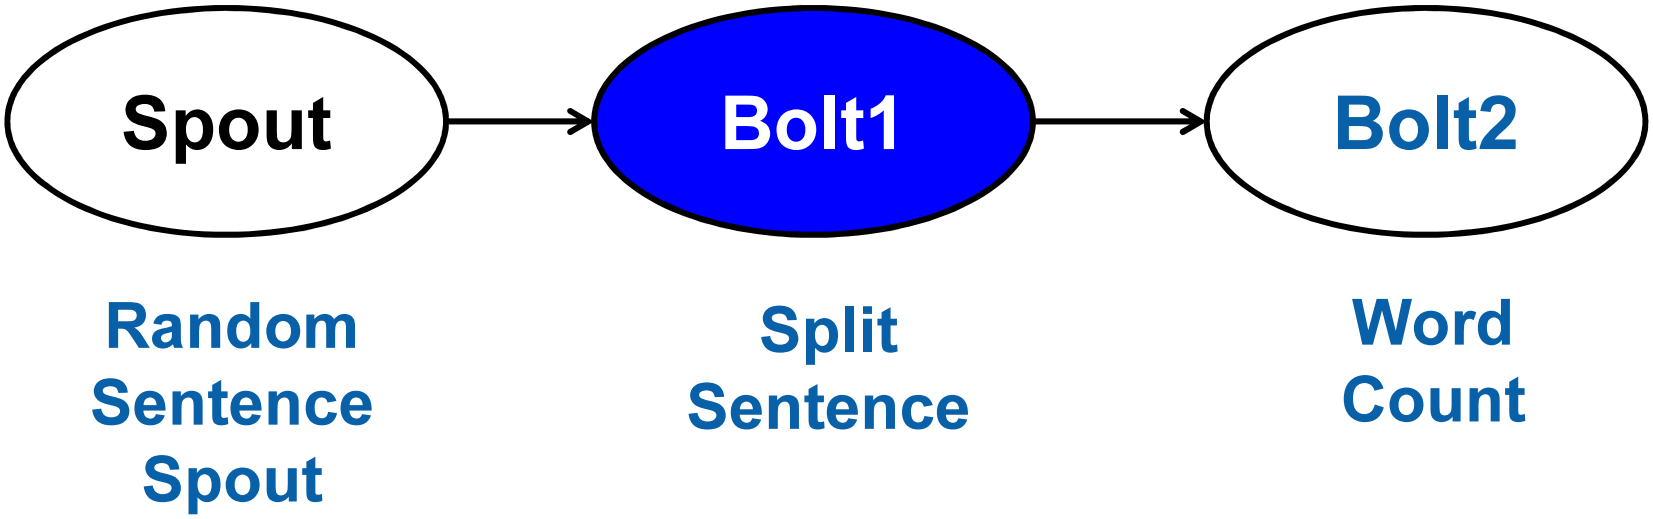

- Split Sentence：把句子分成单词

举例：SplitSentence

```
public static class SplitSentence extends BaseBasicBolt {
  @Override
  public void execute(Tuple tuple, BasicOutputCol
    String sentence= tuple.getString(0);
    StringTokenizer itr = new StringTokenizer(sentence);
    while (itr.hasMoreTokens()) {
      collector.emit(new Values(itr.nextToken()));
    }
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word"));
  }
}
```

实现一个BaseBasicBolt的子类

举例：SplitSentence

主要实现execute函数，每一个输入tuple被调用一次，用emit发出输出的tuple

```
public static class SplitSentence extend
  @Override
  public void execute(Tuple tuple, BasicOutputCollector collector) {
    String sentence= tuple.getString(0);
    StringTokenizer itr = new StringTokenizer(sentence);
    while (itr.hasMoreTokens()) {
      collector.emit(new Values(itr.nextToken()));
    }
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word"));
  }
}
```

举例：SplitSentence

```
public static class SplitSentence extends BaseBasicBolt {
  @Override
  public void execute(Tuple tuple, BasicOutputCollector collector) {
    String sentence= tuple.getString(0);
    StringTokenizer itr = new StringTokenizer(sentence);
    while (itr.hasMoreTokens()) {
      collector.emit(new Values(itr.nextToken()));
    }
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word"));
  }
}
```

定义输出tuple的属性的名字

举例:一个简单的Topology

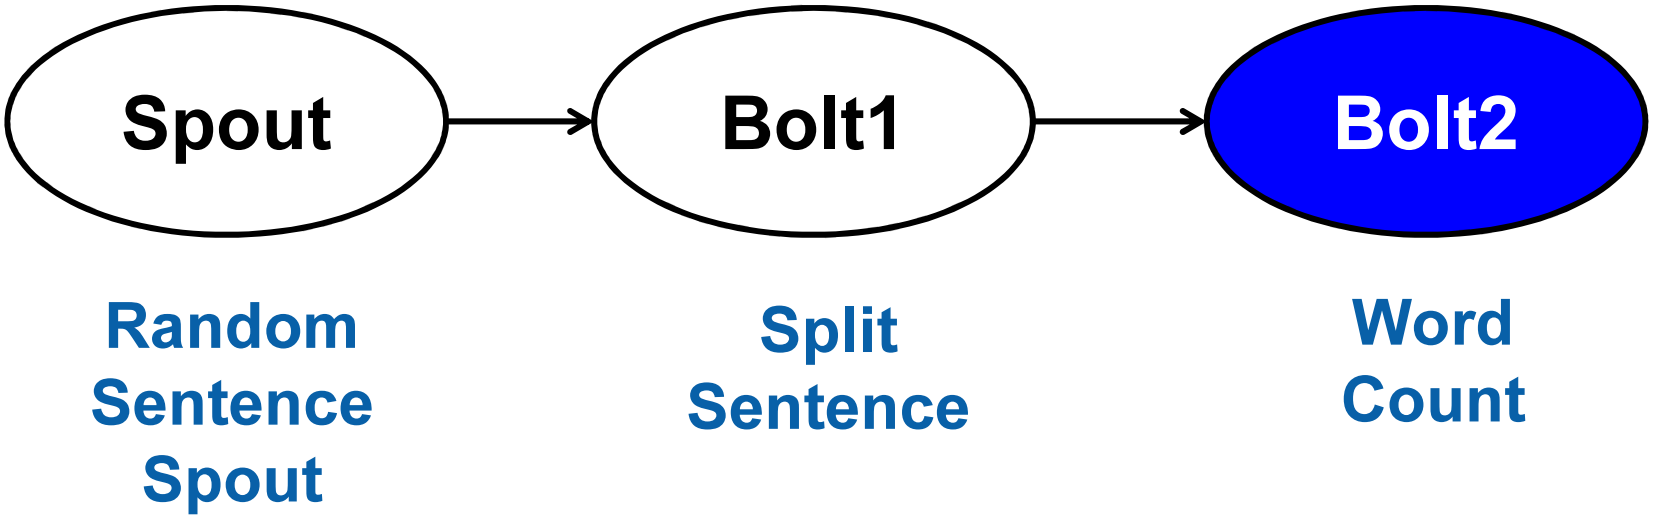

- Word Count：单词计数

举例：WordCount

BaseBasicBolt的子类

```
public static class WordCount extends BaseBasicBolt {
  Map<String, Integer> counts = new HashMap<String, Integer>();

  @Override
  public void execute(Tuple tuple, BasicOutputCollector collector) {
    String word = tuple.getString(0);
    Integer count = counts.get(word);
    if (count == null) count = 0;
    count++;
    counts.put(word, count);
    collector.emit(new Values(word, count));
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word", "count"));
  }
}
```

举例：WordCount

每个输入Tuple是一个word，在HashMap中计数，输出当前计数

```
public static class WordCount extends BaseBa
  Map<String, Integer> counts = new HashMap<

  @Override
  public void execute(Tuple tuple, BasicOutputCollector collector) {
    String word = tuple.getString(0);
    Integer count = counts.get(word);
    if (count == null) count = 0;
    count++;
    counts.put(word, count);
    collector.emit(new Values(word, count));
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word", "count"));
  }
}
```

举例：WordCount

```
public static class WordCount extends BaseBasicBolt {
  Map<String, Integer> counts = new HashMap<String, Integer>();

  @Override
  public void execute(Tuple tuple, BasicOutputCollector collector) {
    String word = tuple.getString(0);
    Integer count = counts.get(word);
    if (count == null) count = 0;
    count++;
    counts.put(word, count);
    collector.emit(new Values(word, count));
  }
  @Override
  public void declareOutputFields(OutputFieldsDeclarer declarer) {
    declarer.declare(new Fields("word", "count"));
  }
}
```

定义输出tuple的属性的名字

举例：主程序

```
public static void main(String[] args) throws Exception {

  TopologyBuilder builder = new TopologyBuilder();

  builder.setSpout("spout", new RandomSentenceSpout(), 5);
  builder.setBolt("split", new SplitSentence(), 8)
         .shuffleGrouping("spout");
  builder.setBolt("count", new WordCount(), 12)
         .fieldsGrouping("split", new Fields("word"));

  Config conf = new Config();
  conf.setMaxTaskParallelism(3);

  LocalCluster cluster = new LocalCluster();
  cluster.submitTopology("word-count", conf, builder.createTopology());
  Thread.sleep(10000);
  cluster.shutdown();
}
```

建立 Topology

运行

举例：主程序

```
public static void main(String[] args) throws Exception {

  TopologyBuilder builder = new TopologyBuilde

  builder.setSpout("spout", new RandomSentenceSpout(), 5);
  builder.setBolt("split", new SplitSentence(), 8)
         .shuffleGrouping("spout");
  builder.setBolt("count", new WordCount(), 12)
         .fieldsGrouping("split", new Fields("word"));

  Config conf = new Config();
  conf.setMaxTaskParallelism(3);

  LocalCluster cluster = new LocalCluster();
  cluster.submitTopology("word-count", conf, builder.createTopology());
  Thread.sleep(10000);
  cluster.shutdown();
}
```

创建Spout, 并行度为5

举例：主程序

```
public static void main(String[] args) throws Exception {

  TopologyBuilder builder = new TopologyBuild

  builder.setSpout("spout", new RandomSentenc
  builder.setBolt("split", new SplitSentence(), 8)
         .shuffleGrouping("spout");
  builder.setBolt("count", new WordCount(), 12)
         .fieldsGrouping("split", new Fields("word"));

  Config conf = new Config();
  conf.setMaxTaskParallelism(3);

  LocalCluster cluster = new LocalCluster();
  cluster.submitTopology("word-count", conf, builder.createTopology());
  Thread.sleep(10000);
  cluster.shutdown();
}
```

创建Bolt1, 并行度为8, 连接spout输出

举例：主程序

```
public static void main(String[] args) throws Exception {

  TopologyBuilder builder = new TopologyBuilder();

  builder.setSpout("spout", new RandomSentenc
  builder.setBolt("split", new SplitSentence(
         .shuffleGrouping("spout");
  builder.setBolt("count", new WordCount(), 12)
         .fieldsGrouping("split", new Fields("word"));

  Config conf = new Config();
  conf.setMaxTaskParallelism(3);

  LocalCluster cluster = new LocalCluster();
  cluster.submitTopology("word-count", conf, builder.createTopology());
  Thread.sleep(10000);
  cluster.shutdown();
}
```

创建Bolt2, 并行度为12, 连接Bolt1输出

Stream Grouping

- 上游节点的输出如何分发到下游顶点？
  - 下游顶点有多个运行的实例
  - 上游产生的一条tuple，应该发给哪个下游实例？

- Shuffle grouping: 随机
  - 随机发送给下游实例
- Fields grouping：group-by shuffle
  - 根据tuple中指定域的取值
  - 相同取值的tuple发给固定的下游实例

- 其它种类

Storm 系统结构

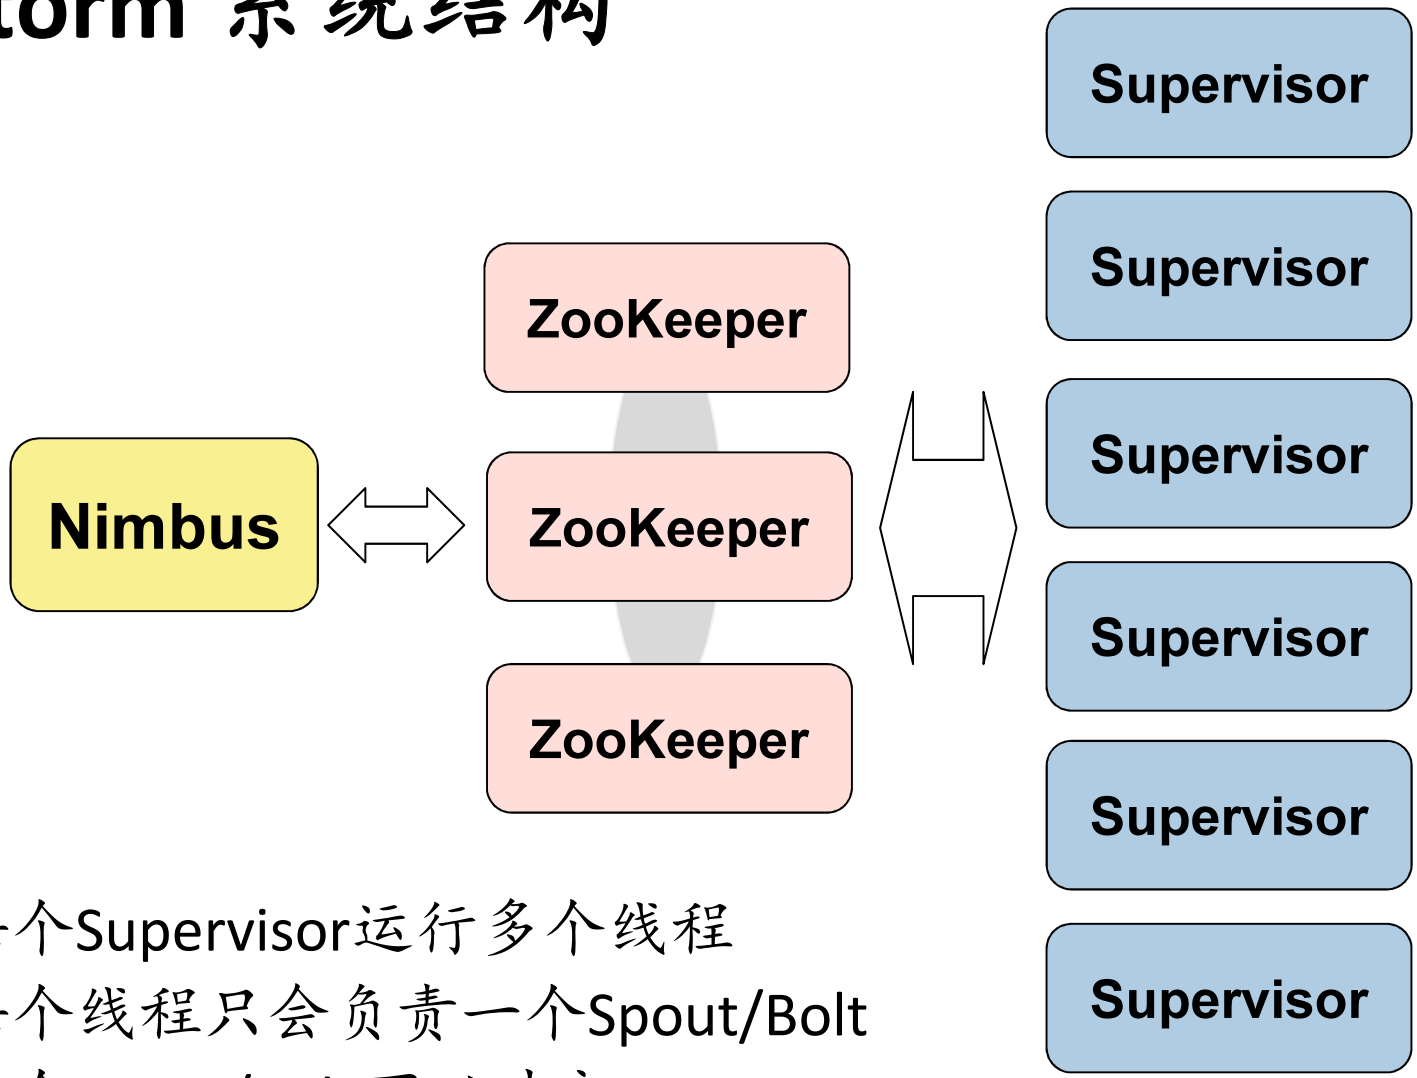

- 每个Supervisor运行多个线程
- 每个线程只会负责一个Spout/Bolt
- 一个Spout/Bolt可以对应
  多个Supervisor和多个线程

Outline

- 图计算系统
  - GraphLab
  - PowerGraph
- 数据流系统Storm
- MapReduce + SQL系统： Hive
- 内存计算
  - 内存数据库
  - 内存键值系统

MapReduce+SQL系统介绍

- MapReduce提供了一个分布式应用编写的平台
  - 程序员开发串行的Map和Reduce函数
  - 在串行的环境开发和调试
  - MapReduce系统可以在成百上千个机器节点上并发执行MapReduce程序，从而实现对大规模数据的处理
- MapReduce的问题
  - 这是一个编程的平台
  - 不太适合数据分析师的使用
  - 即使最基础的选择和投影操作，也必须写程序实现
- 对SQL的需求由此产生

MapReduce+SQL系统介绍

- 产业界研发了许多系统，希望在云平台上增加一层类似SQL的支持
- 这类系统包括
  - Facebook Hive
  - Yahoo Pig
  - Microsoft Scope
  - Google Sawzall
  - IBM Research JAQL
- 一些数据仓库产品也把云计算的能力集成进Execution engine
  - Greenplum, Aster Data, Oracle
  - 基于内部的某种MapReduce实现或者Hadoop
- Hive不是最早出现的，也不是最具创新性的，但是目前它被非常广泛地使用，我们主要介绍Hive

Hive

- Hive是蜂巢
- 简要发展
  - 2008年，Facebook由于数据分析的需求研发了Hive
  - Facebook公开了Hive的源码，Hive成为Apache开源项目
  - 2008年3月，Facebook每天把200GB数据存入Hive系统
  - 2012年，每日存入的数据量超过了15TB
- Hive
  - 管理和处理结构化数据
  - 在Hadoop基础上实现
  - 提供类似SQL的HiveQL语言

Hive系统

Adapted from Hive ApacheCon'08 talk

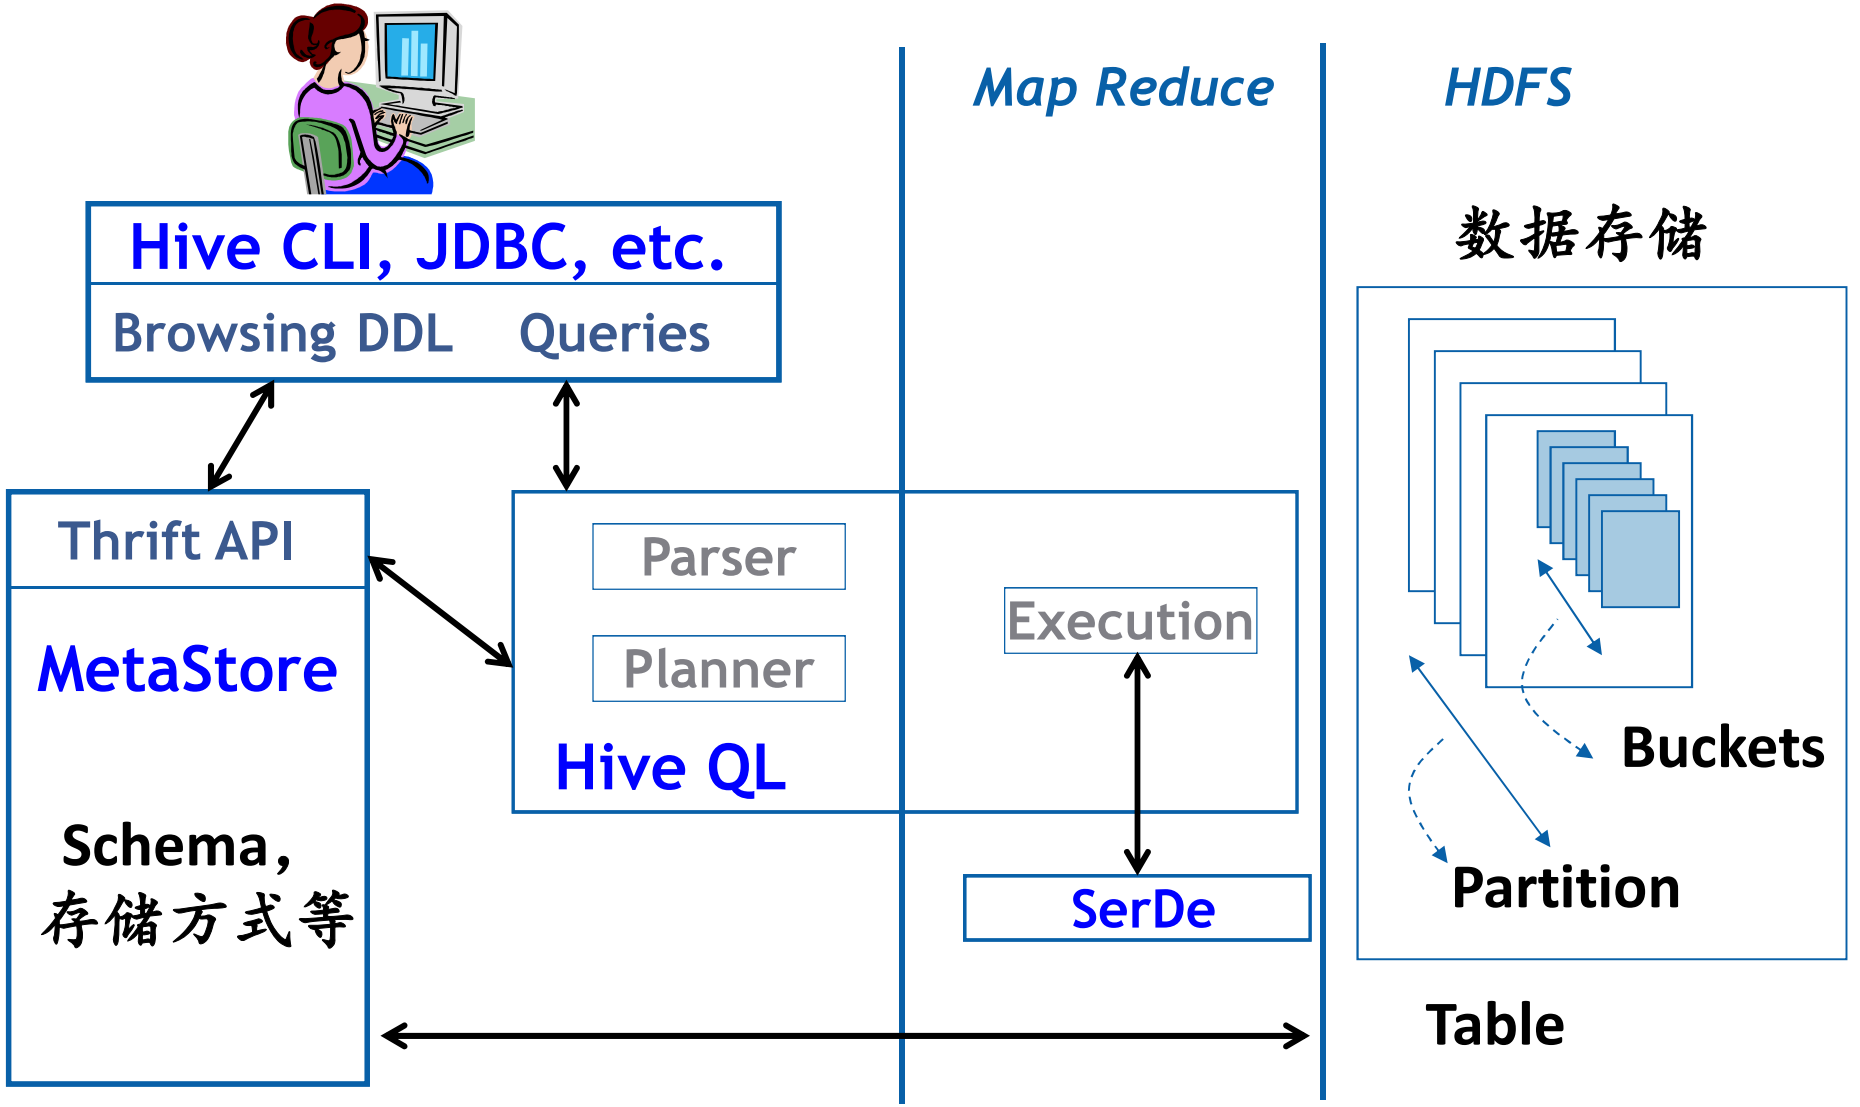

Hive系统

Adapted from Hive ApacheCon'08 talk

Hive CLI, JDBC, etc.

Browsing DDL Queries

Thrift API

MetaStore

Schema,
存储方式等

Map Reduce

HDFS

数据存储

- MetaStore
  - 存储表的定义信息等
  - 默认在本地${HIVE_HOME}/metastore_db中
  - 也可以配置存储在数据库RDBMS系统中
- Hive CLI
  - 命令行客户端，可以执行各种HiveQL命令

Hive系统

Adapted from Hive ApacheCon'08 talk

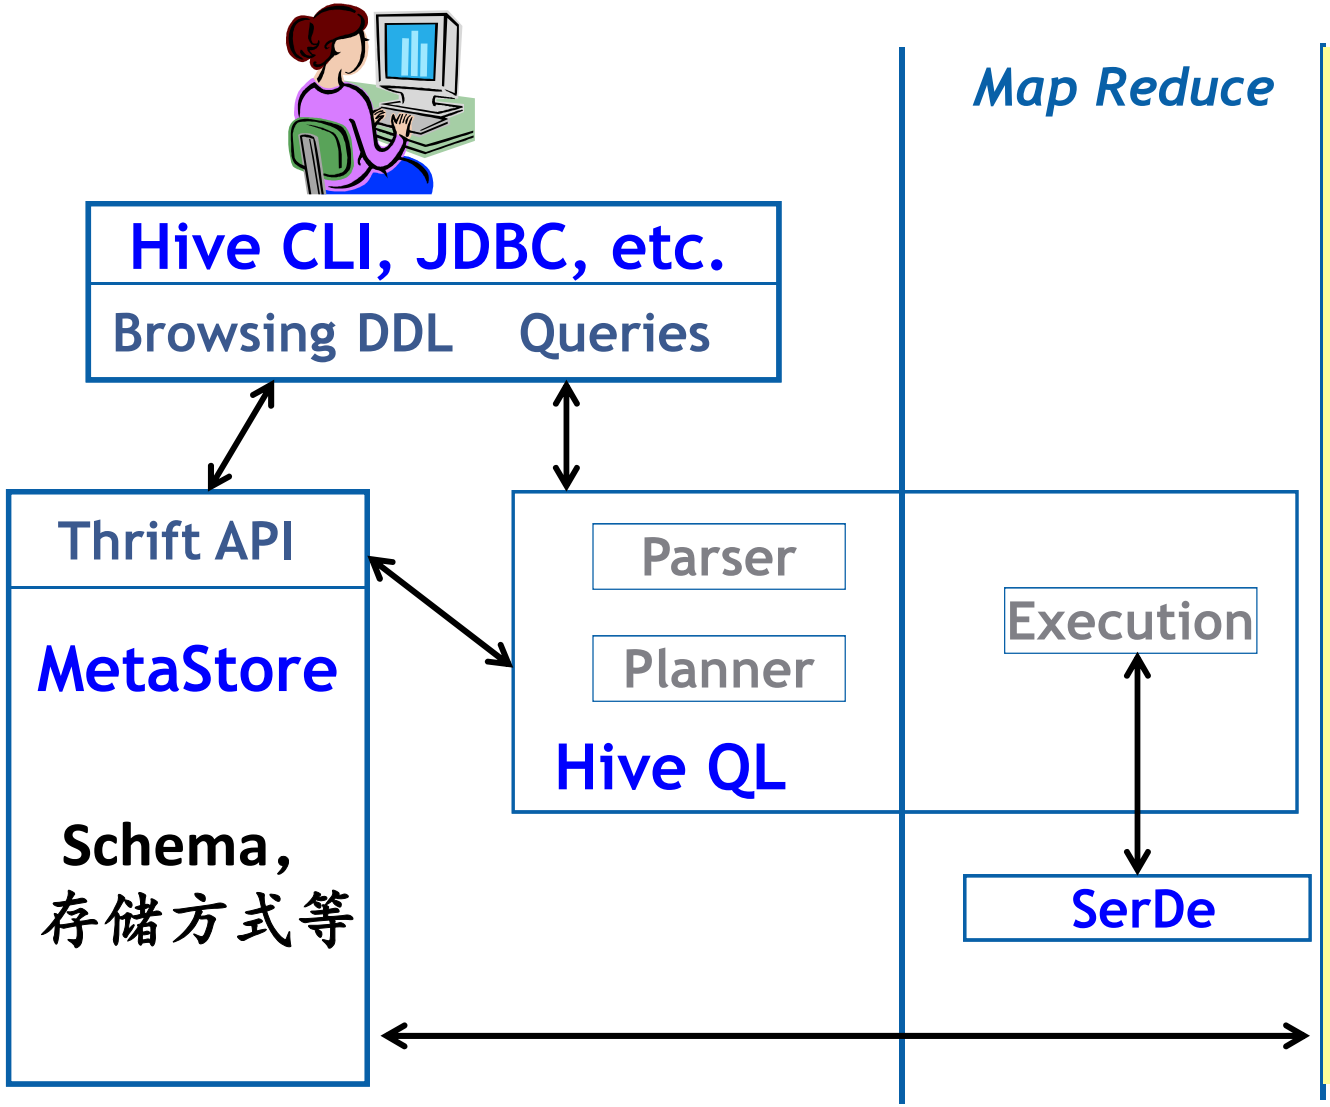

- Hive QL
  - 类似SQL
  - 部分SQL和扩展
  - 采用MapReduce执行
- SerDe
  - 序列化/反序列化

Hive系统

Adapted from Hive ApacheCon'08 talk

Map Reduce | *HDFS*

- 数据存储在HDFS上
  - hdfs目录：/usr/hive/warehouse/
- Table： 一个单独的hdfs目录
  - /user/hive/warehouse/表名
- Table可以进一步划分为Partition
- Partition可以进一步划分为Bucket

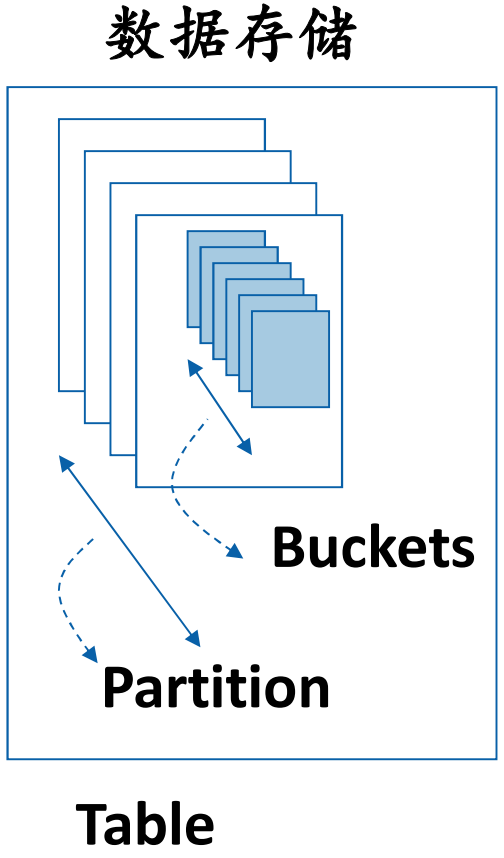

Hive系统

Adapted from Hive ApacheCon'08 talk

Map Reduce | *HDFS*

- Partition：每个Partition是Table目录下的子目录
  - 假设pkey是partition key：
    /user/hive/warehouse/表名/pkey=value
- Bucket：每个Bucket是Partition目录下一个子目录
  - 假设pkey是partition key, bkey是bucket key：
    /user/hive/warehouse/表名
    /pkey=value/bkey=value

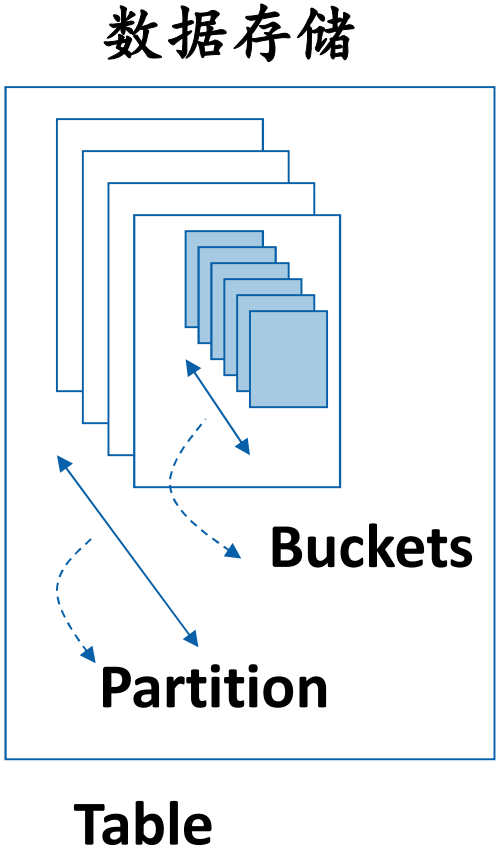

举例

```
CREATE TABLE status_updates(
          userid int,
          status string
)

STORED AS SEQUENCEFILE;
```

存储在HDFS中
/user/hive/warehouse/status_update

Hive数据模型

- 关系型表+扩展
- 扩展1
  - 列可以是更加复杂的数据类型
  - ARRAY<data-type>
    - 例如：a ARRAY<int>: a[0], a[1], …
  - MAP<primitive-type, any-type>
    - 例如：m MAP<STRING, STRING>: m['key1'],…
  - STRUCT<col_name: data_type, …>
    - 例如：s STRUCT {c: INT, d: INT}： s.c, s.d

Hive数据模型

- 关系型表+扩展
- 扩展1

```
CREATE TABLE t1(
        st string,
        fl float,
        a  array<int>,
        m map<string, string>
        n array<map<string, struct<p1:int, p2:int>>
);
```

系统把复杂数据类型Serialize/deserialize (序列化/反序列化)
使用： t1.n[0]['key'].p2

Hive数据模型

- 关系型表+扩展
- 扩展2
  - 可以直接读取已有的外部数据
  - 程序员提供一个SerDe的实现
  - 只有在使用时，才转化读入

```
add jar /jars/myformat.jar;

CREATE TABLE t2
ROW FORMAT SERDE 'com.myformat.MySerDe';
```


Create/Alter/Drop Table

- 支持SQL的DDL (data definition language)
  - Create table
  - Alter table
  - Drop table

Insert

```
Insert into table status_updates values (123,
‘active’), (456, ‘inactive’), (789, ‘active’);

Insert into table status_updates
  select 语句

Insert overwrite table status_updates
  select 语句
```

注意：HDFS文件不支持修改

Insert into是文件append

Insert overwrite是删除然后新创建文件

举例

```
CREATE TABLE status_updates(
          userid int,
          status string
)
PARTITIONED BY (ds string, hr int)

STORED AS SEQUENCEFILE;
```

注意：ds是partition key, hr是bucket key
它们都不包括在table schema中

存储在HDFS中，例如
/user/hive/warehouse/status_update/ds=v1/hr=v2

Partition使用举例

```
INSERT OVERWRITE TABLE
status_updates PARTITION(ds='2009-01-01', hr=12)
SELECT * FROM t;
```

在如下的子目录中，存储select的输出
/user/hive/warehouse/status_updates/ds=2009-01-01/hr=12

划分是手工进行的！

```
SELECT * FROM status_updates WHERE ds='2009-01-01';
```

ds是partition key， 所以Hive只使用对应的子目录中的数据

Example Query (Aggregation)

```
SELECT COUNT(1)
FROM status_updates
WHERE ds = '2009-08-01'
```

```
status_updates (
        userid int,
        status string
 )
Partition key: ds
```

Hive ICDE'10 talk

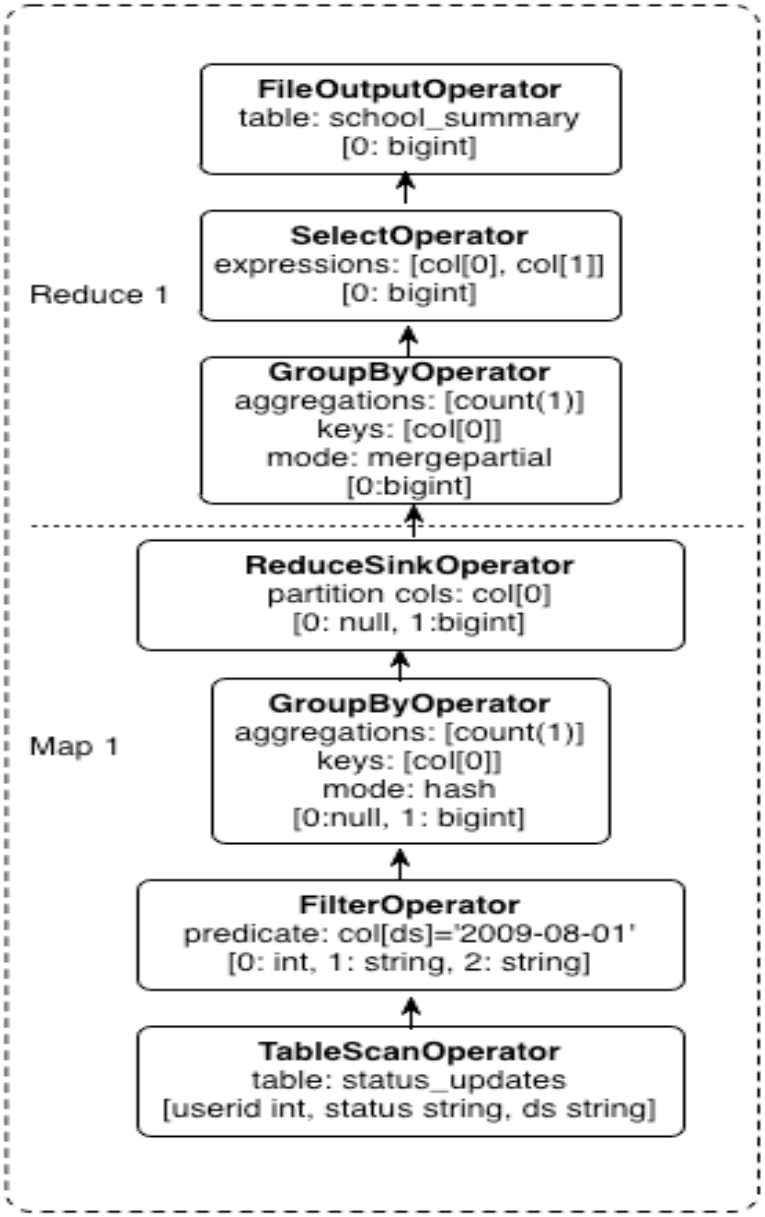

Hive系统

Adapted from Hive ApacheCon'08 talk

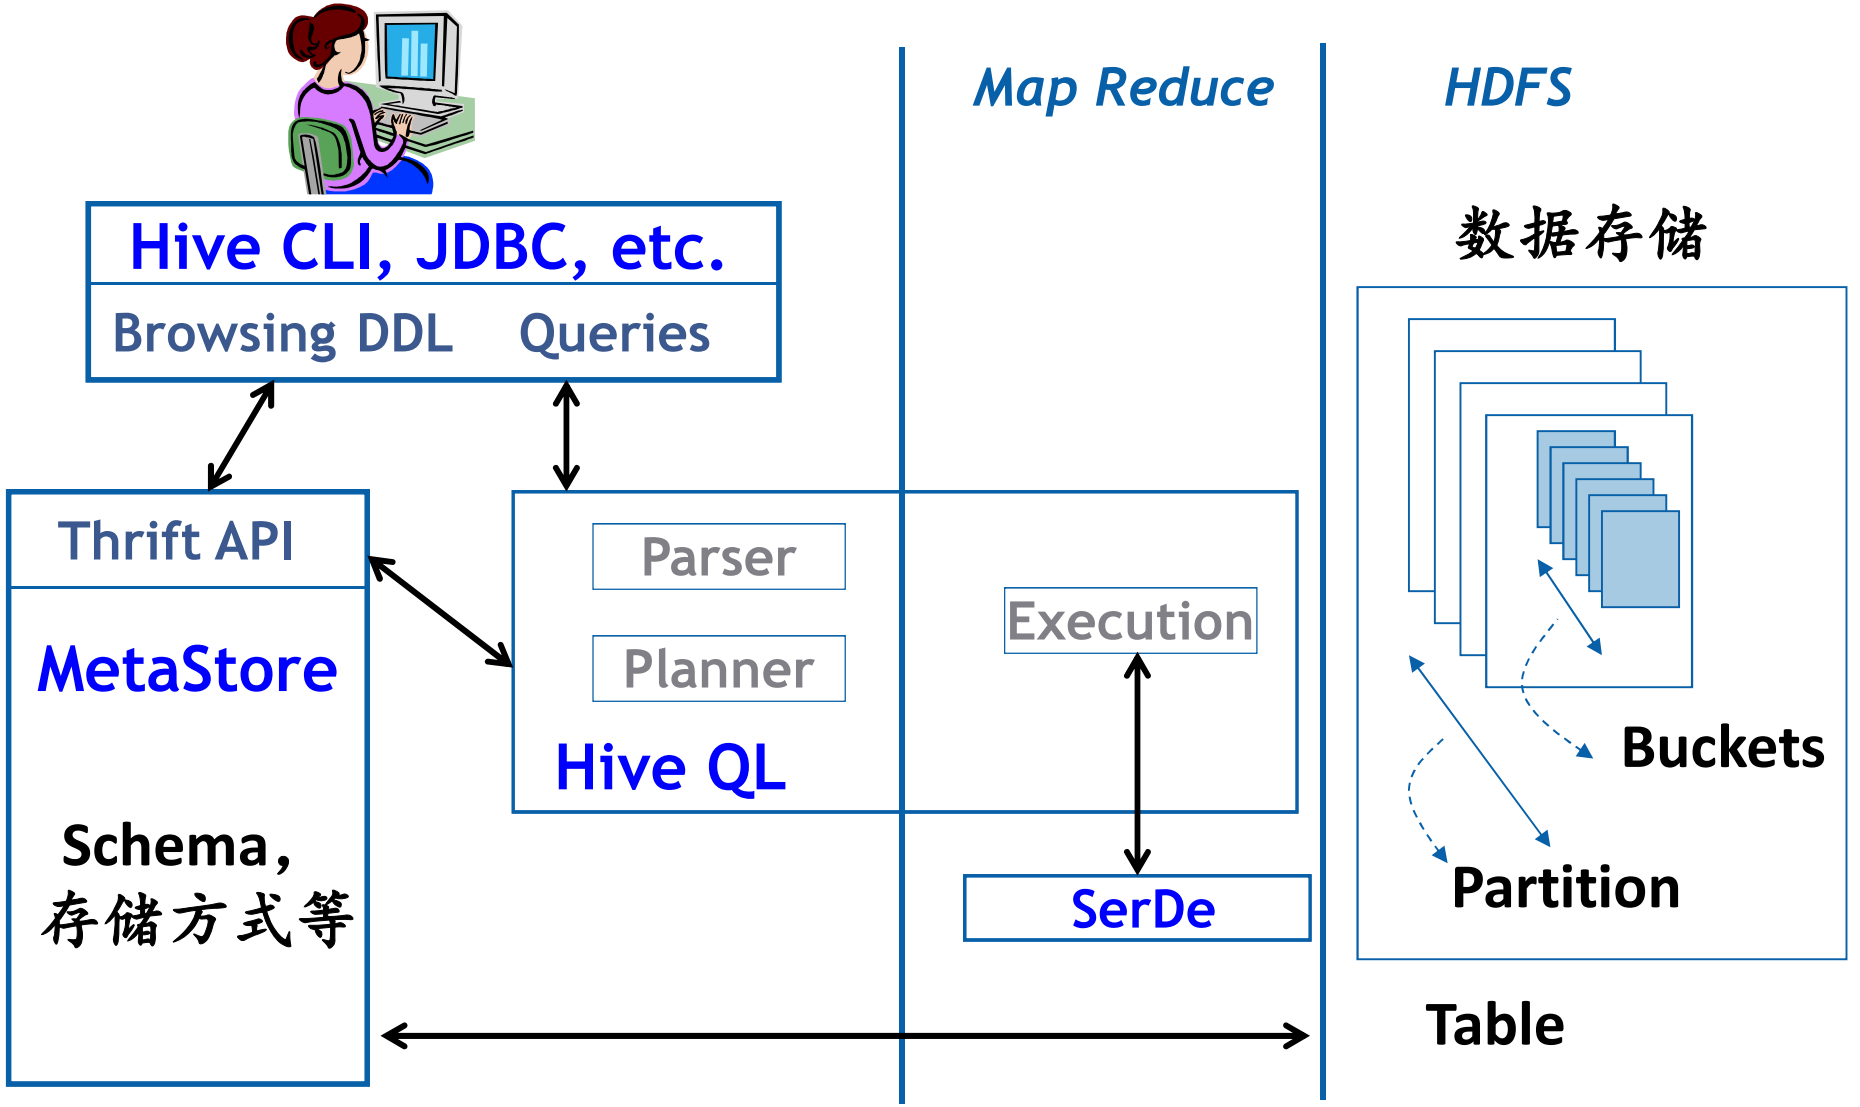

Hive & Hadoop Usage @ Facebook

Hive ICDE'10 talk

- Hive simplifies Hadoop
  - New engineers go though a Hive training session
  - ~200 people/month run jobs on Hadoop/Hive
  - Analysts (non-engineers) use Hadoop through Hive
  - 95% of hadoop jobs are Hive Jobs
- Types of Applications
  - Reporting
    - Eg: Daily/Weekly aggregations of impression/click counts
  - Ad hoc Analysis
    - Eg: how many group admins broken down by state/country
  - Machine Learning (Assembling training data)
    - Ad Optimization, Eg: User Engagement as a function of user attributes
  - Many others

Outline

- 图计算系统
  - GraphLab
  - PowerGraph
- 数据流系统Storm
- MapReduce + SQL系统
- 内存计算
  - 内存数据库
  - 内存键值系统

内存处理

- 随着内存容量的指数级增加
  - 越来越大的数据集可以完全存放在内存中
  - 或者完全存放在一个机群的总和的内存中
  - 例如，每台服务器64GB，一组刀片16台，就是1TB
  - 1TB对于很多重要的热点的数据可能已经足够了

- 内存处理的优点
  - 去除了硬盘读写的开销
  - 于是提高了处理速度

关系型内存数据库

- 最早的提法出现在1980，1990初
- 第一代MMDB出现于1990初
  - 没有高速缓存的概念
  - 例如：TimesTen
- 第二代MMDB出现于1990末，2000初
  - 对于新的硬件进行优化
  - 主要是学术领域提出的
  - 例如：MonetDB
  - 这一时期，产业界也开始重视MMDB，但主要是用来作前端的关系型cache
- 近年来，主流数据库公司纷纷投入研发MMDB
  - IBM Blink, Microsoft Hekaton & Apollo, SAP HANA, IBM BLU, 等

主要挑战

- 内存墙问题
  - 内存访问需要100~1000 cycles
  - 思路1：减少cache miss
    - 调整数据结构或算法
  - 思路2：降低cache miss对性能的影响
    - Software prefetch 预取指令
- 多核数据共享开销
  - 私有数据结构
  - 高效的并发控制方法
- 新的硬件特性
  - NVM, GPU, FPGA, NUMA等

MonetDB

- MonetDB
  - 荷兰CWI研究所研制
  - 1999年数据库领域第一篇关于cache performance的文章
  - 成熟的内存数据仓库,支持几乎所有的SQL
  - 内存列式存储,数据在类似数组的结构中

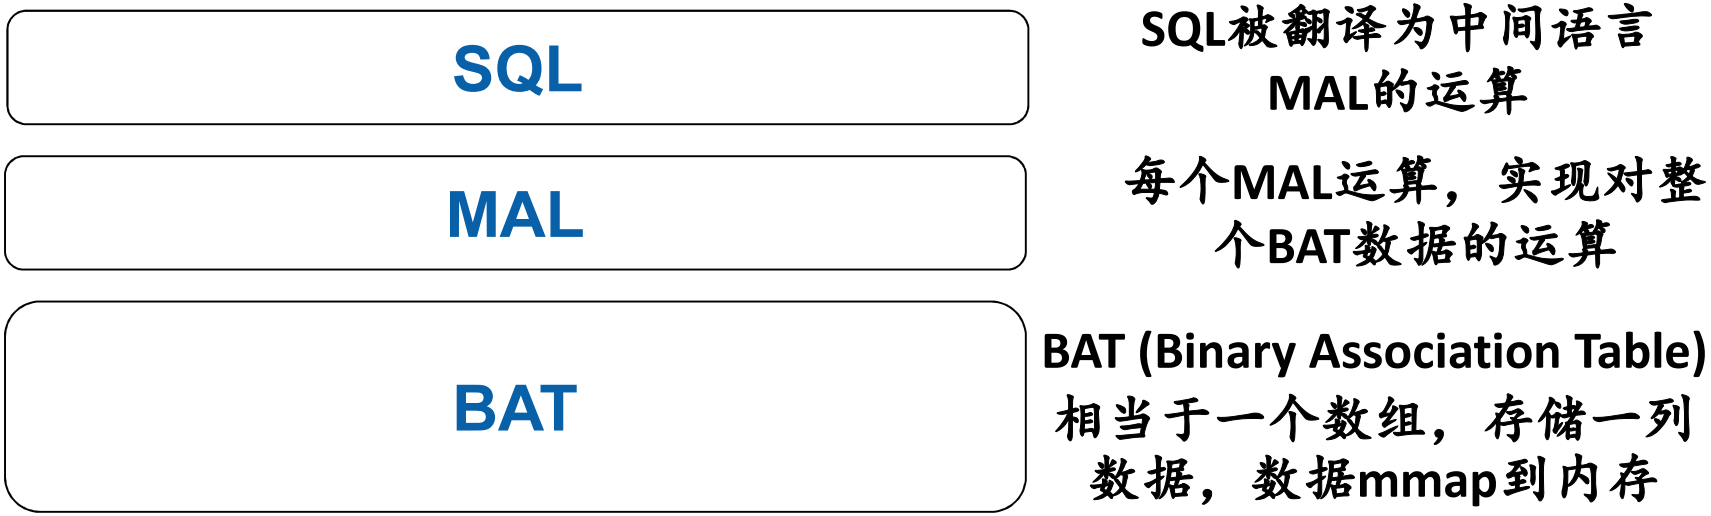

SAP HANA

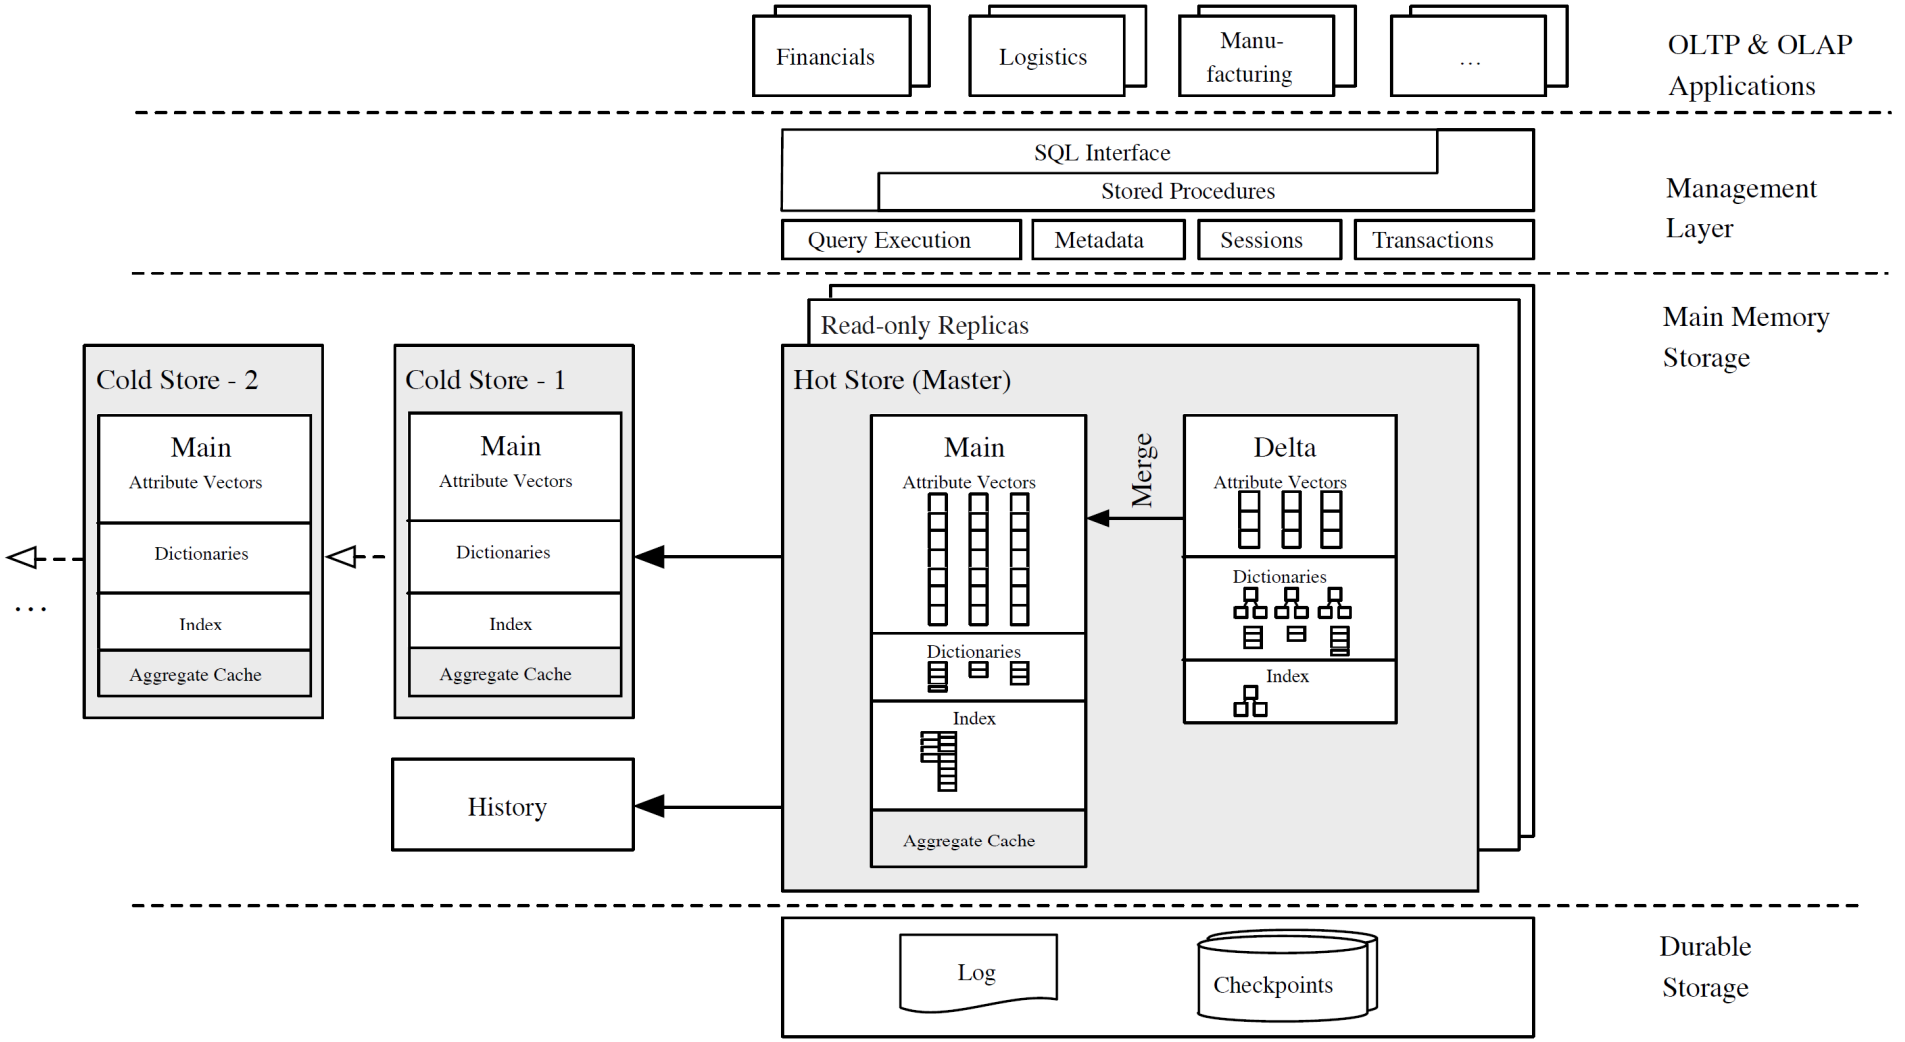

SAP HANA

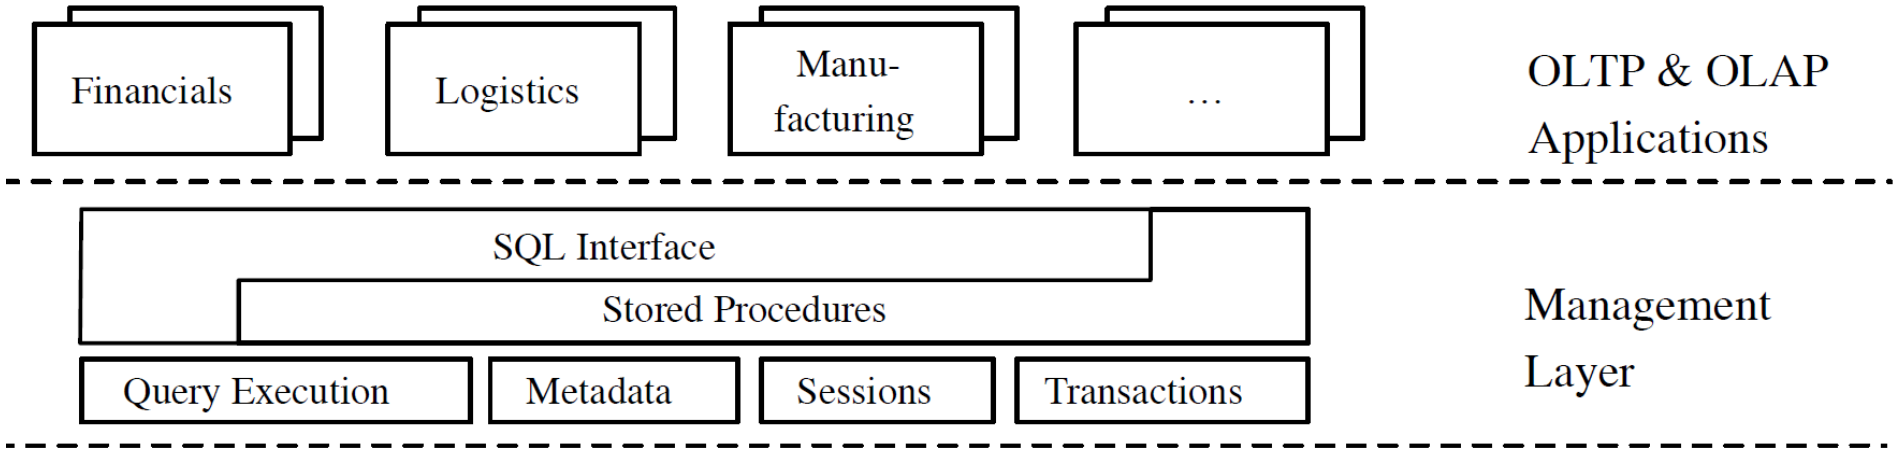

- 前端与普通数据库很相似

SAP HANA

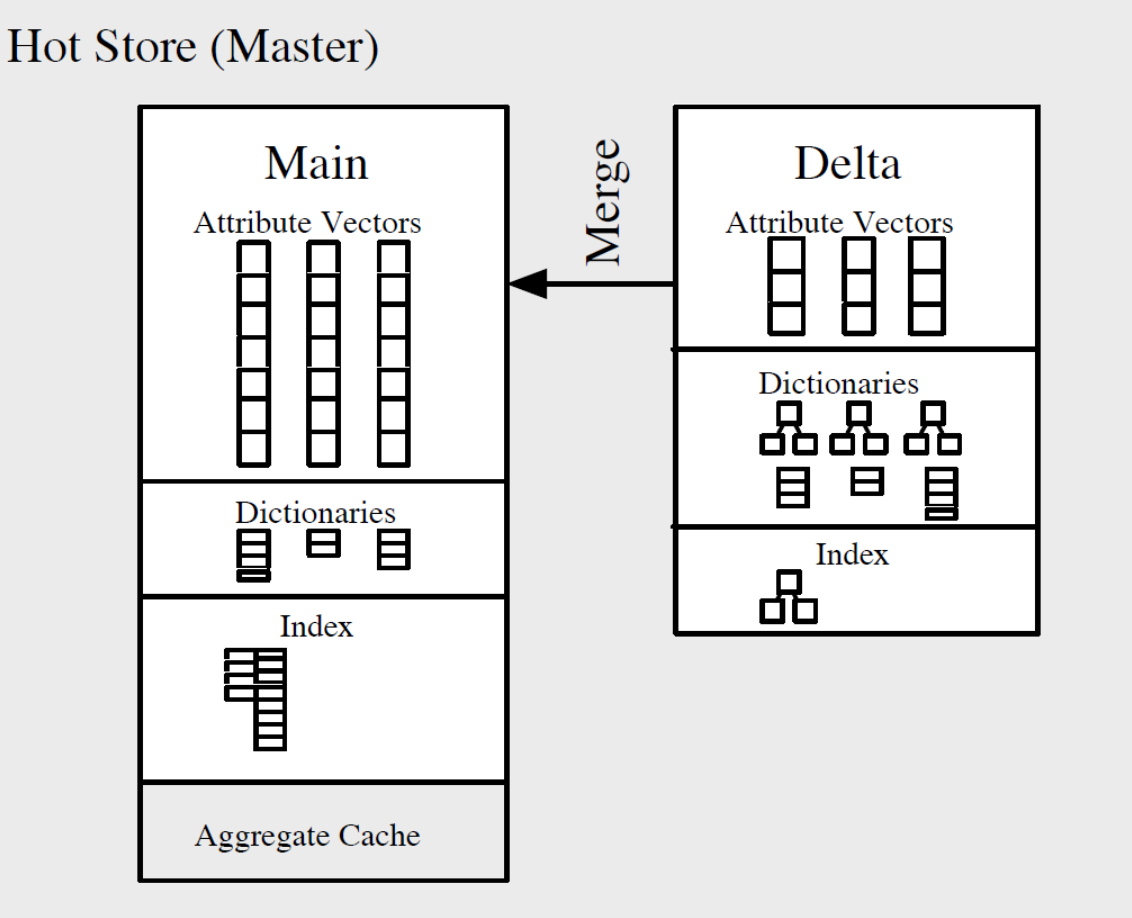

- Main data
- Delta data
  - 新的数据
  - Updates
- Dictionary 压缩
- 轻量index

SAP HANA

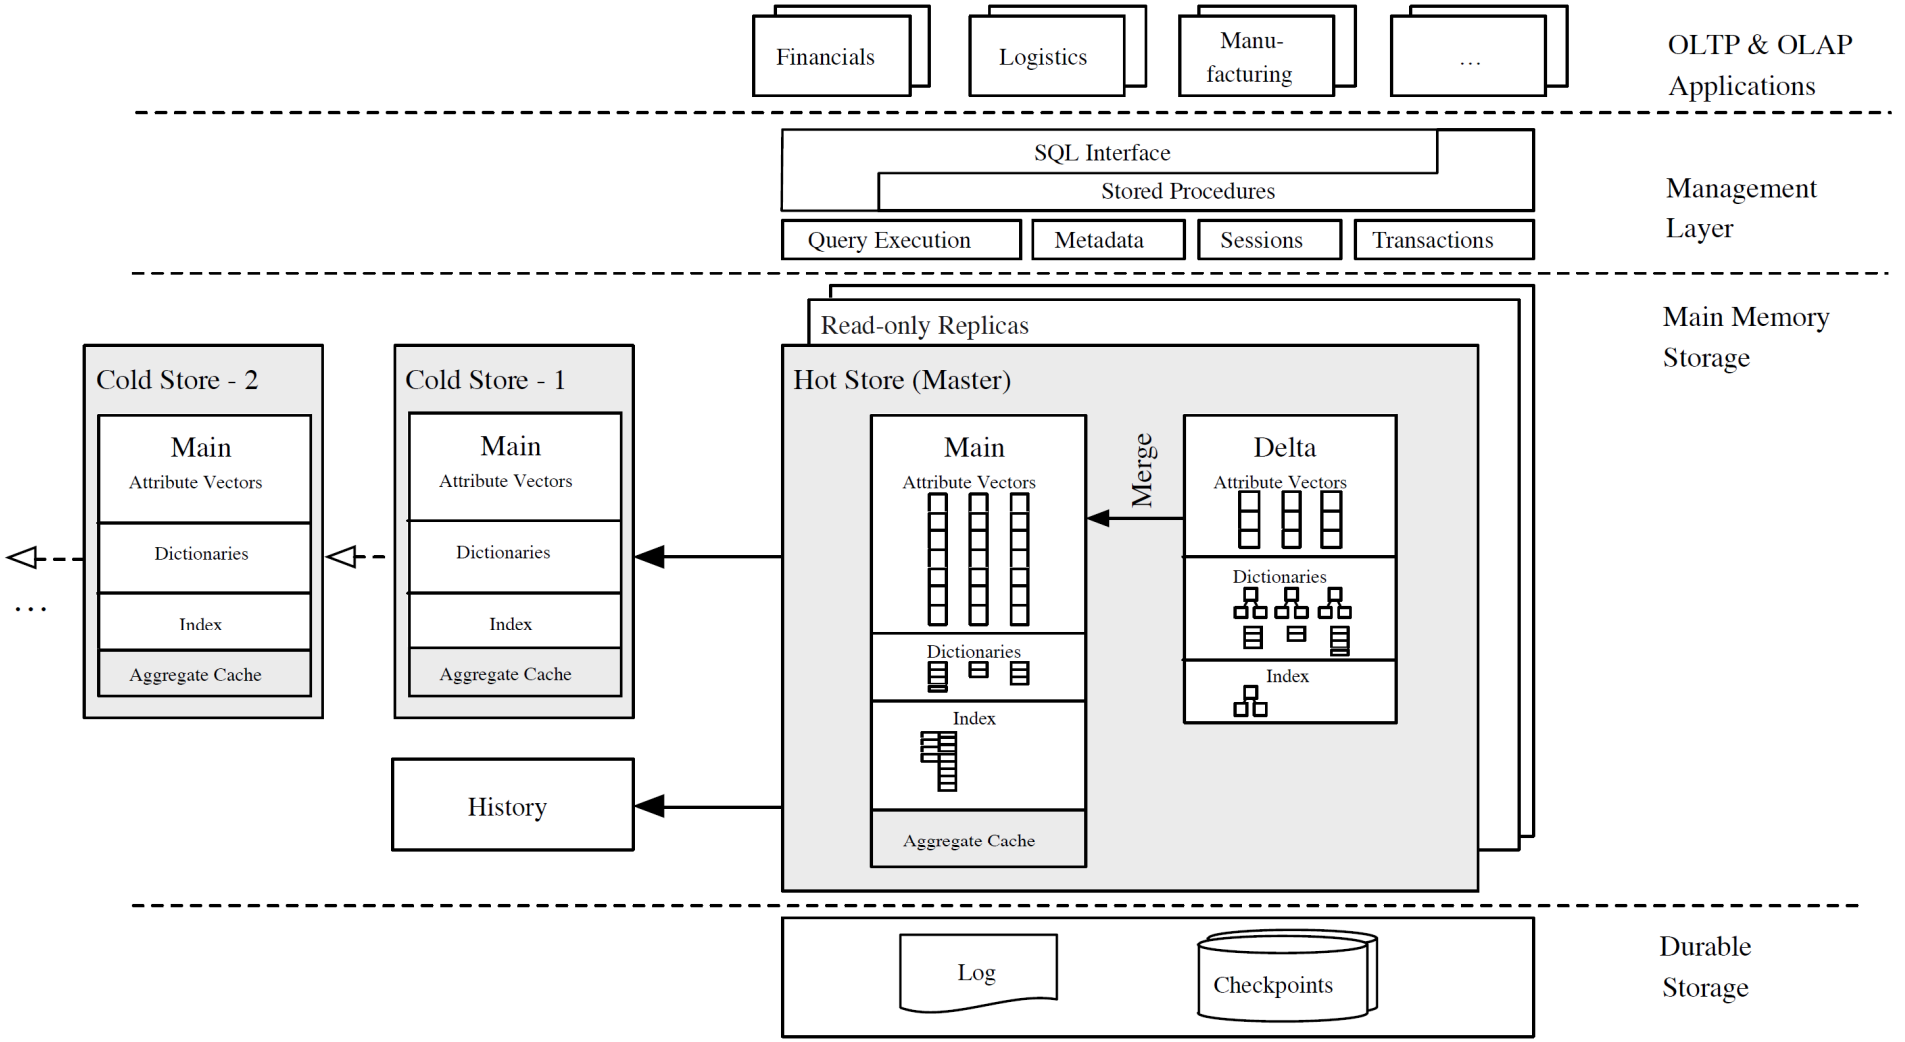
Financials
Logistics
Manu-facturing
…
OLTP & OLAP Applications
SQL Interface
Stored Procedures
Query Execution
Metadata
Sessions
Transactions
Management Layer
Read-only Replicas
Hot Store (Master)
Main
Attribute Vectors
Dictionaries
Index
Aggregate Cache
Merge
Delta
Attribute Vectors
Dictionaries
Index
Cold Store - 2
Main
Attribute Vectors
Dictionaries
Index
Aggregate Cache
Cold Store - 1
Main
Attribute Vectors
Dictionaries
Index
Aggregate Cache
History
Main Memory Storage
Log
Checkpoints
Durable Storage

其它主流数据库产品

- Microsoft
  - Hekaton：OLTP
  - Apollo：OLAP
- IBM
  - Blink：IBM的数据仓库加速系统
  - BLU：列式数据库engine, 有硬盘存储，使用了许多内存处理技术
- Oracle
  - In-memory data analytics caching

Outline

- 图计算系统
  - GraphLab
  - PowerGraph
- 数据流系统Storm
- MapReduce + SQL系统
- 内存计算
  - 内存数据库
  - 内存键值系统

内存key-value系统

- Memcached
  - 用户： Facebook, twitter, flickr, youtube, …
  - 单机内存键值对系统
  - 数据在内存中以hash table的形式存储
  - 支持最基础的<key, value>数据模型
  - 通常被用于前端的cache
  - 可以使用多个memcached+sharding建立一个分布式系统
- Redis： 与memcached相比
  - 分布式内存键值对系统
  - 提供更加丰富的类型，例如hashes, lists, sets 和sorted sets
  - 支持副本和集群

Memcached内部结构

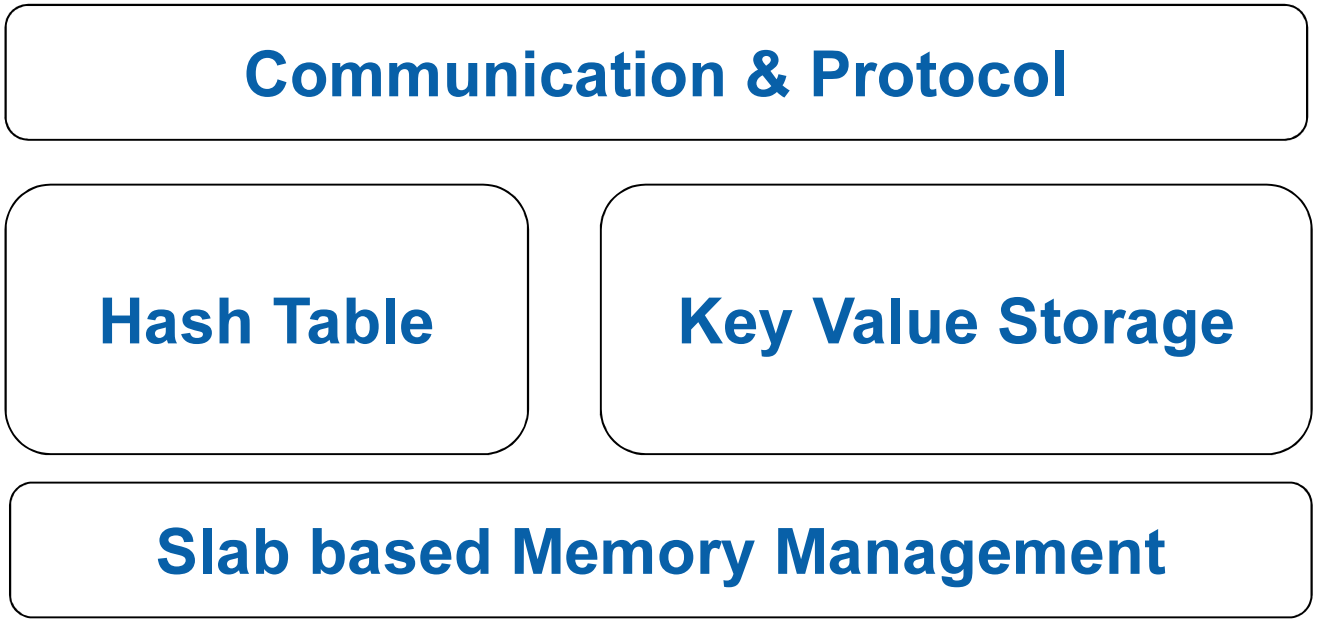

- 单机系统

Memcached内部结构

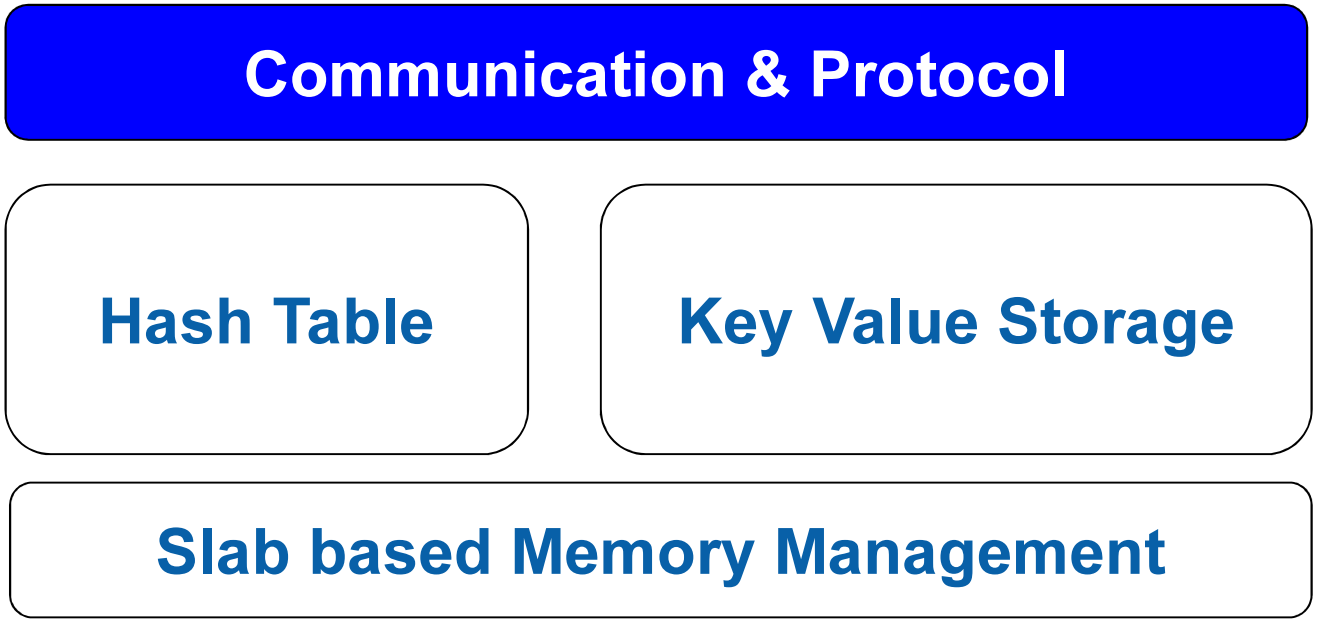

- 实现自定义的协议，支持GET/PUT等请求和响应
  - 文本方式的协议
  - 二进制协议

Memcached内部结构

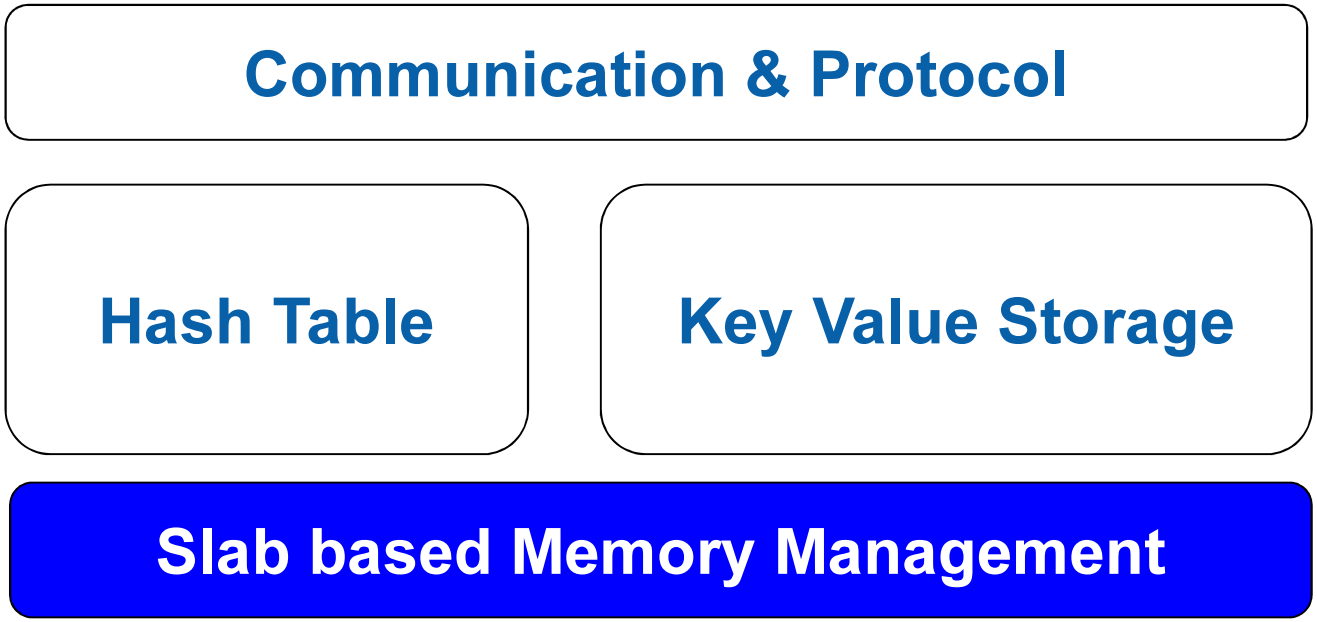

- 采用多个链表管理内存
  - 每个链表中的内存块大小相同
  - 第k个链表的内存块大小是2^kBase字节
  - 只分配和释放整个内存块

Slab-Based Memory Management

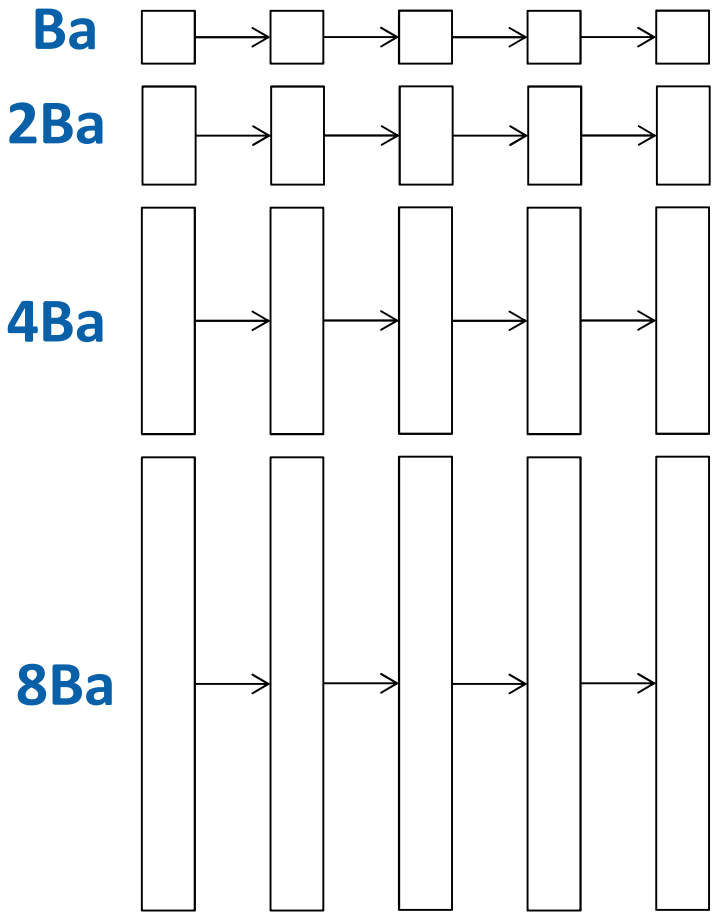

Ba(se)是最小的块的大小

Memcached内部结构

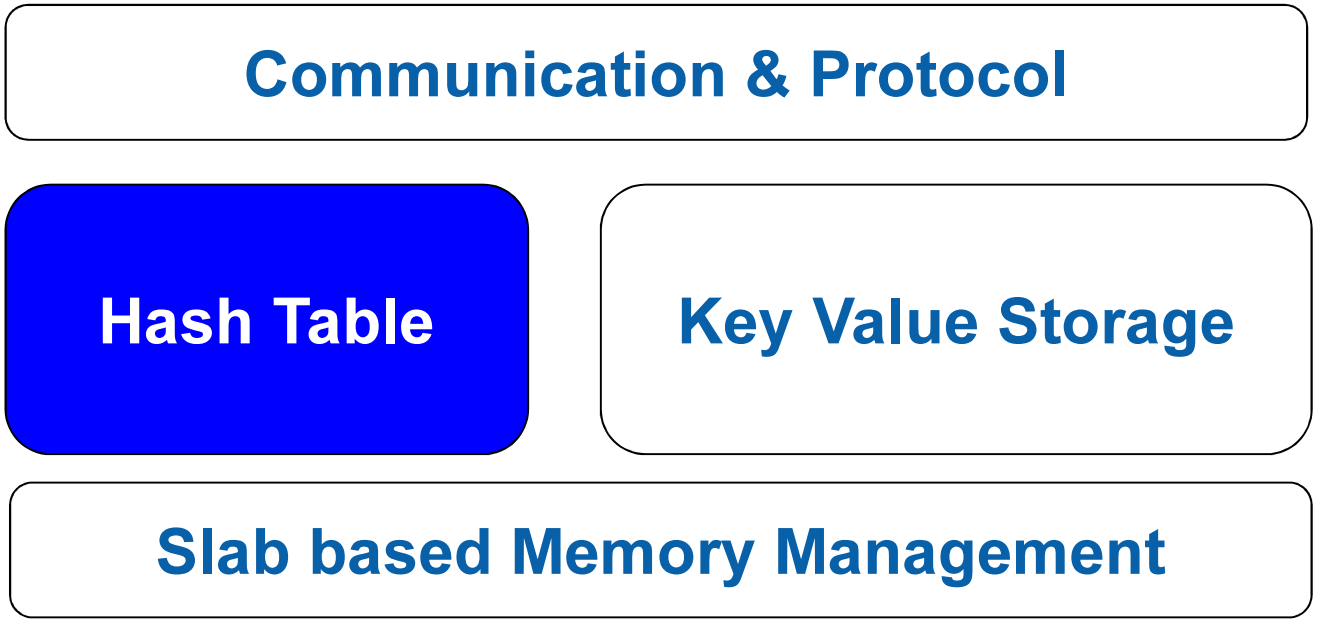

- Key-Value采用一个全局的Hash Table进行索引
- 多线程并发互斥访问

Memcached内部结构

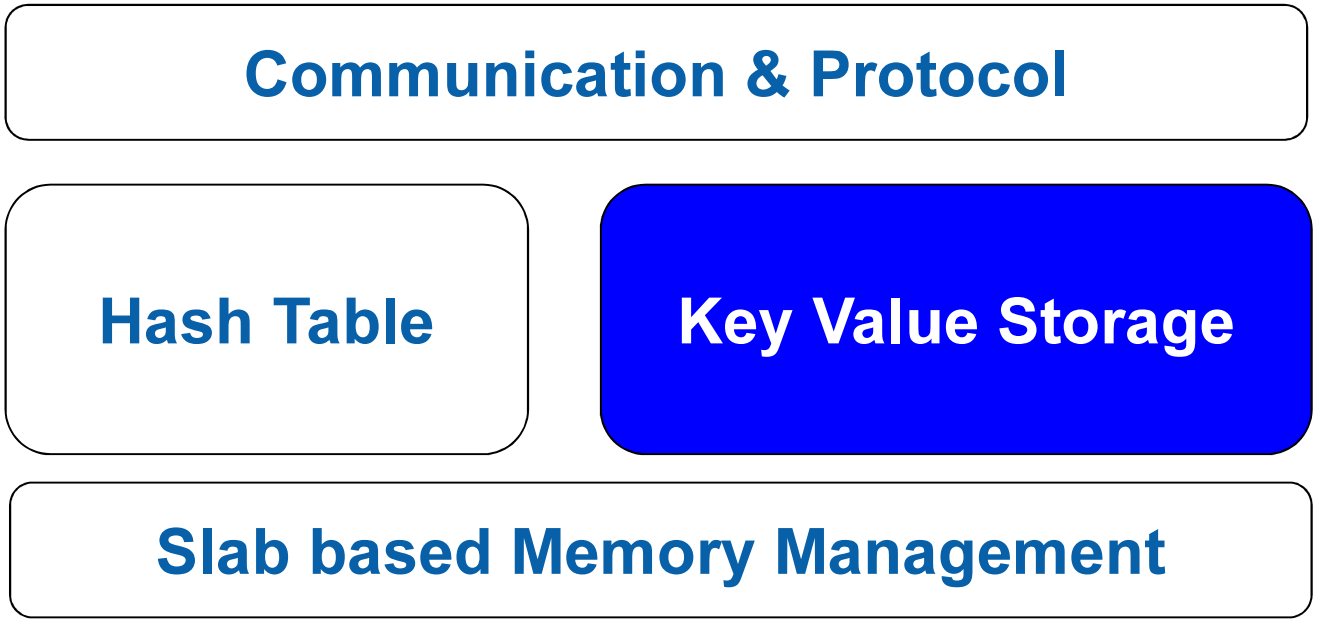

- 每个Key-Value存储在一个内存块中
  - Hash link： chained hash table
  - LRU link: 相同大小的已分配内存块在一个LRU链表上
- 内存不够时，可以丢弃LRU项

Facebook

- “Scaling Memcache at Facebook”. NSDI’13
- 刚开始：直接用MySQL就足够了

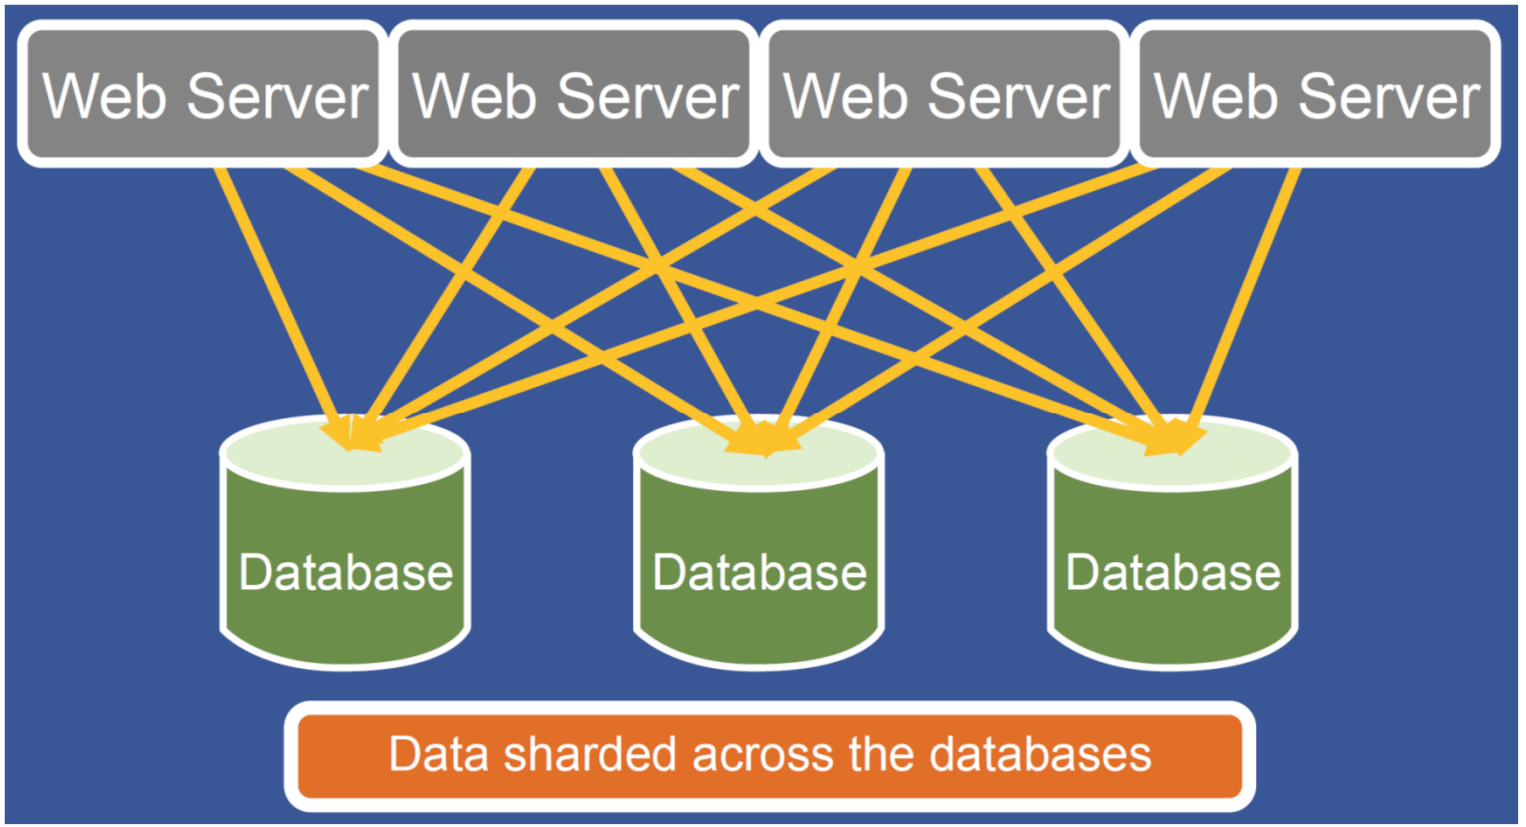

图来源：NSDI’13 slides

数十台服务器，每秒上百万操作请求

- 增加了几台Memcached服务器
- 读比写多2个数量级
- Look-aside cache
  - 多数hit在memcached
  - 如果miss，再读DB，然后放入memcached

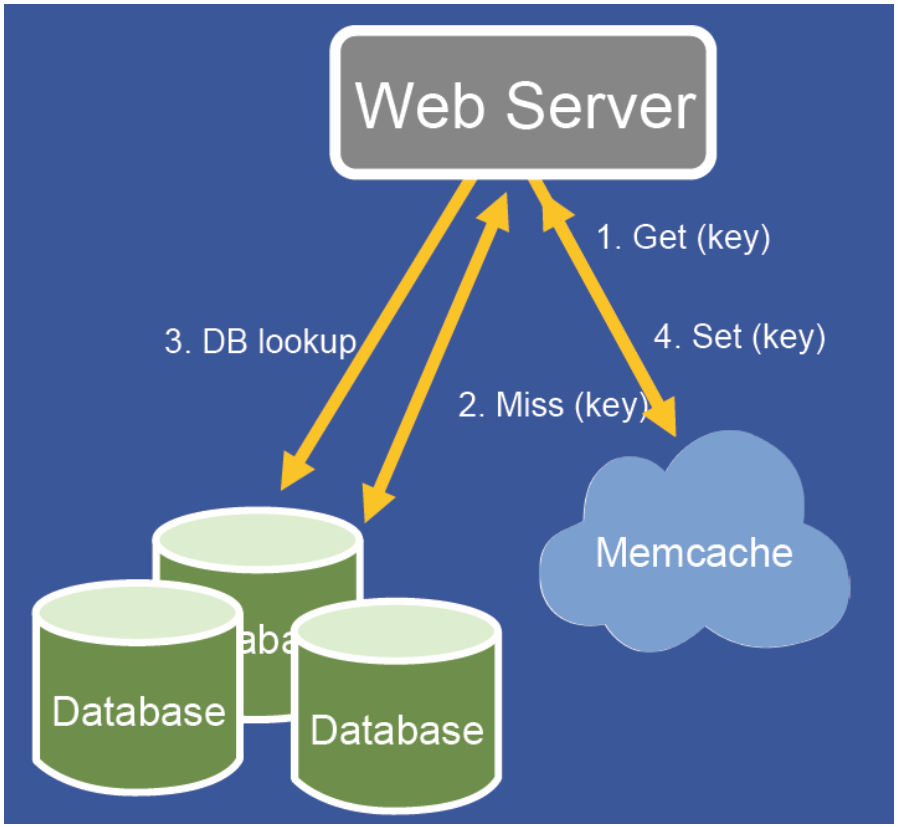

图来源：NSDI'13 slides

数十台服务器，每秒上百万操作请求

- 增加了几台Memcached服务器
  - 应用进行sharding
- 读比写多2个数量级
- Look-aside cache
  - 在从DB中删除后
  - 也从memcached删除
- 问题
  - 分布式读写，DB与memcached不一致
  - 可能读到稍旧的数据

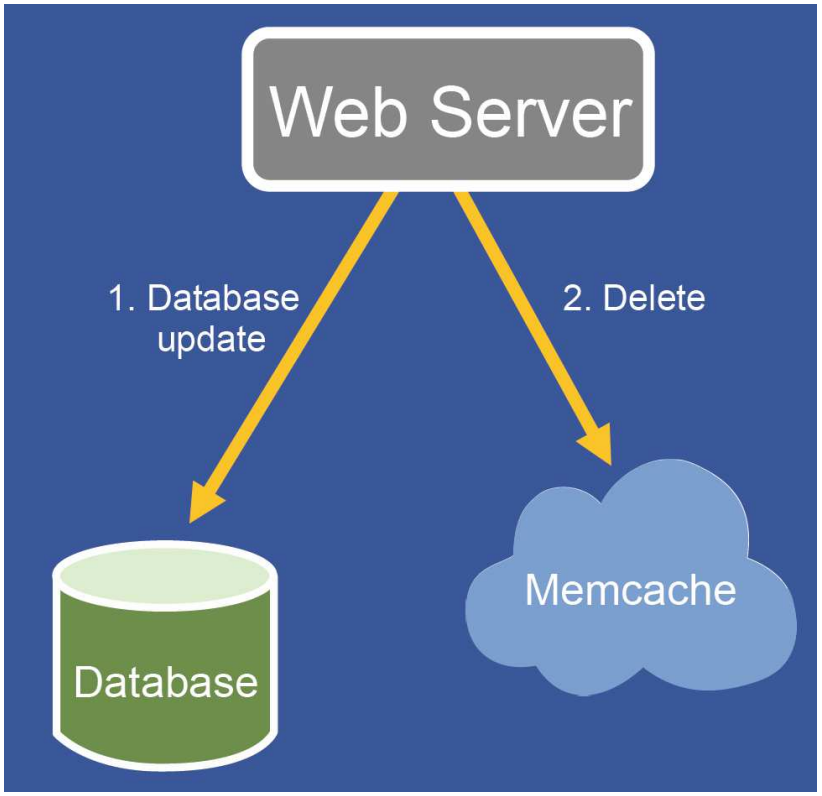

图来源：NSDI'13 slides

数百台服务器，每秒上千万操作请求

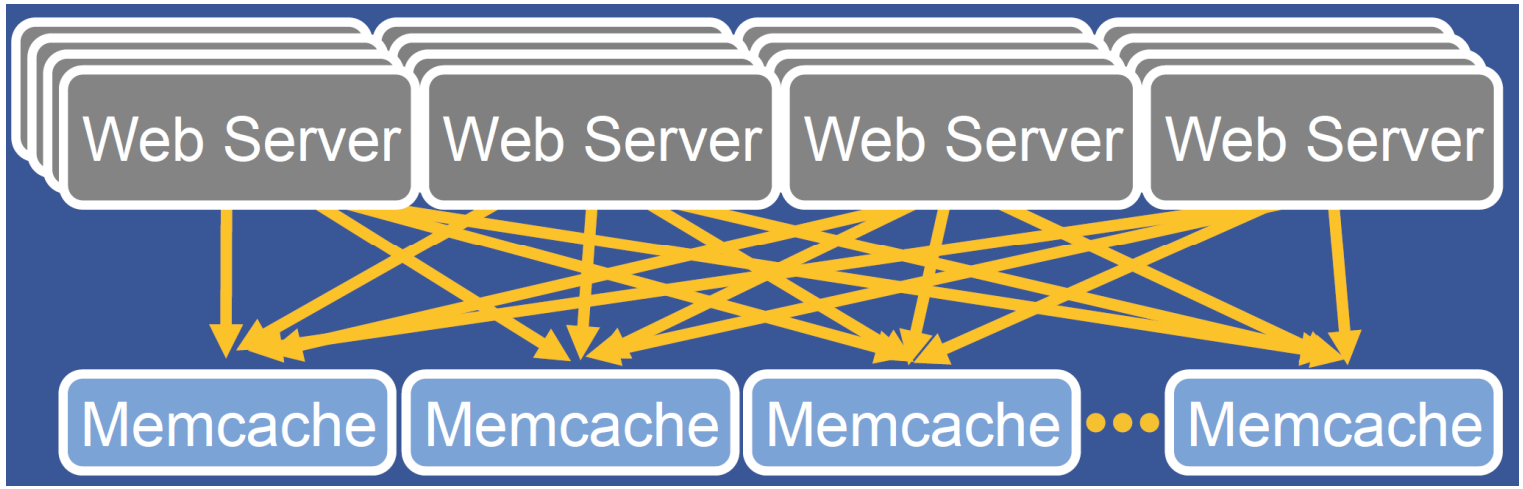

- 多个Memcached组成一个cluster
- 采用consistent hashing管理
- 每个web server为了满足一个网页，可能同时发出上百个请求

图来源：NSDI'13 slides

数千台服务器，每秒上亿次操作请求

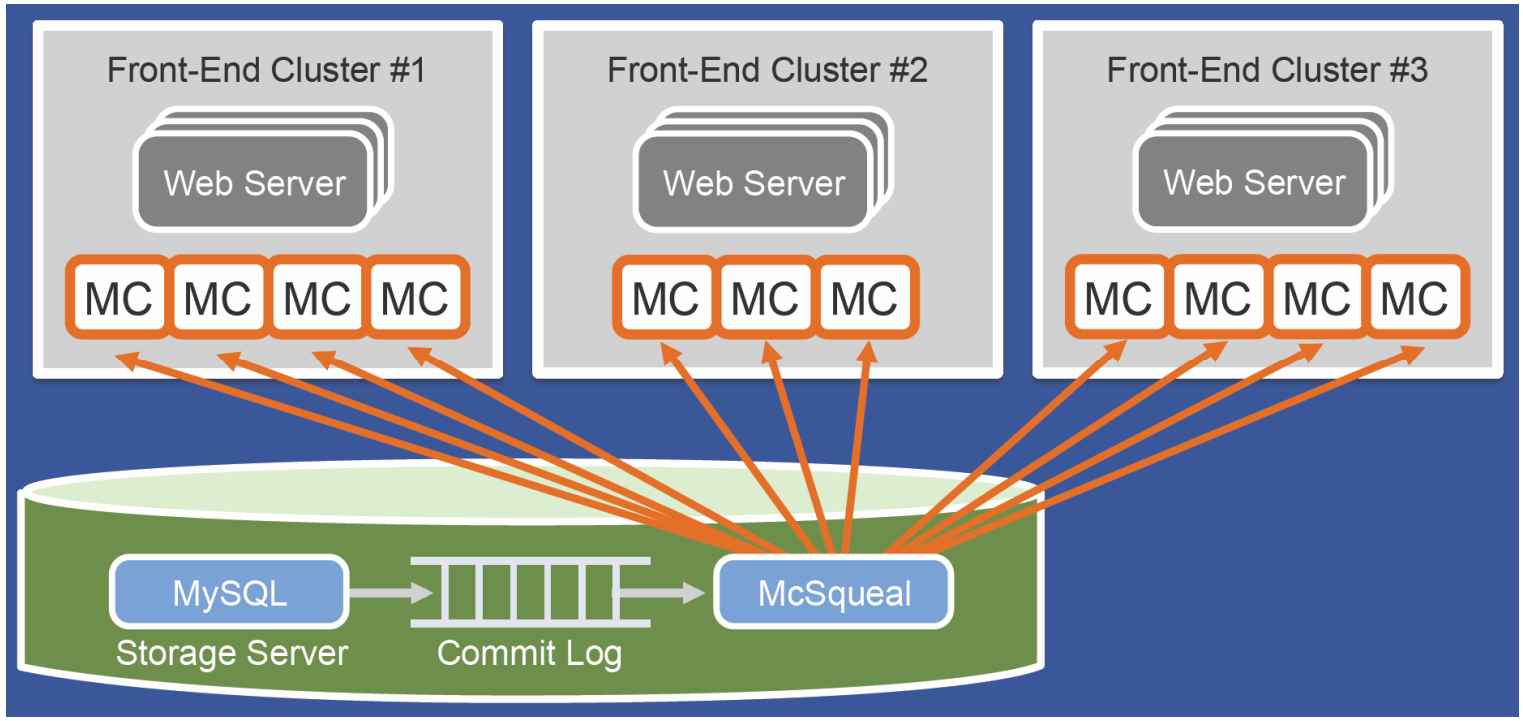

- 多个Front-end cluster
  - 每个Front-end cluster由Web servers, memcached cluster组成
- 同一组DB服务器
  - 使用commit log来把数据更新发到memcached

图来源： NSDI'13 slides

数千台服务器，每秒数十亿次操作请求

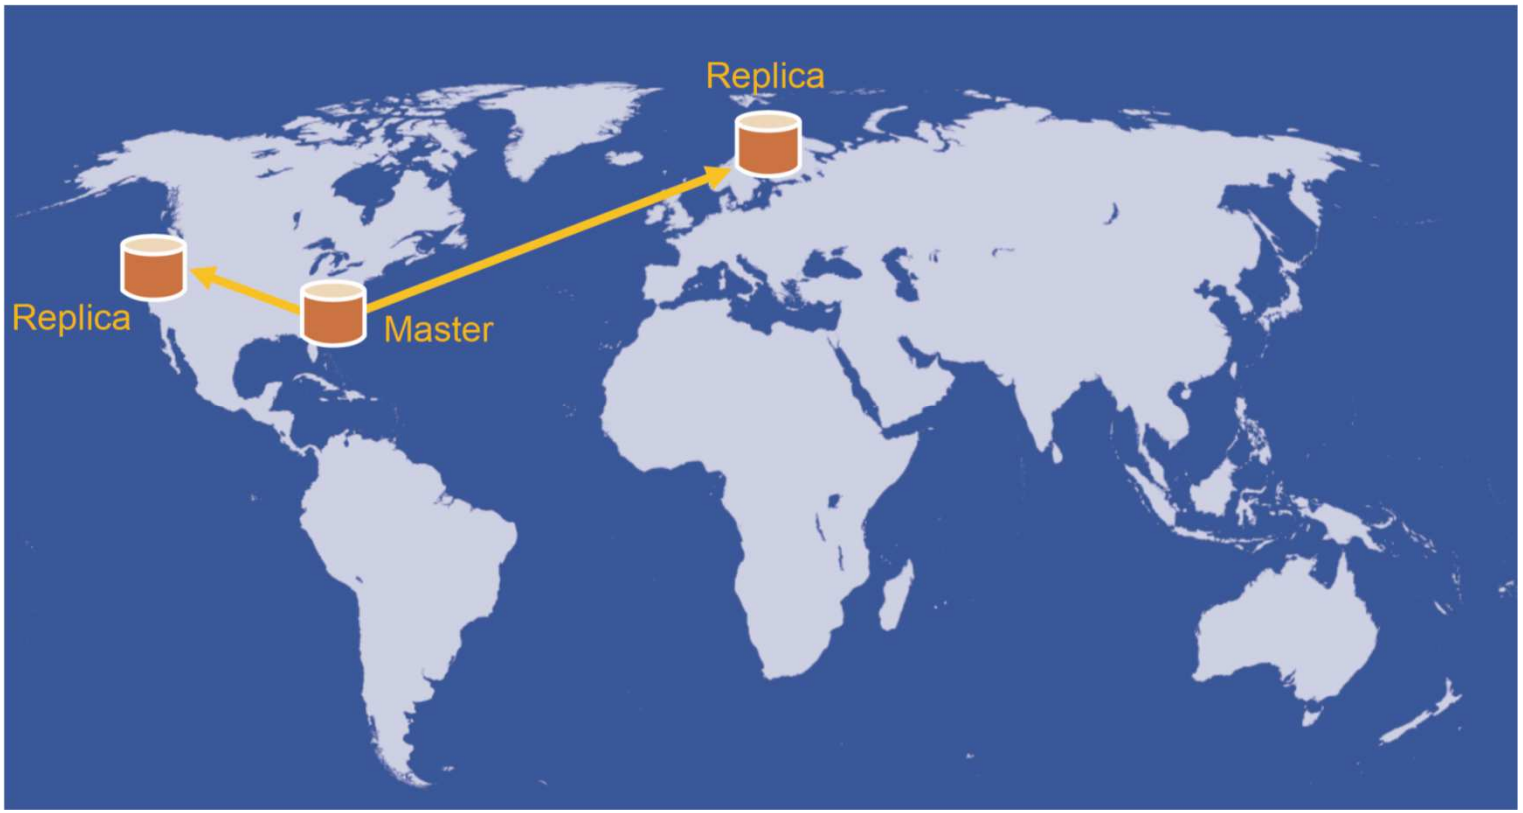

- 多个Replica
  - 主DB与Replica DB不一致？

图来源： NSDI'13 slides

数千台服务器，每秒数十亿次操作请求

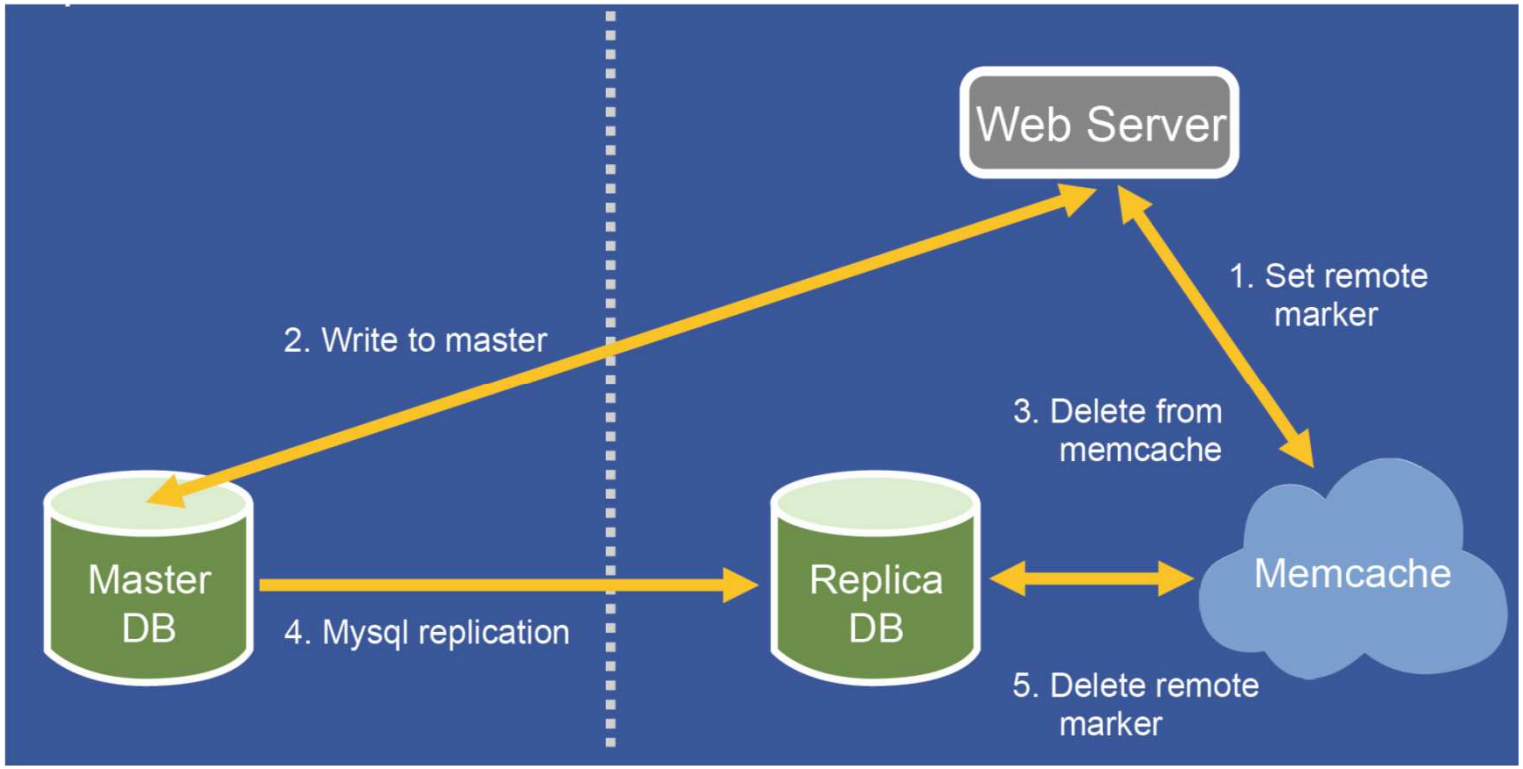

- 在DB write之前，先在memcached中写一个marker
- 这样读时发现marker，就一定要从主DB中取

图来源：NSDI'13 slides

Outline

- 图计算系统
  - GraphLab
  - PowerGraph
- 数据流系统Storm
- MapReduce + SQL系统
- 内存计算
  - 内存数据库
  - 内存键值系统

课后问题

1. 请说明GAS三个函数的作用
2. 请说明在Storm中上游和下游的grouping连接方式

