

第十二讲：模型预测控制的数值方法

最优控制的智能方法之二

张杰

人工智能学院
中国科学院大学

复杂系统管理与控制国家重点实验室
中国科学院自动化研究所

2017 年 10 月 26 日

Table of Contents

- 1 模型预测控制
- 2 非线性规划简介
- 3 间接法求解最优控制
- 4 直接法求解最优控制
- 5 非线性预测控制示例
- 6 附录：直接法求解最优控制

Table of Contents

- 1 模型预测控制
- 2 非线性规划简介
- 3 间接法求解最优控制
- 4 直接法求解最优控制
- 5 非线性预测控制示例
- 6 附录：直接法求解最优控制

如何求解模型预测控制?

- 【关键】 每个时刻求解开环形式最优控制
- 【上节】 无约束线性状态方程、二次性能指标可直接求解!
- 【本节】 有约束、非线性等情况如何求解?
 - PMP 得两点边值问题, 求解 BVP – 间接法
 - 欧拉的几何方法 – 直接法

MPC 文献

Remark 1 (综述)

- Mayne, David Q., James B. Rawlings, Christopher V. Rao, and Pierre OM Scokaert. "Constrained model predictive control: Stability and optimality." Automatica 36, no. 6 (2000): 789-814.
- Qin, S. Joe, and Thomas A. Badgwell. "A survey of industrial model predictive control technology." Control engineering practice 11, no. 7 (2003): 733-764. (工业)

Table of Contents

- 1 模型预测控制
- 2 非线性规划简介
- 3 间接法求解最优控制
- 4 直接法求解最优控制
- 5 非线性预测控制示例
- 6 附录：直接法求解最优控制

泰勒展开

用泰勒公式对函数多项式近似

$$F(x + \Delta x) = F(x) + \Delta x^T \nabla F(x) + \frac{1}{2} \Delta x^T \nabla^2 F(x) \Delta x + \dots$$

$$\nabla F(x) = \begin{bmatrix} \frac{\partial F}{\partial x_1}(x) \\ \vdots \\ \frac{\partial F}{\partial x_n}(x) \end{bmatrix}, \quad \nabla^2 F(x) = \begin{bmatrix} \frac{\partial^2 F}{\partial x_1^2}(x) & \dots & \frac{\partial^2 F}{\partial x_1 \partial x_n}(x) \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 F}{\partial x_n \partial x_1}(x) & \dots & \frac{\partial^2 F}{\partial x_n^2}(x) \end{bmatrix}.$$

最优的必要条件（一阶条件）： $\nabla F(x) = 0$

线搜索方法

线搜索方法, Line Search, 迭代地通过数值方法求解函数极值:

- 给定: 对最优解 \mathbf{x} 的初步估计 \mathbf{x}_0
- 迭代:

$$\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + \alpha_k \mathbf{d}_k \quad (1)$$

其中 α_k 为步长, \mathbf{d}_k 为迭代方向

$\hat{\mathbf{x}}_{k+1}$ 更接近 (甚至达到) 最优

最常见搜索步长

- 固定较小步长

$$\alpha_k = \alpha \quad (2)$$

- 衰减至 0 的步长

$$\lim_{k \rightarrow \infty} \alpha_k \rightarrow 0, \quad \sum_{k=0}^{\infty} \alpha_k = \infty \quad (3)$$

线搜索方向选择：最速下降法（一阶方法）

泰勒展开 $F(\hat{\mathbf{x}})$ 得到

$$F(\hat{\mathbf{x}}_{k+1}) \approx F(\hat{\mathbf{x}}_k) + \nabla F(\hat{\mathbf{x}}_k)^T (\hat{\mathbf{x}}_{k+1} - \hat{\mathbf{x}}_k) = F(\hat{\mathbf{x}}_k) + \nabla F(\hat{\mathbf{x}}_k)^T \alpha_k \mathbf{d}_k \quad (4)$$

假定 $\alpha_k > 0$ ，若要使得序列单调递减，应有

$$\nabla F(\hat{\mathbf{x}}_k)^T \mathbf{d}_k < 0 \quad (5)$$

只需选择负梯度方向为线搜索方向

$$\mathbf{d}_k = -\nabla F(\hat{\mathbf{x}}_k)$$

线搜索方向选择：牛顿法（牛顿求根）

函数极值一阶条件，

$$\nabla F(\hat{\mathbf{x}}) = 0.$$

转化为求函数零点 $c(\hat{\mathbf{x}}) = 0$ ，泰勒展开，若“下一步”为零点，

$$0 \approx c(\hat{\mathbf{x}}_{k+1}) \approx c(\hat{\mathbf{x}}_k) + \frac{\partial c}{\partial x}(\hat{\mathbf{x}}_k)(\hat{\mathbf{x}}_{k+1} - \hat{\mathbf{x}}_k) \quad (6)$$

其中

$$\frac{\partial c}{\partial x} = \begin{bmatrix} \frac{\partial c_1}{\partial x_1} & \cdots & \frac{\partial c_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial c_m}{\partial x_1} & \cdots & \frac{\partial c_m}{\partial x_n} \end{bmatrix}.$$

$$\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k - \frac{\partial c}{\partial x}(\hat{\mathbf{x}}_k)^{-1} c(\hat{\mathbf{x}}_k), \quad \mathbf{d}_k = -\frac{\partial c}{\partial x}(\hat{\mathbf{x}}_k)^{-1} c(\hat{\mathbf{x}}_k). \quad (7)$$

线搜索方向选择：牛顿法

函数极值一阶条件，

$$\nabla F(\hat{\mathbf{x}}) = 0.$$

使用牛顿求根公式，

$$0 \approx \nabla F(\hat{\mathbf{x}}_{k+1}) \approx \nabla F(\hat{\mathbf{x}}_k) + \nabla^2 F(\hat{\mathbf{x}}_k)(\hat{\mathbf{x}}_{k+1} - \hat{\mathbf{x}}_k) \quad (8)$$

$$\mathbf{d}_k = -\nabla^2 F^{-1}(\hat{\mathbf{x}}_k) \nabla F(\hat{\mathbf{x}}_k) \quad (9)$$

拟牛顿法

海塞矩阵计算复杂。拟牛顿法在 x_k 附近考虑 $F(x)$ 的二次逼近

$$\begin{aligned} F(\hat{\mathbf{x}}_{k+1}) &\approx F(\hat{\mathbf{x}}_k) + (\hat{\mathbf{x}}_{k+1} - \hat{\mathbf{x}}_k)^T \nabla F(\hat{\mathbf{x}}_k) \\ &\quad + \frac{1}{2} (\hat{\mathbf{x}}_{k+1} - \hat{\mathbf{x}}_k)^T B_k^{-1} (\hat{\mathbf{x}}_{k+1} - \hat{\mathbf{x}}_k) \end{aligned} \quad (10)$$

$$\hat{\mathbf{d}}_k = -B_k \nabla F(\hat{\mathbf{x}}_k) \quad (11)$$

常见的拟牛顿法包括 DFP(Davidon, Fletcher, Powell), BFGS(Broyden, Fletcher, Goldfarb, Shanno) 等 (可参考袁亚湘《非线性优化计算方法》第四章, 或其他最优化、运筹学教材)

等式约束的函数极值——Lagrange 乘子法

$$\begin{aligned} \min F(x) \\ \text{s.t. } f(x) = 0. \end{aligned}$$

引入 Lagrange 乘子 $\lambda \in \mathbb{R}^m$,

$$\bar{F}(x, \lambda) = F(x) + \lambda^T f(x). \quad (12)$$

则等式约束情况下 $F(x)$ 取极值的必要条件是

$$\frac{\partial \bar{F}}{\partial x} = 0 \quad (13)$$

$$\frac{\partial \bar{F}}{\partial \lambda} = f(x) = 0. \quad (14)$$

不等式约束函数极值——KKT 条件

定理 1 (不等式约束的函数极值)

不等式约束 $f(x) \leq 0$, 求 $F(x)$ 极值。引入拉格朗日乘子 λ

$$\bar{F}(x, \lambda) = F(x) + \lambda^T f(x) \quad (15)$$

$F(x)$ 取极值的必要条件是 Karush-Kuhn-Tucker 条件

$$\frac{\partial \bar{F}}{\partial x} = 0 \quad (16)$$

$$\lambda^T f(x) = 0, \lambda \geq 0. \quad (17)$$

若 $f(x) = 0$, 称激活约束; 若 $f(x) < 0$, 称非激活约束

二次规划问题 (Quadratic Programming, QP)

问题 1 (二次规划问题)

最小化性能指标

$$\min_{x \in \mathbb{R}^n} F(x) = \frac{1}{2}x^T Qx - x^T b \quad (18)$$

约束条件为

$$A_1 x = a_1 \quad (19)$$

$$A_2 x \leq a_2 \quad (20)$$

等式约束二次规划

问题 2 (等式约束二次规划)

最小化性能指标

$$\min_{x \in \mathbb{R}^n} F(x) = \frac{1}{2} x^T Q x - x^T b \quad (21)$$

约束条件为

$$Ax = a \quad (22)$$

等式约束二次规划

解:

$$\bar{F}(x, \lambda) = \frac{1}{2}x^T Qx - x^T b + \lambda^T (Ax - a) \quad (23)$$

由 KKT 条件有

$$0 = \nabla_x \bar{F} = Qx - b + A^T \lambda \quad (24)$$

$$0 = Ax - a \quad (25)$$

$$\begin{bmatrix} Q & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ \lambda \end{bmatrix} = \begin{bmatrix} b \\ a \end{bmatrix} \Rightarrow c(X) = 0 \text{ 形式, 牛顿法求解} \quad (26)$$

激活集法 (Active set) 不等式约束 *

Remark 2

只需断定哪些约束是激活的即可

- 从一个容许解出发
- 开始迭代：
 - 对给定激活集合解 QP，得到解和拉格朗日乘子
 - 去除不满足 KKT 条件的拉格朗日乘子（小于零）
 - 增加未被满足的约束条件
- 停止迭代

序列二次规划, Sequential Quadratic Programming, SQP

对于一般的目标函数 F 、约束 f, g , 对 F 和 f, g 泰勒展开

$$F(\mathbf{x}) \approx F(\hat{\mathbf{x}}_k) + (\mathbf{x} - \hat{\mathbf{x}}_k)^T \nabla F(\hat{\mathbf{x}}_k) + \frac{1}{2}(\mathbf{x} - \hat{\mathbf{x}}_k)^T \nabla^2 F(\hat{\mathbf{x}}_k)(\mathbf{x} - \hat{\mathbf{x}}_k) \quad (27)$$

$$f(\mathbf{x}) \approx f(\hat{\mathbf{x}}_k) + (\mathbf{x} - \hat{\mathbf{x}}_k)^T \nabla f(\hat{\mathbf{x}}_k) \quad (28)$$

$$g(\mathbf{x}) \approx g(\hat{\mathbf{x}}_k) + (\mathbf{x} - \hat{\mathbf{x}}_k)^T \nabla g(\hat{\mathbf{x}}_k) \quad (29)$$

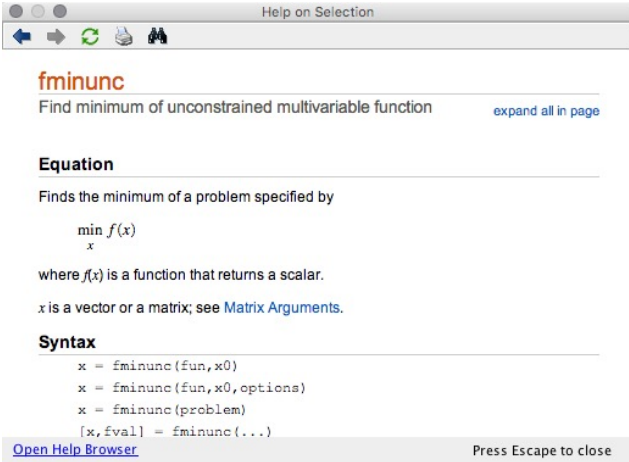
得到

$$\min_{\mathbf{x} - \hat{\mathbf{x}}_k \in \mathbb{R}^n} (\mathbf{x} - \hat{\mathbf{x}}_k)^T \nabla F(\hat{\mathbf{x}}_k) + \frac{1}{2}(\mathbf{x} - \hat{\mathbf{x}}_k)^T \nabla^2 F(\hat{\mathbf{x}}_k)(\mathbf{x} - \hat{\mathbf{x}}_k) \quad (30)$$

$$\text{s.t. } f(\hat{\mathbf{x}}_k) + (\mathbf{x} - \hat{\mathbf{x}}_k)^T \nabla f(\hat{\mathbf{x}}_k) = 0 \quad (31)$$

$$g(\hat{\mathbf{x}}_k) + (\mathbf{x} - \hat{\mathbf{x}}_k)^T \nabla g(\hat{\mathbf{x}}_k) \leq 0 \quad (32)$$

MATLAB 求解无约束非线性规划



A screenshot of the MATLAB Help window for the `fminunc` function. The window has a title bar "Help on Selection" and a toolbar with navigation icons. The content is organized into sections: the function name `fminunc` in orange, a description "Find minimum of unconstrained multivariable function", an "Equation" section with the mathematical expression $\min_x f(x)$, a description of the function, the "Syntax" section with code examples, and a link to the "Open Help Browser".

fminunc
Find minimum of unconstrained multivariable function [expand all in page](#)

Equation

Finds the minimum of a problem specified by

$$\min_x f(x)$$

where $f(x)$ is a function that returns a scalar.

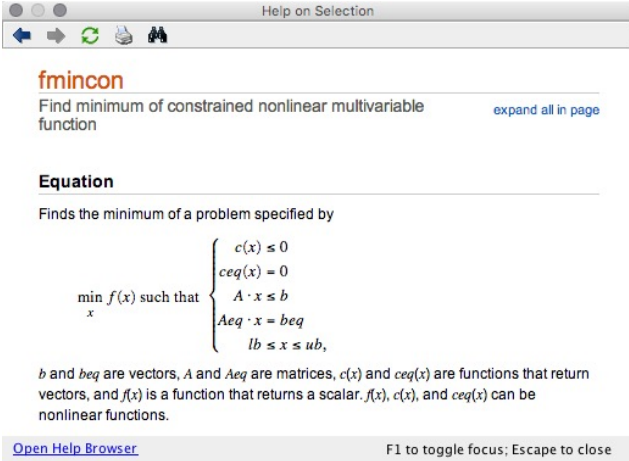
x is a vector or a matrix; see [Matrix Arguments](#).

Syntax

```
x = fminunc(fun,x0)
x = fminunc(fun,x0,options)
x = fminunc(problem)
[x,fval] = fminunc(...)
```

[Open Help Browser](#) Press Escape to close

MATLAB 求解有约束非线性规划



A screenshot of the MATLAB Help window for the `fmincon` function. The window has a title bar "Help on Selection" and a toolbar with navigation icons. The main content area shows the function name `fmincon` in orange, followed by the description "Find minimum of constrained nonlinear multivariable function" and a link "expand all in page". Below this is a section titled "Equation" which describes the problem: "Finds the minimum of a problem specified by". The equation is presented as a minimization problem over x with constraints. The text below the equation explains the variables: b and beq are vectors, A and Aeq are matrices, $c(x)$ and $ceq(x)$ are functions that return vectors, and $f(x)$ is a function that returns a scalar. At the bottom, there is a link "Open Help Browser" and a note "F1 to toggle focus; Escape to close".

fmincon
Find minimum of constrained nonlinear multivariable function [expand all in page](#)

Equation
Finds the minimum of a problem specified by

$$\min_x f(x) \text{ such that } \begin{cases} c(x) \leq 0 \\ ceq(x) = 0 \\ A \cdot x \leq b \\ Aeq \cdot x = beq \\ lb \leq x \leq ub, \end{cases}$$

b and beq are vectors, A and Aeq are matrices, $c(x)$ and $ceq(x)$ are functions that return vectors, and $f(x)$ is a function that returns a scalar. $f(x)$, $c(x)$, and $ceq(x)$ can be nonlinear functions.

[Open Help Browser](#) F1 to toggle focus; Escape to close

Table of Contents

- 1 模型预测控制
- 2 非线性规划简介
- 3 间接法求解最优控制**
- 4 直接法求解最优控制
- 5 非线性预测控制示例
- 6 附录：直接法求解最优控制

极值原理求解最优控制的过程

Remark 3 (极值原理求解最优控制的过程)

- 构造 Hamiltonian
- 求容许控制极值条件，以协态状态表示最优控制
- 最优控制代入规范方程，得到关于最优状态、协态的微分方程组
- 根据边界条件和初值获得微分方程组的边界条件
- 直接求解或 使用数值方法求解两点边值问题

初值问题 v.s. 两点边值问题

例 1 (初值问题, IVP)

仅在 t_0 有边界条件

$$\dot{x}_1(t) = x_2(t) \quad (33)$$

$$\dot{x}_2(t) = \lambda \sinh(\lambda x_1(t)) \quad (34)$$

$$x_1(0) = 0, x_2(0) = -0.518621. \quad (35)$$

例 2 (两点边值问题, BVP)

在 t_0, t_f 两点都有边界条件

$$\dot{x}_1(t) = x_2(t) \quad (36)$$

$$\dot{x}_2(t) = \lambda \sinh(\lambda x_1(t)) \quad (37)$$

$$x_1(0) = 0, x_1(1) = 1 \quad (38)$$

例子：打靶法

例 3 (直观的例子)

已知 $x(t_f) = x_f$ 但不知 $x(t_0)$ ，不从 t_f 倒推，要从 t_0 正推！

$$\dot{x}(t) = x(t) \quad (39)$$

$$x(t) = x(t_0)e^{t-t_0} \quad (40)$$

什么初值 $x(t_0)$ 能使得 $x(t_f) = x_f$ ？假定初值为 x_0 ，“打靶”误差

$$c(x_0) = x_f - x(t_f) = x_f - x_0e^{t_f-t_0} \quad (41)$$

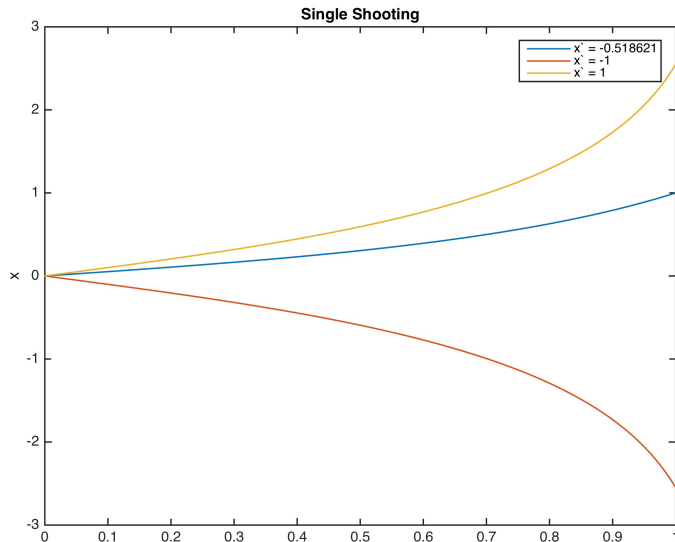
是 x_0 的函数，求解优化问题即可找到合适的初值使 $c(x_0) = 0$ ！

打靶法, Single/Sequential Shooting Method

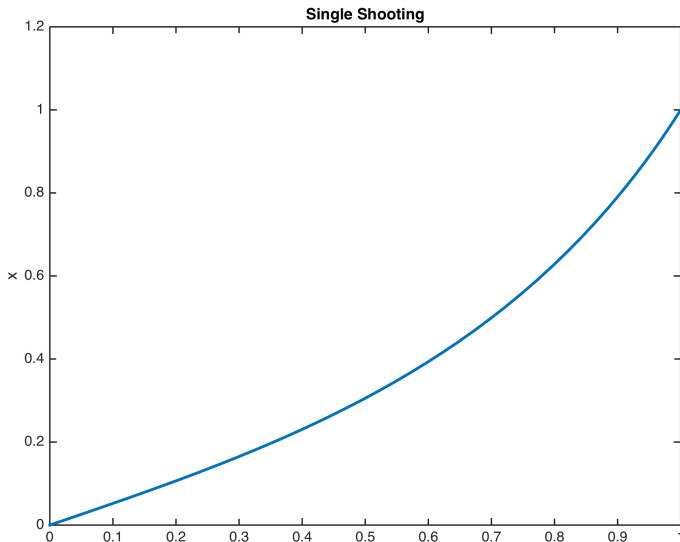
我们将上述过程抽象如下打靶法（单打靶法，顺序打靶法）

- 初始化：“猜测” $x_0 = x(t_0)$
- 打靶：求解常微分方程初值问题（IVP），得 $x(t_f; x_0)$
- 得终止时刻的误差： $c(x_0) = x_f - x(t_f; x_0)$
- 使用非线性规划方法求解 $c(x_0) = 0$


例2: $\lambda = 2.0$ “打靶” (随机选取 $x_2(0)$ 即 $\dot{x}_1(0)$)



例2: $\lambda = 2.0$ 打靶法求解 BVP



例3的误差被放大，打靶法无法处理



单打靶法的问题

Remark 4 (单打靶法的问题)

- 难以处理不稳定的系统（例2中 $\lambda > 2$ 和例3）
- 对高度非线性问题收敛较慢
- 初值猜测太差会导致无解

多重打靶法

单打靶法在较长区间上难以收敛，多重打靶将时间区间分割


例 4 (多重打靶法)

在一半时间 $t_1 = (t_0 + t_f)/2$ 再立一靶。猜测 t_0 点取值为 $s_1 = x(t_0)$ ，猜测 t_1 点取值为 $s_2 = x(t_1)$ ， $s = (s_1, s_2)^T$ 。于是应满足二维的约束条件

$$0 = c_1(s_1, s_2) = s_2 - s_1 e^{t_1 - t_0} \quad (42)$$

$$0 = c_2(s_1, s_2) = x_f - s_2 e^{t_f - t_1} \quad (43)$$

多重打靶法



多重打靶法, Multiple Shooting Method

将时间轴划分为 $t_0 < t_1 < \dots < t_{N-1} < t_N = t_f$, 则

$$0 = c_1(s) = s_2 - \hat{s}_1 \quad (44)$$

$$0 = c_2(s) = s_3 - \hat{s}_2 \quad (45)$$


$$\dots \quad (46)$$

$$0 = c_N(s) = x_f - \hat{s}_{N-1} \quad (47)$$


其中 \hat{s}_i 是第 i 个区间上求解 IVP 问题得到的终值, s_1 的函数

例2: $\lambda = 5.0, N = 20$ 多重打靶法求解边值问题

$x_1[0,1]\text{inspace}$



$x_2[0,0]\text{inspace}$



多重打靶法的优势劣势

Remark 5 (多重打靶法的优势)

- 一般系统均可处理
- 分块使得每个子系统更加线性，收敛更快
- 初值中可运用对轨迹的已知信息

Remark 6 (多重打靶法的劣势)

- 需要猜测整个状态轨迹作为初值

Table of Contents

- 1 模型预测控制
- 2 非线性规划简介
- 3 间接法求解最优控制
- 4 直接法求解最优控制**
- 5 非线性预测控制示例
- 6 附录：直接法求解最优控制

考察最优控制问题

问题3 (固定终端时刻的最优控制问题)

$$\begin{aligned} \min_u & h(x(T)) + \int_0^T g(x(t), u(t)) dt. \\ \text{s.t.} & x(0) = x_0 \\ & \dot{x}(t) - f(x(t), u(t)) = 0 \\ & c(x(t), u(t)) \leq 0 \\ & m(x(T)) = 0 \end{aligned}$$

T 确定

时间依赖可通过增加一维状态（为时间）解决

自由终止时间转化为固定终止时间 *

引入对时间的变换

$$t = \tau T, \tau \in [0, 1]. \quad \bar{x}(\tau) := x(\tau T) = x(t) \quad (48)$$

$$\frac{d}{d\tau} \bar{x}(\tau) = \frac{d}{dt} x(t) \frac{dt}{d\tau} = T f(\bar{x}(\tau), \bar{u}(\tau)) \quad (49)$$

于是自由终止时间的最优控制问题转化为固定终止时间 (1)


问题 4 (时间变换)

$$\begin{aligned} \min_{u, T} & h(\bar{x}(1)) + \int_0^1 T g(\bar{x}(\tau), \bar{u}(\tau)) d\tau. \\ \text{s.t.} & \bar{x}(0) = x_0 \\ & \dot{\bar{x}}(\tau) - T f(\bar{x}(\tau), \bar{u}(\tau)) = 0 \\ & c(\bar{x}(\tau), \bar{u}(\tau)) \leq 0 \\ & m(\bar{x}(1)) = 0 \end{aligned}$$

控制参数化

将时间轴划分为 N 份, $0 = \tau_0 < \tau_1 < \dots < \tau_N = 1$,


$$u(\tau) = q_i, \tau \in [\tau_i, \tau_{i+1}] \quad (50)$$



用 q_0, \dots, q_{N-1} 近似控制变量

控制参数化


可使用更加自由的参数化方式，分段函数、神经网络或模糊系统



直接法求解：直接序列打靶法

利用打靶法，可将最优控制问题转化为非线性规划问题

- 自变量为控制 $u(t; q)$ 的参数 q
- 状态 $x(t; q)$ 可表示为 q 的函数（常微分方程数值解）



直接打靶法的非线性规划问题

问题 5 (直接打靶法的非线性规划问题)

控制参数化、状态变量使用 IVP 数值解，原最优控制问题转化为

$$\begin{aligned} \min_q F(q) &= h(x(T; q)) + \int_0^T g(x(t; q), u(t; q)) dt. \\ \text{s.t. } c(x(t_i; q), u(t_i; q)) &\leq 0, i = 0, \dots, N \\ m(x(T; q)) &= 0 \end{aligned}$$

使用序列二次规划 (Sequential Quadratic Programming) 求解形如下式的方程

$$\min_q F(q) \quad \text{s.t. } g(q) \leq 0, \quad f(q) = 0. \quad (51)$$

例子：直接打靶法解最优控制

例 5 (直接打靶法解最优控制)



$$\begin{aligned} \min_u \int_0^3 [x^2(t) + u^2(t)] dt \\ \text{s.t. } \dot{x} = (1+x)x + u, x(0) = 0.05 \\ -1 \leq x \leq 1 \\ -1 \leq u \leq 1 \end{aligned}$$

固定终值 $x(3) = 0$



取 $N = 30$ ，均分 $[0, 3]$ 。初始估计 $q_i = 0$

直接打靶法解最优控制 1/8



迭代 $k = 0$





直接打靶法解最优控制 2/8

迭代 $k = 1$ 



直接打靶法解最优控制 3/8

迭代 $k = 2$ 

直接打靶法解最优控制 4/8



迭代 $k = 3$ 

直接打靶法解最优控制 5/8

迭代 $k = 4$ 



直接打靶法解最优控制 6/8

迭代 $k = 5$





直接打靶法解最优控制 7/8

迭代 $k = 6$



直接打靶法解最优控制 8/8


迭代 $k = 7$



直接法求解：直接多重打靶法

多重打靶，将区间划分为多段

- 增加对每个区间初值的猜测 $x(t_i) = s_i$
- 控制 $u(t; q) = q_i, t \in [t_i, t_{i+1}]$
- 状态 $x(t; s, q), t \in [t_i, t_{i+1}]$ 依然使用 IVP 求解



直接多重打靶法的非线性规划问题



问题 6 (直接多重打靶法的非线性规划问题)

原最优控制问题转化为非线性规划问题



$$\begin{aligned}
 \min_q F(q) &= h(x(T; q_N)) + \sum_{i=0}^{N-1} \int_{t_i}^{t_{i+1}} g(x(t; s_i, q_i), q_i) dt. \\
 \text{s.t. } c(x(t_i; s_i, q_i), q_i) &\leq 0, i = 0, \dots, N \\
 m(x(T; q_N)) &= 0 \\
 s_0 &= x_0 \\
 s_{i+1} - x_-(t_{i+1}; s_i, q_i) &= 0
 \end{aligned}$$

直接多重打靶法解最优控制 1/4

迭代 $k = 0$, q_i 初始化为零, s_i 初始化为 IVP 解在 $[-1, 1]$ 的限制





直接多重打靶法解最优控制 2/4

迭代 $k = 1$ 



直接多重打靶法解最优控制 3/4

迭代 $k = 2$



直接多重打靶法解最优控制 4/4

迭代 $k = 3$



直接打靶法的优势劣势

Remark 7 (直接打靶法的优势)

- 充分利用现代非线性规划技术
- 初值中可运用对轨迹的已知信息
- 尚未收敛的解也很可能是容许的

Remark 8 (直接打靶法的劣势)

- 需要猜测整个状态轨迹作为初值
- 容易收敛到局部最优，非最优控制

Table of Contents

- 1 模型预测控制
- 2 非线性规划简介
- 3 间接法求解最优控制
- 4 直接法求解最优控制
- 5 非线性预测控制示例**
- 6 附录：直接法求解最优控制

非线性预测控制求解方法

- 使用间接法求解最优控制问题
- 使用直接法求解最优控制问题

线性模型使用非线性预测方法

例 6 (线性模型使用非线性预测方法)

状态方程

$$\dot{x}_1 = x_2 \quad (52)$$

$$\dot{x}_2 = x_2 + u \quad (53)$$

$t_0 = 0, t_f = 10$, 初始状态 $(1, 1)$ 。约束条件


$$|u(t)| \leq 1.5 \quad (54)$$

最小化性能指标

$$J(u) = \frac{h}{2} x_2^2(t_f) + \int_{t_0}^{t_f} \left[\frac{q}{2} x_1^2(t) + \frac{r}{2} u^2(t) \right] dt \quad (55)$$


使用直接序列打靶法求解最优控制 1/2

Figure: $q = 1, r = 3, h = 4$ 状态




使用直接序列打靶法求解最优控制 2/2

Figure: $q = 1, r = 3, h = 4$ 控制, 单次计算 9.934s




使用直接序列打靶法求解预测控制 1/2

Figure: $q = 1, r = 3, h = 4, T = 1$ 失败!



使用直接序列打靶法求解预测控制 2/2

Figure: 设计性能指标 $q = 1, r = 0.3, h = 4, T = 1$



模型预测控制的优势

- 灵活的预测模型
 - 连续模型 / 离散模型
 - 线性模型 / 非线性模型
- 善于处理约束
 - 控制变量约束
 - 状态变量约束
- 通过求解开环控制获得近似的闭环控制 (弥补了极值原理和直接法数值方法不是闭环的缺陷)

模型预测控制相对于经典最优控制的缺陷

发生下列情形之一则性能指标下降或控制目标难以精确达到

- 预测时段过短
- 预测模型不够精确
- 开环控制求解耗时过长
- 开环控制求解不够精确或求解失败

Table of Contents

- 1 模型预测控制
- 2 非线性规划简介
- 3 间接法求解最优控制
- 4 直接法求解最优控制
- 5 非线性预测控制示例
- 6 附录：直接法求解最优控制

```

1  opts = optimoptions('fmincon','Algorithm','sqp');
2  q = fmincon(@obj,q0,[],[],[],[],[],[],@nonlcon,opts);
3
4  function J=obj(q)
5      J = dt * 0.5 * ( q * q' );
6  end
7  function [c,ceq] = nonlcon(q)
8      X = zeros(2,N+1);
9      X(:,1)=[-2 1]';
10     for i=1:N
11         X(:,i+1) = X(:,i) + dt * f(X(:,i),q(i));
12     end
13     c = [];
14     ceq = X(:,N+1);
15 end
16 function dxdt = f(x,u)
17     dxdt = [ x(2)
18             u ];
19 end

```